



DECSAI

Departamento de Ciencias de la Computación e I.A.

Universidad de Granada



Redes Neuronales

Fernando Berzal, berzal@acm.org

Redes Neuronales Artificiales



- Motivación
 - El cerebro humano
 - Computación neuromórfica
- Modelos de redes neuronales
 - Modelos de neuronas
 - Redes neuronales artificiales
- Historia de las redes neuronales artificiales
- Aplicaciones de las redes neuronales artificiales
- Herramientas





DECSAI

Departamento de Ciencias de la Computación e I.A.

Universidad de Granada



Redes Neuronales – Motivación

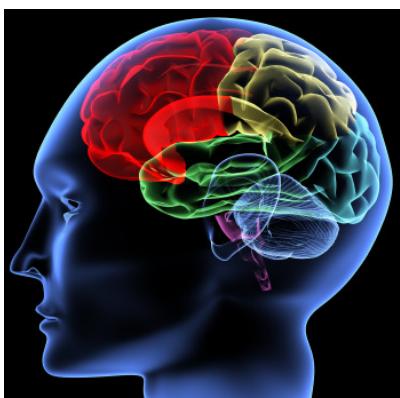
Fernando Berzal, berzal@acm.org

Introducción



El cerebro humano

Inspiración de las redes neuronales artificiales



Las RNA intentan modelar la estructura y funcionamiento de algunas partes del sistema nervioso animal.



Introducción



¿Por qué estudiar redes neuronales?

- Para comprender cómo funciona realmente el cerebro.
- Para diseñar un modelo de cómputo paralelo inspirado en las neuronas y sus sinapsis [conexiones] adaptativas.
- **Para resolver problemas prácticos utilizando algoritmos de aprendizaje inspirados en el cerebro.**

NOTA: Incluso aunque no sepamos realmente cómo funciona el cerebro, los algoritmos de aprendizaje nos serán muy útiles.

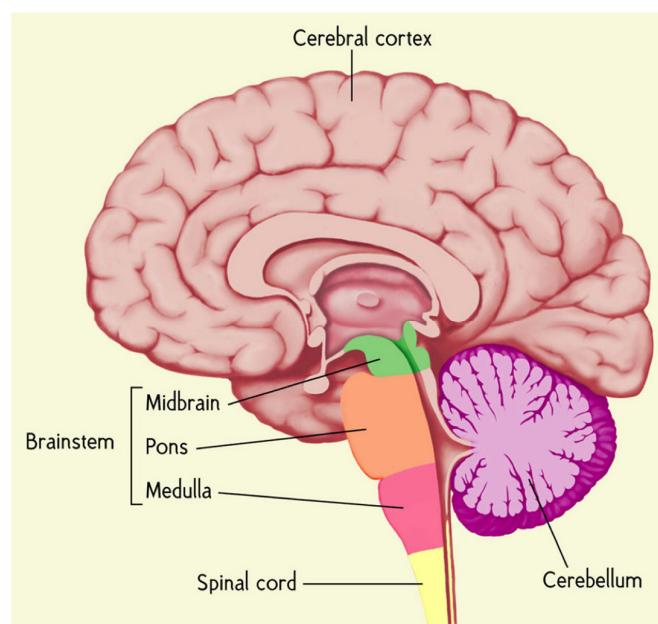


Introducción



El cerebro humano

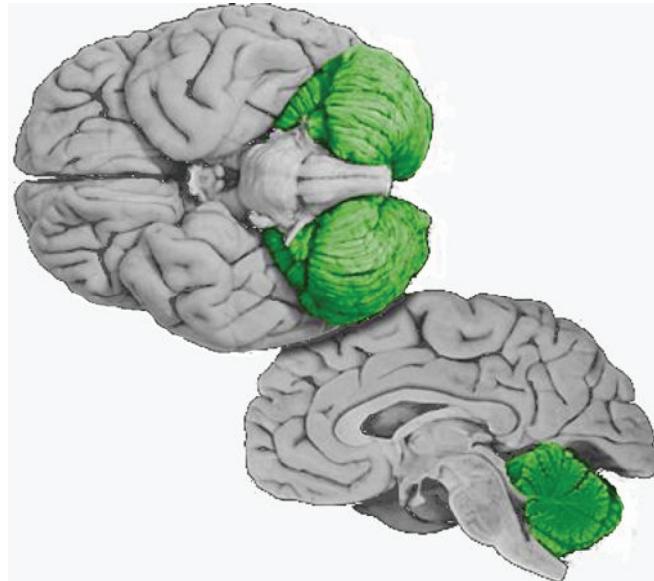
Anatomía del cerebro



Introducción



El cerebro humano Anatomía del cerebro

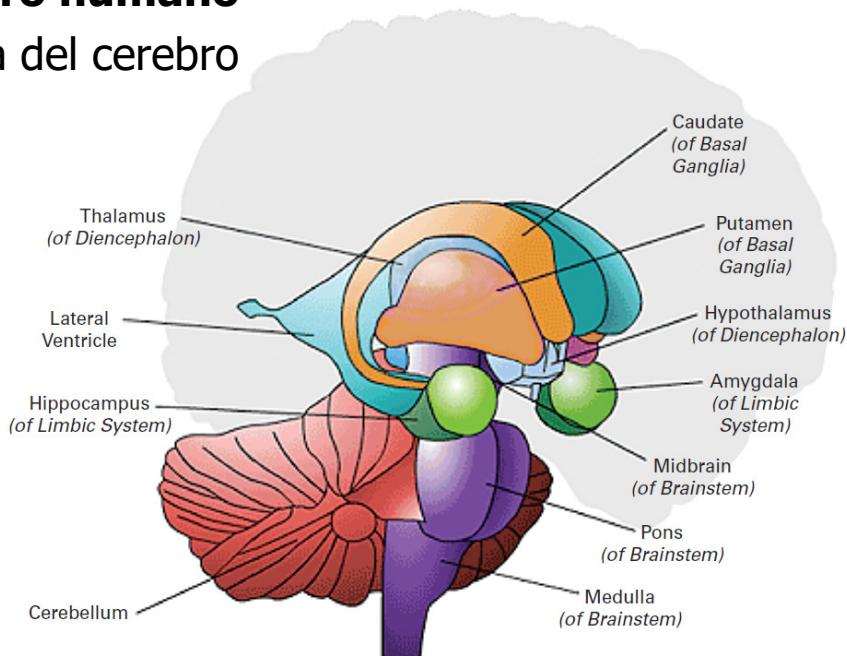


El cerebelo
[Sylvius 4 Online, Sinauer Associates]

Introducción



El cerebro humano Anatomía del cerebro



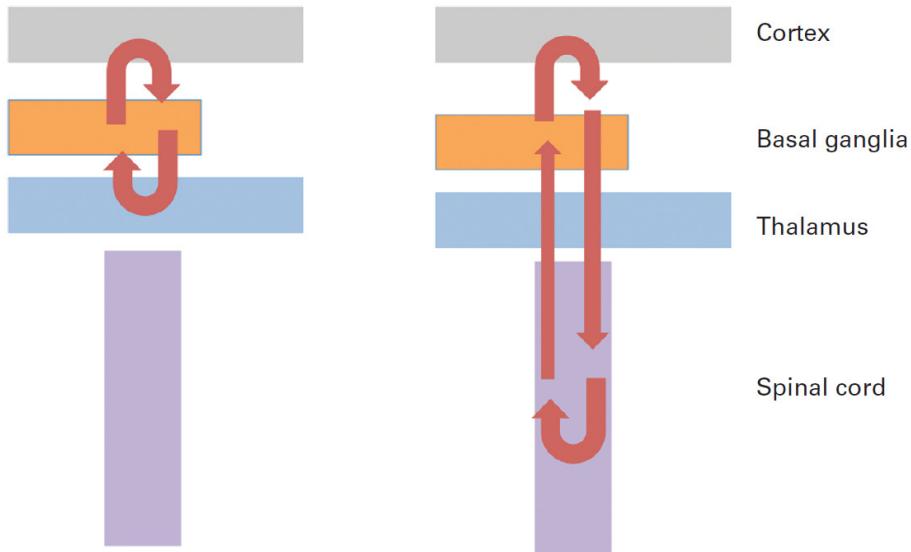
[Dana Ballard: Brain Computation as Hierarchical Abstraction, 2015]

Introducción



El cerebro humano

El ciclo de cálculo del cerebro



[Dana Ballard: Brain Computation as Hierarchical Abstraction, 2015]

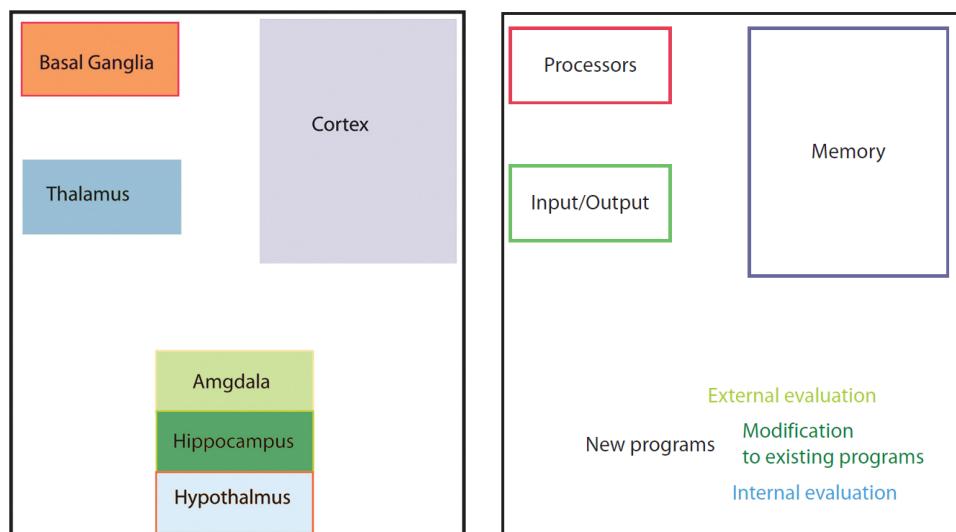


Introducción



El cerebro humano

Analogía entre el cerebro humano y un ordenador



[Dana Ballard: Brain Computation as Hierarchical Abstraction, 2015]



Introducción



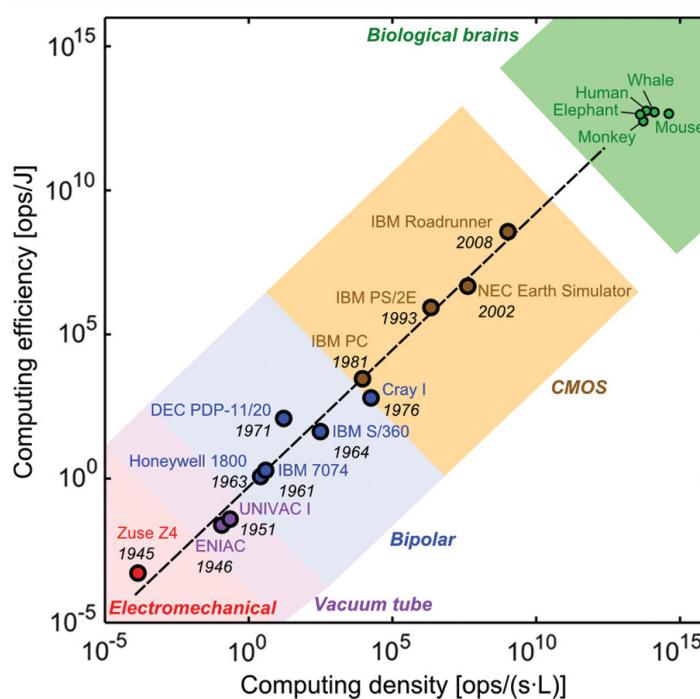
El cerebro humano

Diferencias entre un ordenador y el cerebro humano

Ordenador	Cerebro humano
Computación en serie	Computación en paralelo
Poco robusto	Tolerancia a fallos
Programable	Aprendizaje autónomo
Digital	Analógico
10^9 transistores	10^{11} neuronas $10^{14} \sim 10^{15}$ sinapsis
Nanosegundos (3.6GHz)	Milisegundos (4~90Hz)
51.2 GB/s	10 spikes/s
210,000,000 m/s	1 ~ 100 m/s
2.3×10^{13} TEPS	6.4×10^{14} TEPS



Introducción

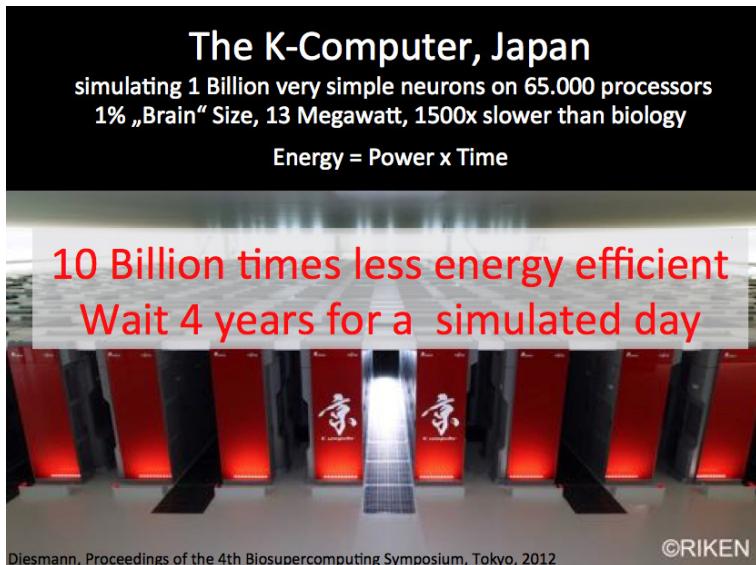


Introducción



Arquitecturas basadas en el cerebro

Simulación (muy ineficiente) → "Neuromorphic Computing"

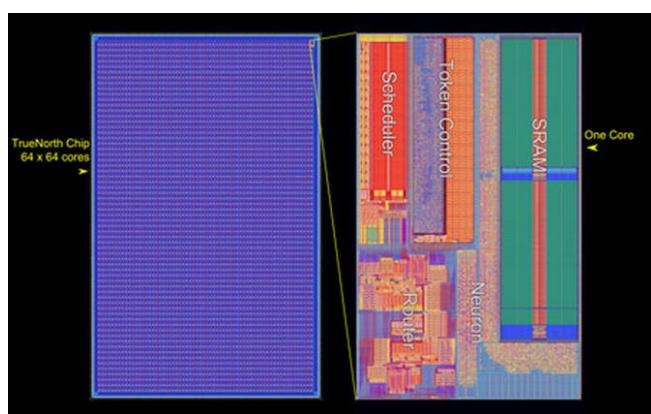
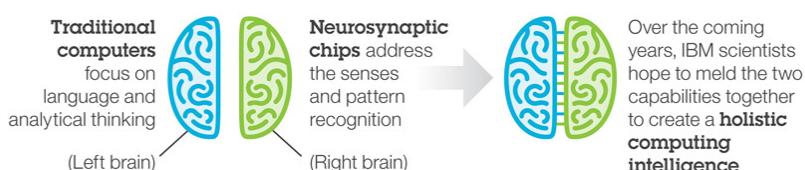


Introducción



Arquitecturas basadas en el cerebro

IBM TrueNorth Brain-inspired Computer



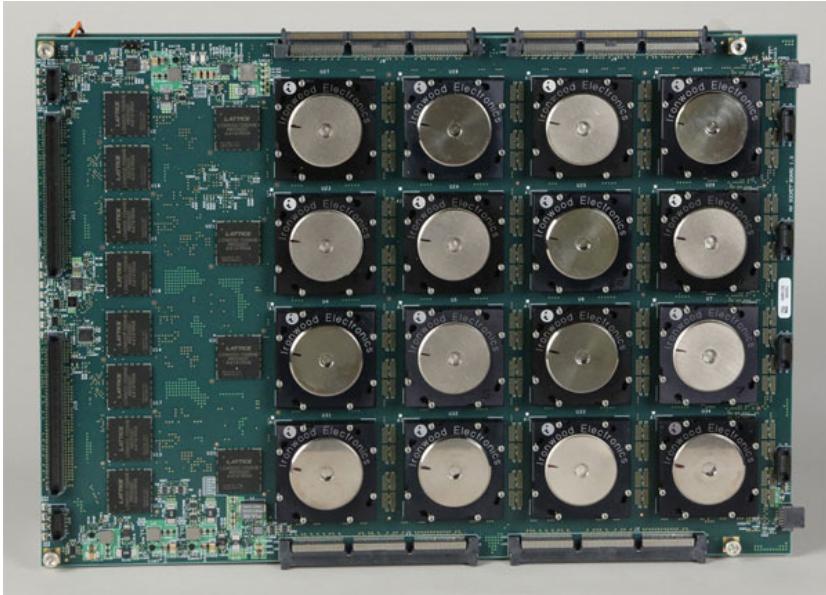
4096 cores
1M neurons
256M synapses
5.4B transistors
CMOS
70mW



Introducción



Arquitecturas basadas en el cerebro IBM TrueNorth Brain-inspired Computer



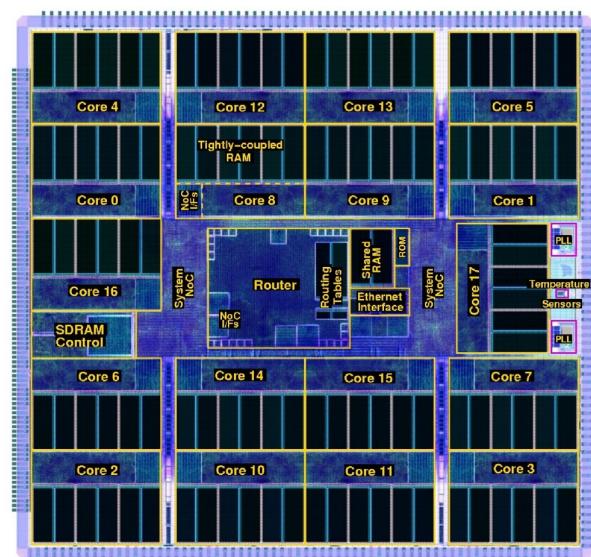
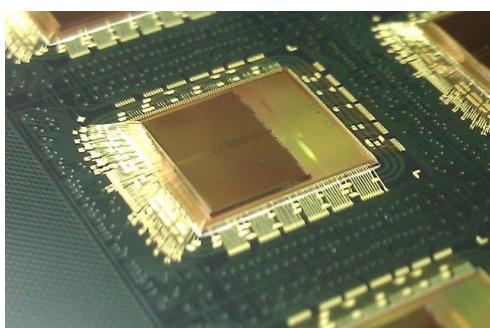
Synapse 16
16M neurons
4B synapses



Introducción



Arquitecturas basadas en el cerebro SpiNNaker project (UK)



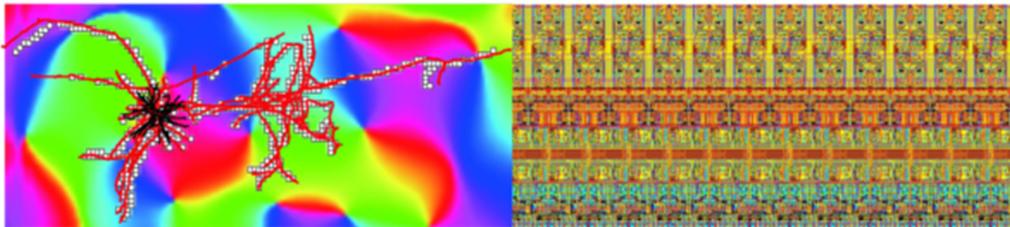
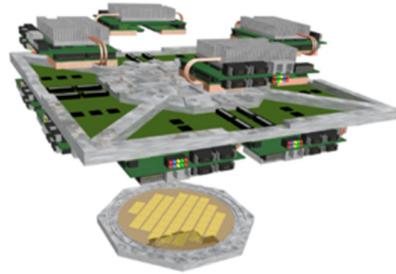
Globally Asynchronous Locally Synchronous (GALS) chip:
18 ARM968 processor nodes + 128MB Mobile DDR SDRAM
<http://apt.cs.manchester.ac.uk/projects/SpiNNaker/project/>



Introducción



Arquitecturas basadas en el cerebro BrainScaleS (Germany)



Mixed CMOS signals

<https://brainscales.kip.uni-heidelberg.de/>

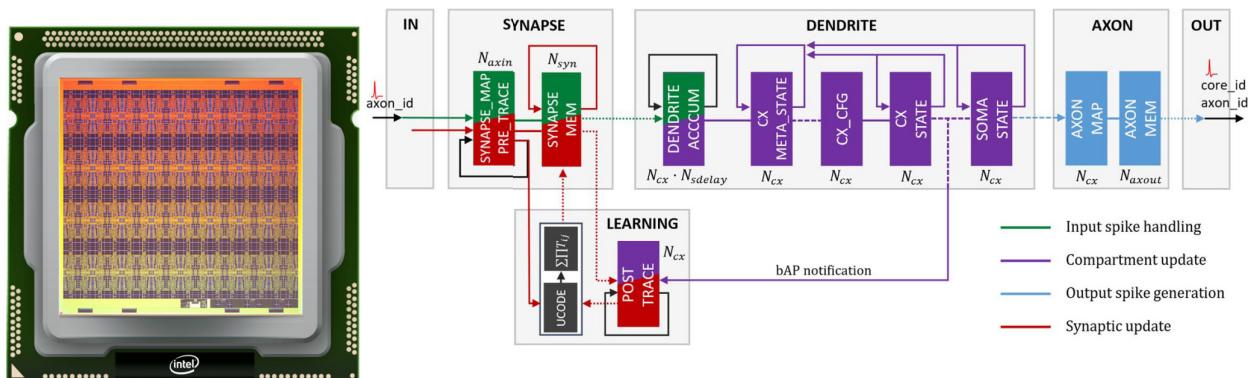


Introducción



Arquitecturas basadas en el cerebro

Intel Loihi (self-learning neuromorphic research chip)



SNNs [Spiking Neural Networks]

130k neuronas / chip, 60mm², 14nm

[https://www.intel.com/content/www/us/en/research/neuromorphic-computing.html/](https://www.intel.com/content/www/us/en/research/neuromorphic-computing.html)

<https://ieeexplore.ieee.org/document/8259423/>

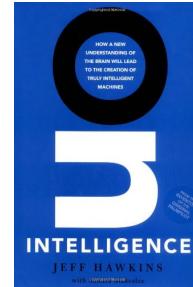
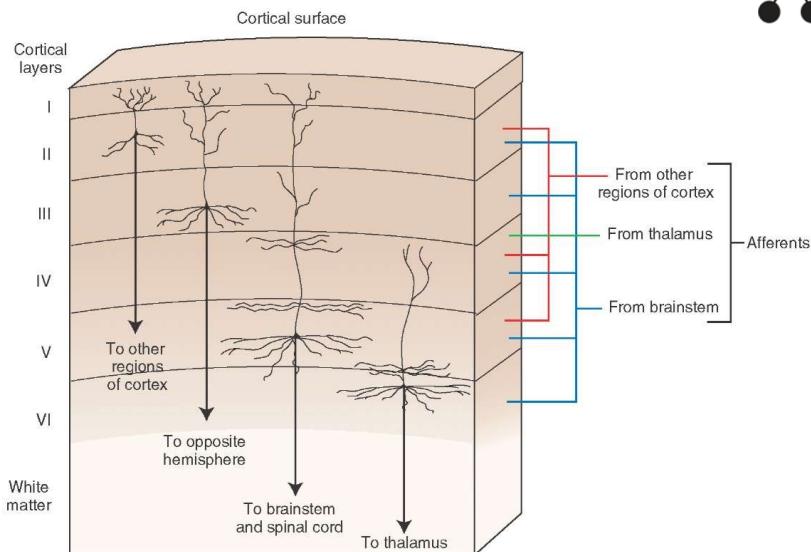


Introducción



Arquitecturas basadas en el cerebro

HTM [Hierarchical Temporal Memory]

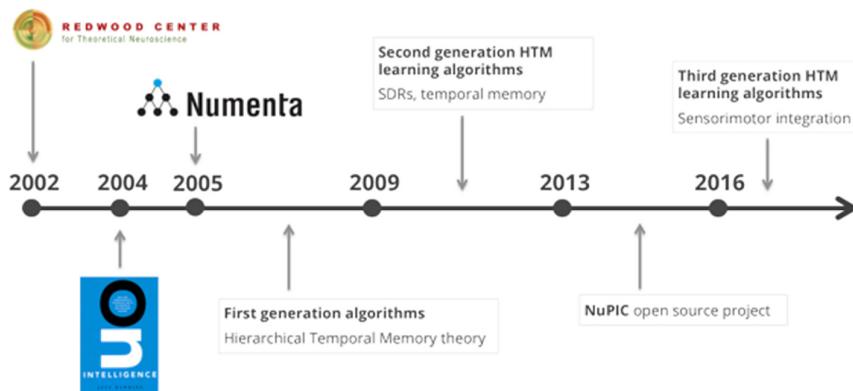


Introducción



Arquitecturas basadas en el cerebro

HTM [Hierarchical Temporal Memory]



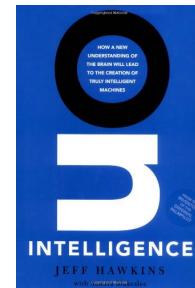
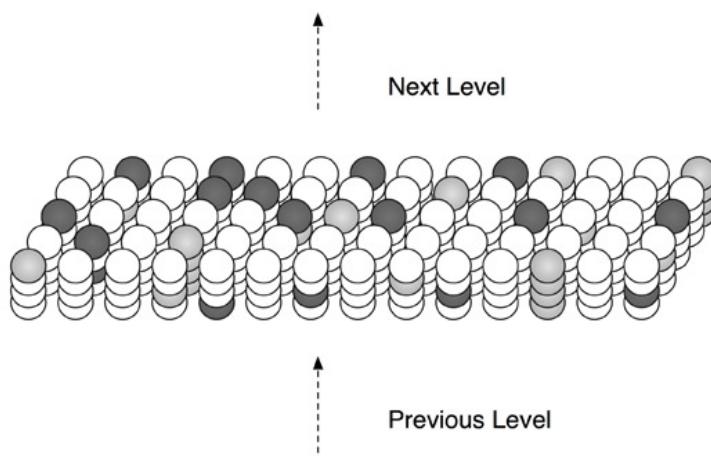
<http://numenta.com/>

Introducción



Arquitecturas basadas en el cerebro

HTM [Hierarchical Temporal Memory]



<http://numenta.com/>

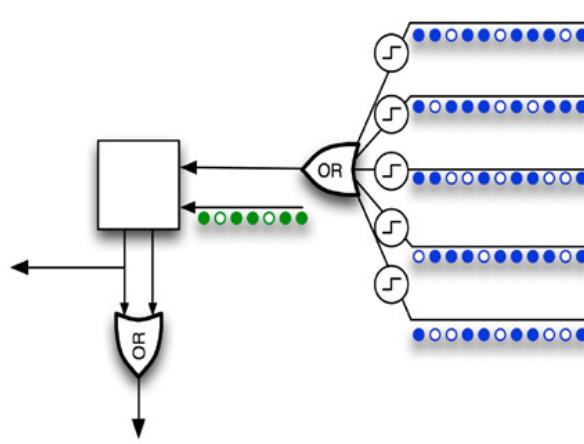
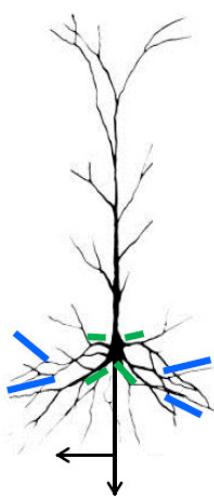


Introducción



Arquitecturas basadas en el cerebro

HTM [Hierarchical Temporal Memory]



<http://numenta.com/>





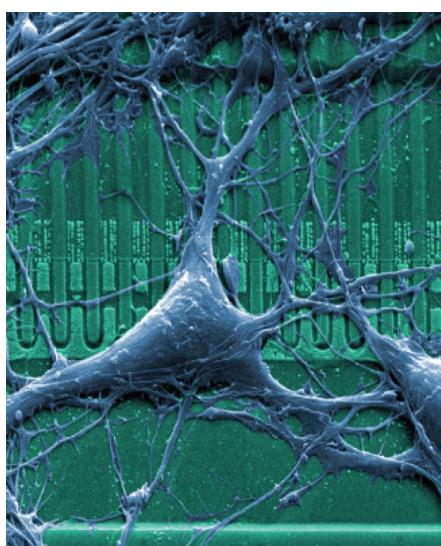
Modelos de redes neuronales

Fernando Berzal, berzal@acm.org

Introducción



Neuronas



Microfotografía de una neurona “cultivada” sobre una oblea de silicio.
[Peter Fromherz, Max Planck Institute]

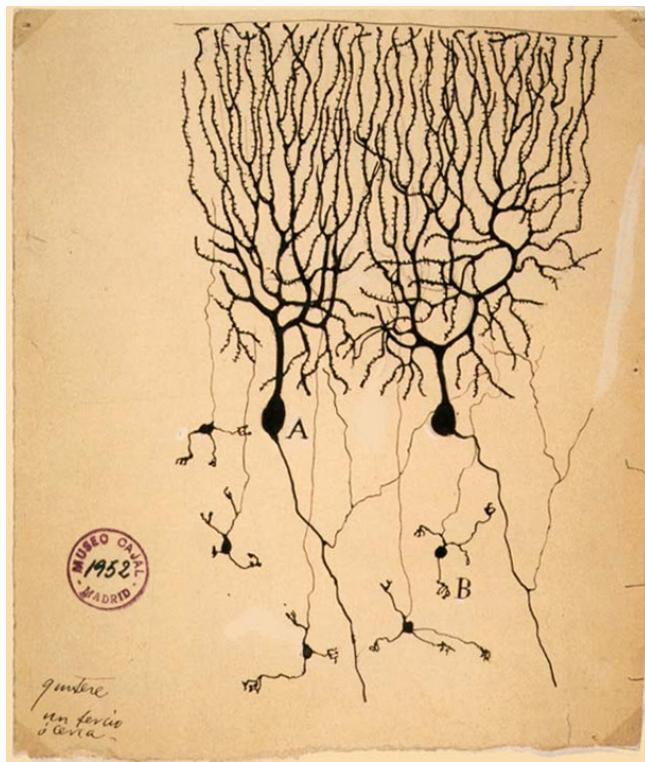


Introducción



Neuronas

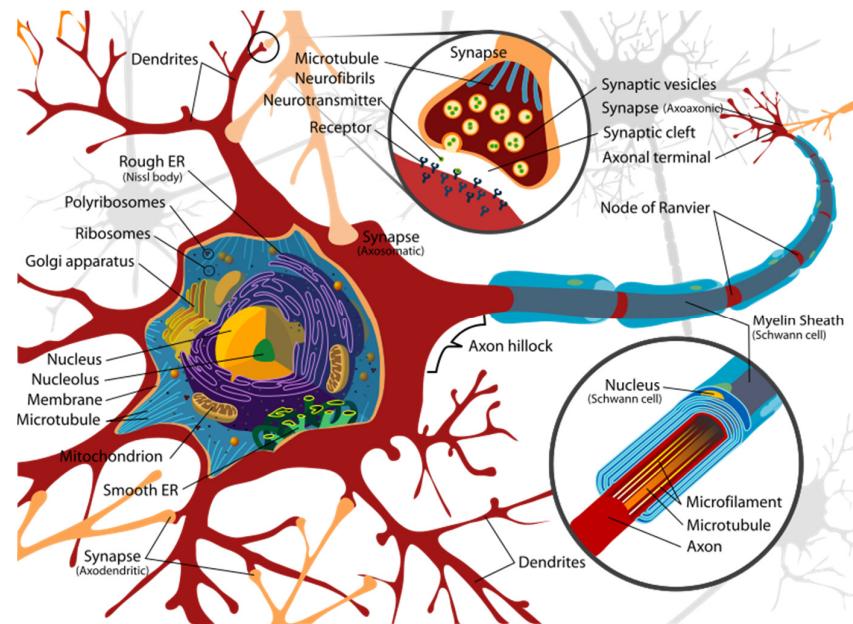
Neuronas del cerebelo
[Dibujo de Santiago Ramón y Cajal, 1899]



Introducción



Neuronas



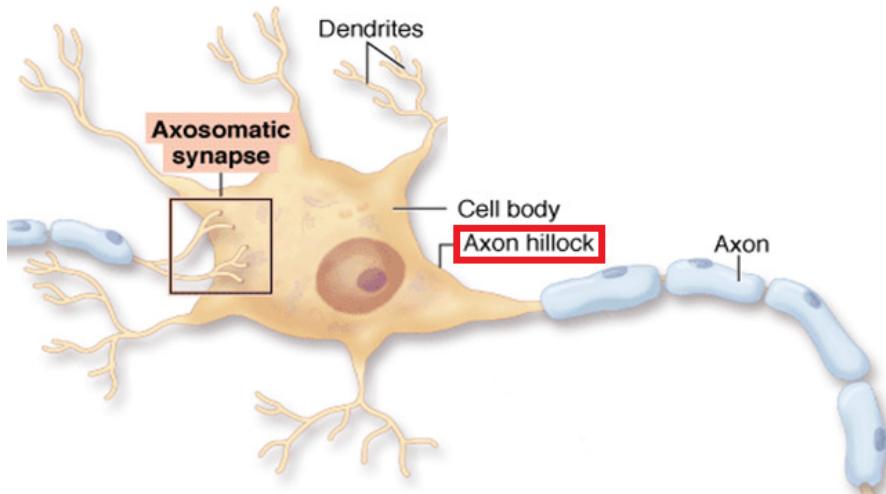
[Wikipedia]



Introducción



Neuronas



https://en.wikipedia.org/wiki/Axon_hillock

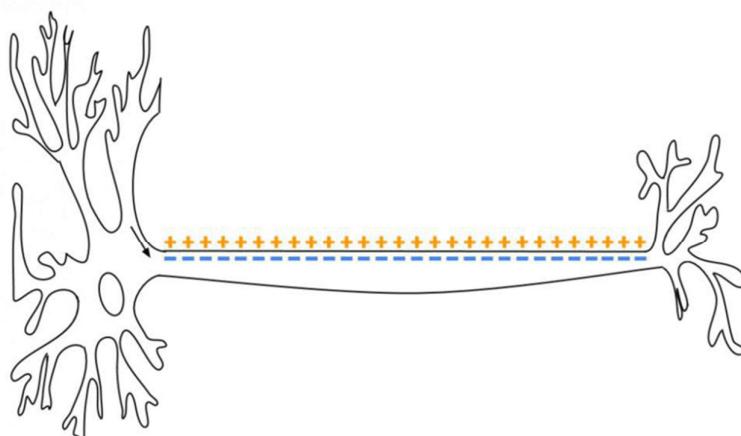


Introducción



Neuronas

Spike, a.k.a. action potential [potencial de acción]



https://en.wikipedia.org/wiki/Action_potential

MakeACI.com

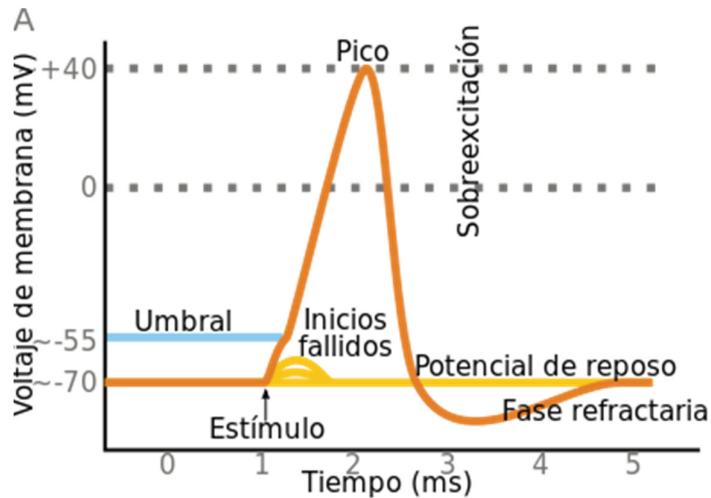


Introducción



Neuronas

Spike, a.k.a. action potential [potencial de acción]



https://en.wikipedia.org/wiki/Action_potential

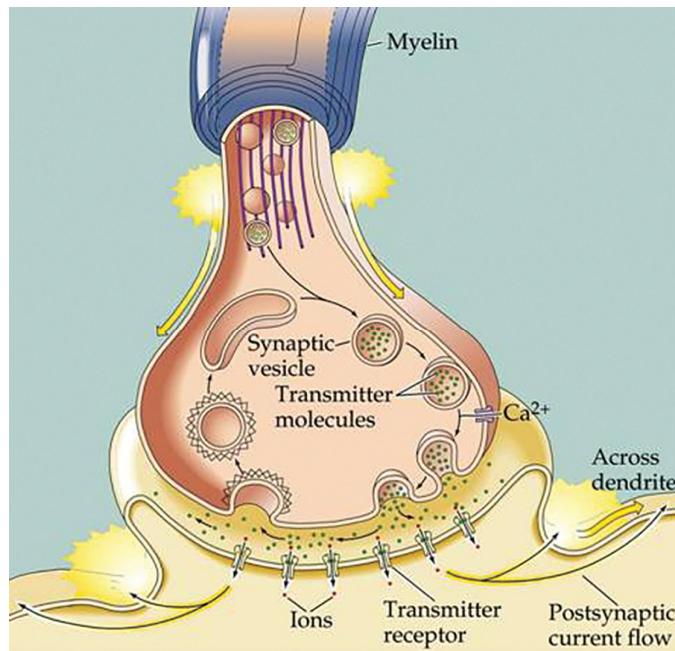


Introducción



Neuronas

Sinapsis



[Purves et al.: Neuroscience, 3rd edition, 2004]



Introducción



Neuronas

Sinapsis

Las sinapsis son lentas (en comparación con los transistores de un ordenador), pero...

- Son muy pequeñas y consumen muy poca energía.
- Se adaptan utilizando señales locales.

Como tenemos cerca de 10^{11} neuronas y de 10^{14} a 10^{15} sinapsis, muchas sinapsis pueden influir en un “cálculo” en un período de tiempo muy breve:

Ancho de banda muy superior al de un ordenador.



Introducción



Neuronas

Sinapsis

- El efecto de cada entrada sobre una neurona depende de un peso sináptico (positivo o negativo)
- Los pesos sinápticos se adaptan [plasticidad]: La “efectividad” de una sinapsis puede cambiar.
 - Neurona pre-sináptica:
Número de vesículas de neurotransmisores.
 - Neurona post-sináptica:
Número de receptores de neurotransmisores.

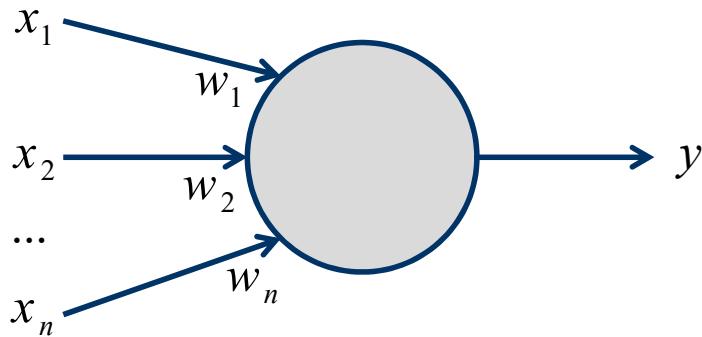


Modelos de redes neuronales



Neuronas

El modelo computacional más simple de una neurona



$$y = \sum_i x_i w_i = x_1 w_1 + x_2 w_2 + \dots + x_n w_n$$



Modelos de redes neuronales



Neuronas

- Diferentes partes del córtex se encargan de distintas tareas (daños locales tienen efectos específicos y la realización de tareas concretas aumenta el consumo de oxígeno en regiones determinadas).
- La estructura de todo el córtex es similar (6 capas de neuronas en una “servilleta arrugada” [Hawkins])

HIPÓTESIS

El córtex es un sistema de propósito general capaz de convertirse en hardware de propósito específico usando un algoritmo de aprendizaje (¿único?).



Modelos de redes neuronales



Redes neuronales artificiales

Modelos de neuronas

- Para modelar las neuronas tenemos que idealizarlas: Eliminar de detalles irrelevantes que no son esenciales para entender su funcionamiento.
- La idealización nos permitirá utilizar herramientas (p.ej. matemáticas) y establecer analogías.



Modelos de redes neuronales



Redes neuronales artificiales

Modelos de neuronas

- Una vez que tengamos un modelo básico, será más sencillo añadirle detalles y hacerlo más complejo para que sea más fiel a la realidad.
- Incluso modelos que son incorrectos de partida pueden resultarnos útiles.
p.ej. Asumir que las neuronas transmiten números reales en vez de potenciales de acción [spikes].



Modelos de redes neuronales

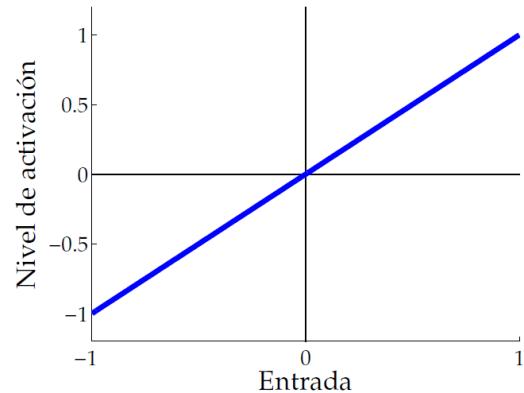


Redes neuronales artificiales

Modelos de neuronas: Neuronas lineales

$$y = b + \sum_i x_i w_i$$

y Salida
x Entradas
w Pesos
b Sesgo [bias]



- Sencillas, pero computacionalmente limitadas.



Modelos de redes neuronales



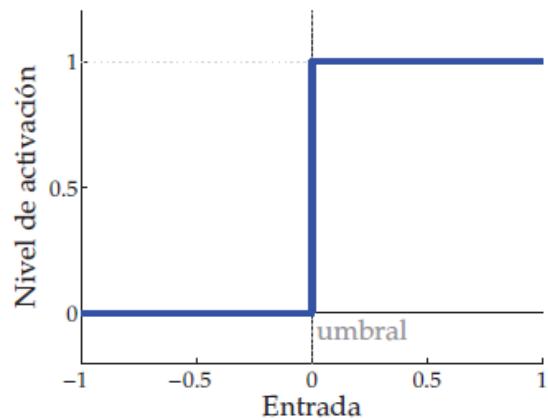
Redes neuronales artificiales

Modelos de neuronas: Neuronas binarias con umbral

[McCulloch & Pitts, 1943]

$$z = b + \sum_i x_i w_i$$

$$y = \begin{cases} 1 & \text{si } z \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$



Umbral $\theta = -b$



Modelos de redes neuronales



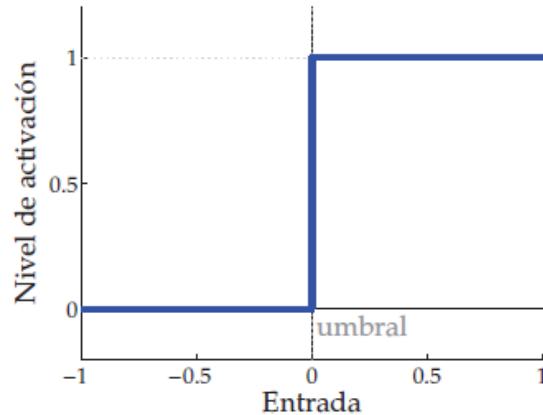
Redes neuronales artificiales

Modelos de neuronas: Neuronas binarias con umbral

[McCulloch & Pitts, 1943]

$$z = \sum_i x_i w_i$$

$$y = \begin{cases} 1 & \text{si } z \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$



Asumiendo $x_0=1$ y $w_0=b$ (umbral $\theta=-b$)



Modelos de redes neuronales

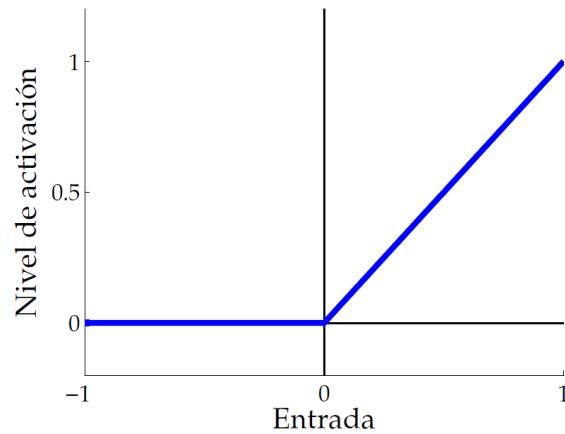


Redes neuronales artificiales

Modelos de neuronas: Neuronas lineales rectificadas

$$z = \sum_i x_i w_i$$

$$y = \begin{cases} z & \text{si } z \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$



Asumiendo $x_0=1$ y $w_0=b$ (umbral $\theta=-b$)



Modelos de redes neuronales

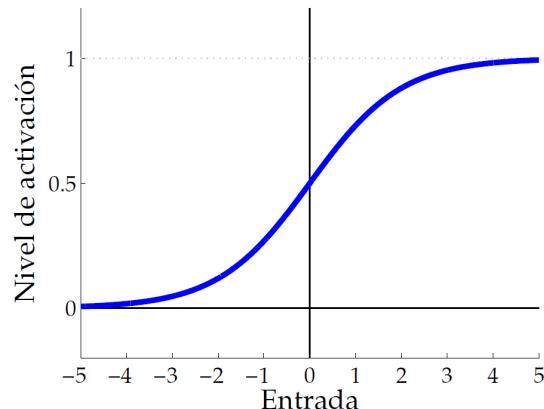


Redes neuronales artificiales

Modelos de neuronas: Neuronas sigmoidales

$$z = \sum_i x_i w_i$$

$$y = \frac{1}{1 + e^{-z}}$$



- Función de activación suavizada y acotada.
p.ej. Función logística, tangente hiperbólica...
- El uso de sus derivadas facilita el aprendizaje.



Modelos de redes neuronales

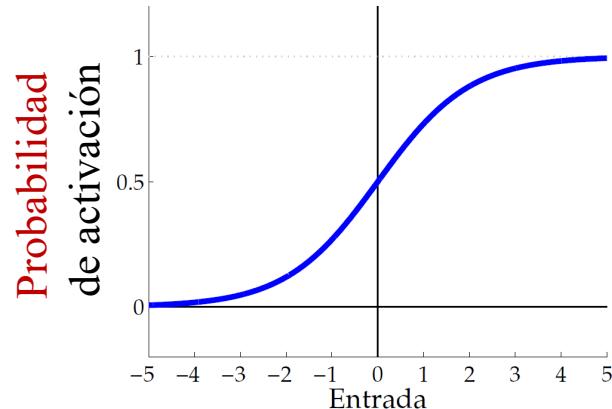


Redes neuronales artificiales

Modelos de neuronas: Neuronas binarias estocásticas

$$z = \sum_i x_i w_i$$

$$p = \frac{1}{1 + e^{-z}}$$



Las mismas ecuaciones que las neuronas sigmoidales, si bien su salida se interpreta como una probabilidad (de producir un spike en una pequeña ventana de tiempo)



Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)

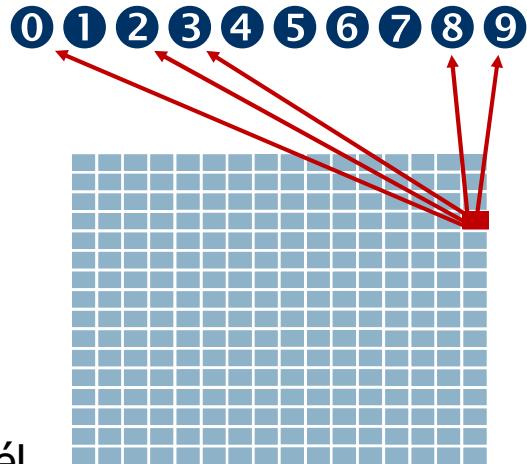
Red neuronal con 2 capas de neuronas:

- Capa de salida: Símbolos reconocidos.
- Capa de entrada: Píxeles de la imagen

Cada píxel vota si tiene tinta en él.

Cada píxel puede votar a varios símbolos.

El símbolo con más votos gana.

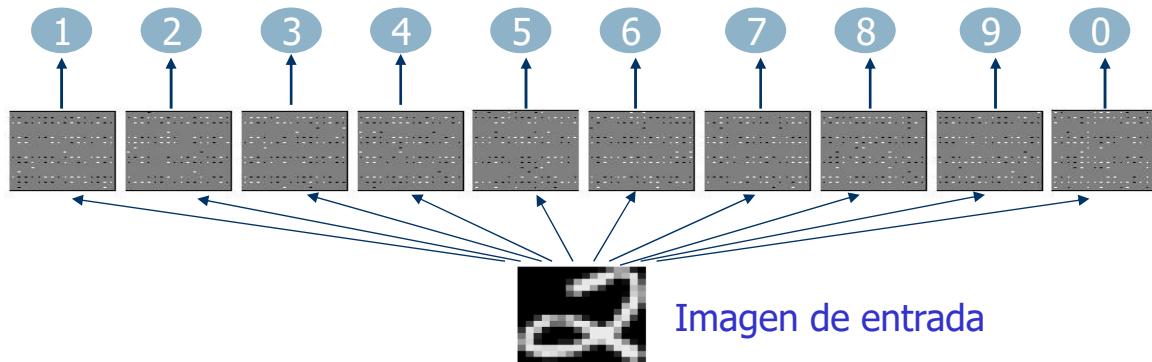


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Visualización: Cada unidad de salida tiene su propio "mapa" de la imagen de entrada que muestra el peso asociado a cada píxel de la imagen de entrada.

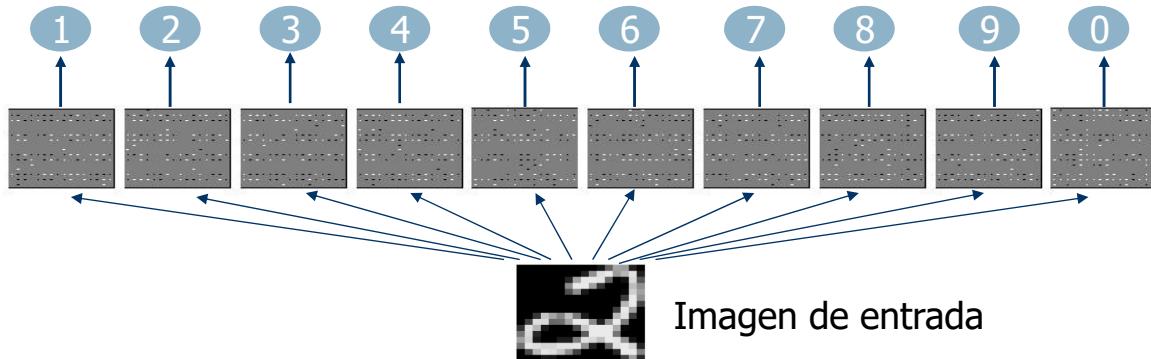


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Entrenamiento: Se le enseña una imagen a la red...

- Se incrementan los pesos asociados a los píxeles activos para el símbolo de la imagen (clase correcta).
- Se decrementan los pesos de los píxeles activos de la imagen si la red se equivoca y predice un símbolo equivocado (error).

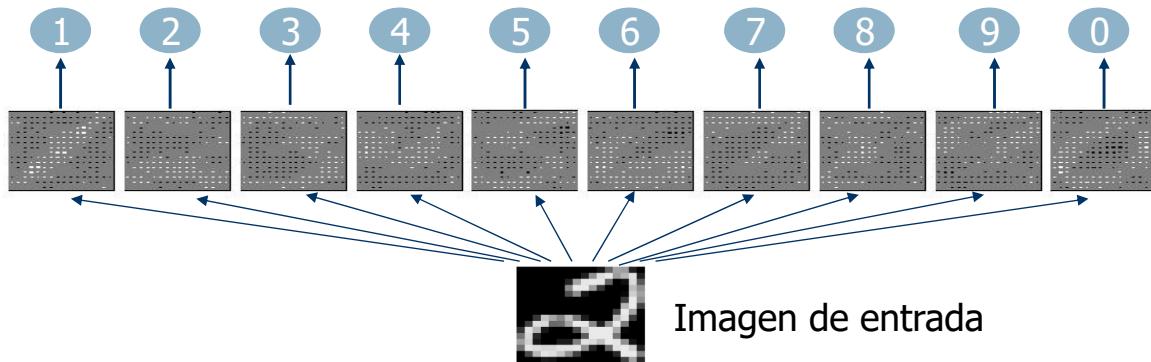


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Aprendizaje...

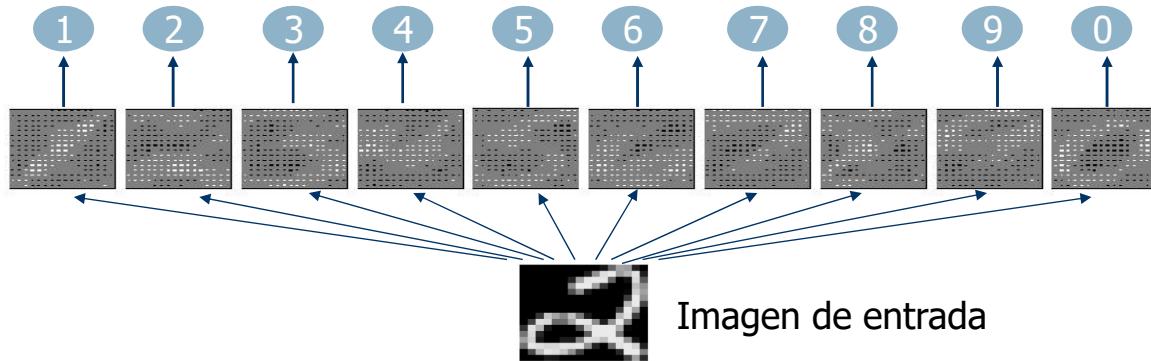


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Aprendizaje...

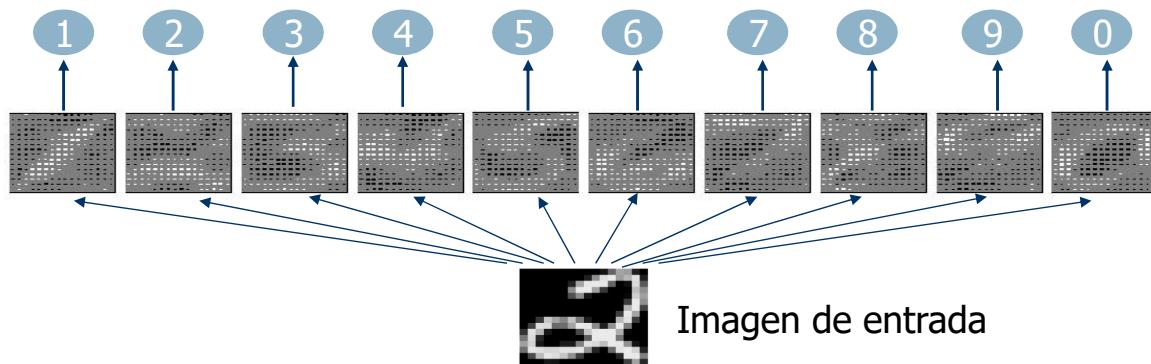


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Aprendizaje...

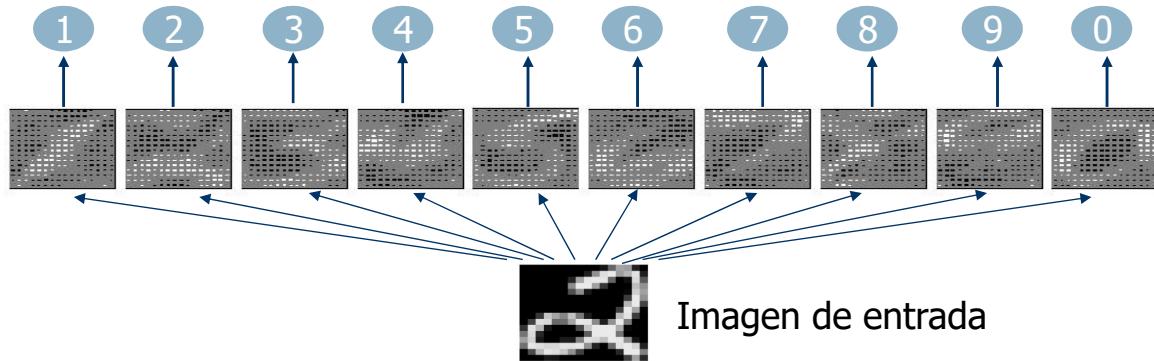


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Aprendizaje...

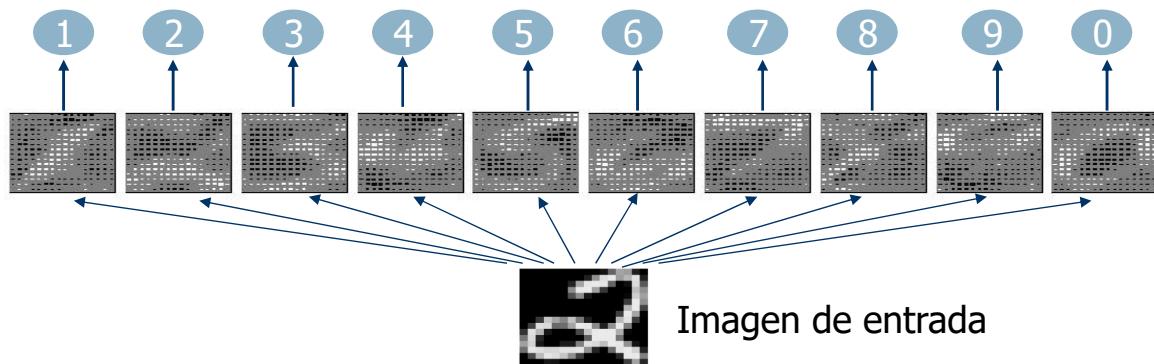


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Aprendizaje...

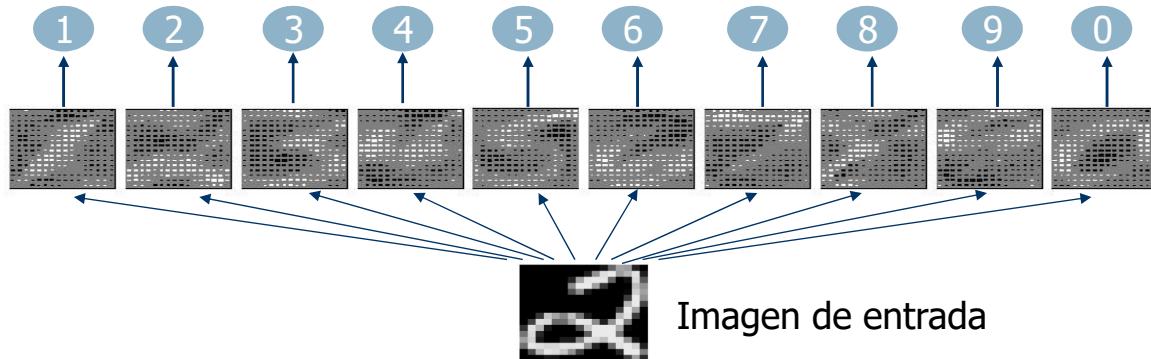


Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)



Aprendizaje...



Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)

- Una red neuronal tan simple, con una capa de entrada y una de salida, es equivalente a tener una plantilla rígida para cada símbolo (se elige el símbolo cuya plantilla se solapa más con la imagen de entrada).
- Las distintas formas en que pueden variar los dígitos manuscritos son demasiado complicadas para que se puedan capturar con plantillas tan simples.



Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)

- Aprenderemos formas de capturar las variaciones de los símbolos aprendiendo sus características: capas intermedias de neuronas, a.k.a. capas ocultas.
- Podremos incluso hacerlo utilizando técnicas no supervisadas, creando una representación interna de la entrada que luego sea útil en otras tareas (p.ej. aprendizaje supervisado para clasificar símbolos).



Modelos de redes neuronales



Redes neuronales artificiales

Ejemplo de aprendizaje: Reconocimiento de dígitos (OCR)

- Seremos capaces de clasificar correctamente símbolos como los siguientes la primera vez que los veamos:

0 0 0 1 1 1 1 1 2

2 2 2 2 2 2 3 3 3

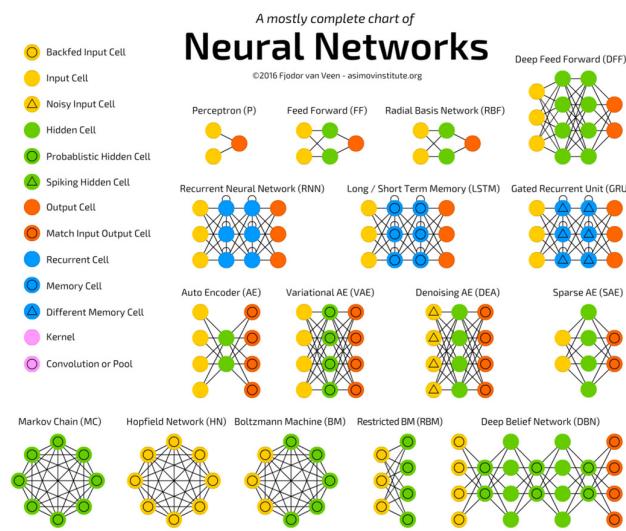
3 4 4 4 4 5 5 5 5

6 6 7 7 7 7 8 8 8

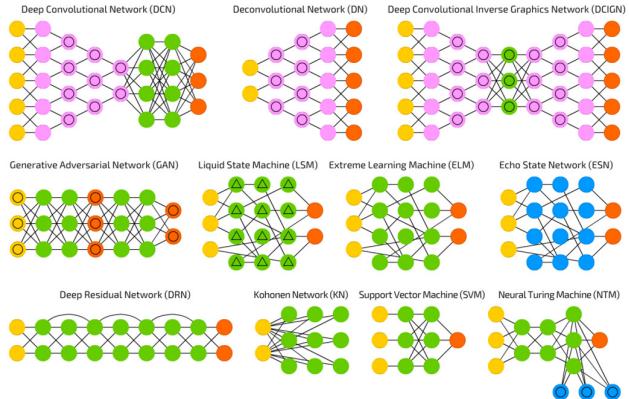
8 8 9 9 9 9 9 9



Modelos de redes neuronales



El zoo de las redes neuronales



DECSAI
Departamento de Ciencias de la Computación e I.A.

Universidad de Granada

Historia de las Redes Neuronales
Fernando Berzal, berzal@acm.org

Historia



- | | |
|-----------|---|
| 1943 | Neurona de McCulloch-Pitts |
| 1957 | Perceptrón |
| 1960 | ADALINE |
| 1969 | Minsky & Papert: "Perceptrons" |
| 1974-1986 | Backpropagation |
| 1982 | Redes de Hopfield |
| 1985 | Máquinas de Boltzmann |
| 1986 | Harmonium [Restricted Boltzmann Machines] |
| 2006 | Deep Learning |

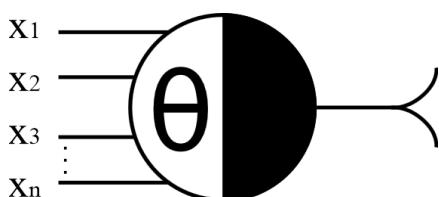


Historia de las redes neuronales artificiales Neurona de McCulloch & Pitts

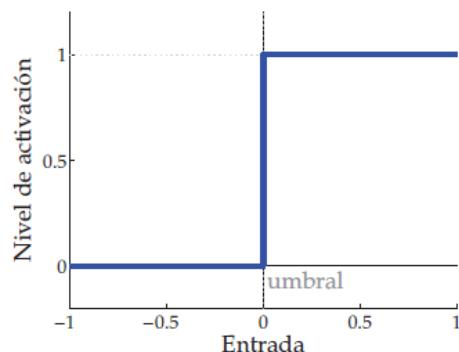


Modelo de neurona de McCulloch & Pitts

Nacimiento de las redes neuronales artificiales:
Circuitos booleanos como modelos del cerebro



Threshold Logic Unit (TLU):
Primer modelo de neurona artificial



1943

Warren McCulloch & Walter Pitts:
"A logical calculus of the ideas
immanent in nervous activity."
Bulletin of Mathematical Biophysics, 5:115-133.



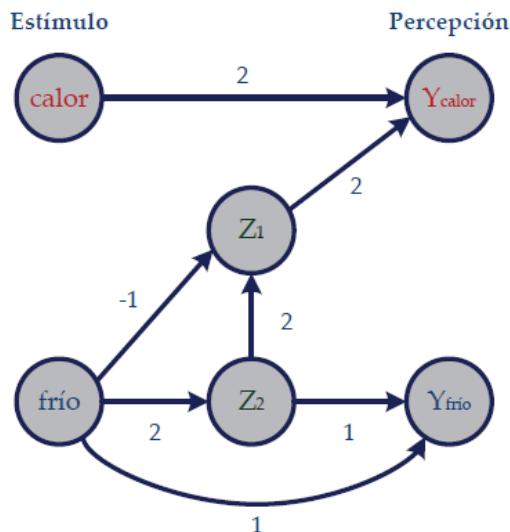
Historia de las redes neuronales artificiales

Neurona de McCulloch & Pitts



Modelo de neurona de McCulloch & Pitts

Ejemplo: Percepción fisiológica del calor y del frío



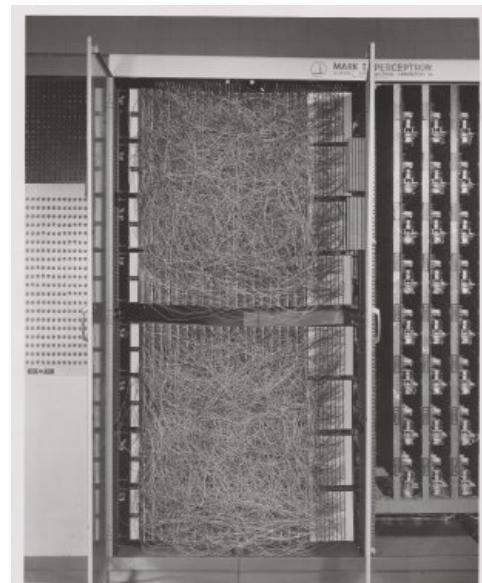
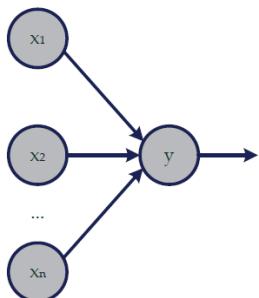
58

Historia de las redes neuronales artificiales

El perceptrón



Primer algoritmo
de aprendizaje supervisado



Mark I Perceptron Machine
Primera implementación...

1957

Frank Rosenblatt:
"The Perceptron - A perceiving and recognizing
automaton". Report 85-460-1,
Cornell Aeronautical Laboratory, 1957.



59

Historia de las redes neuronales artificiales

El perceptrón



En la prensa...
New York Times

NEW NAVY DEVICE LEARNS BY DOING

Psychologist Shows Embryo
of Computer Designed to
Read and Grow Wiser

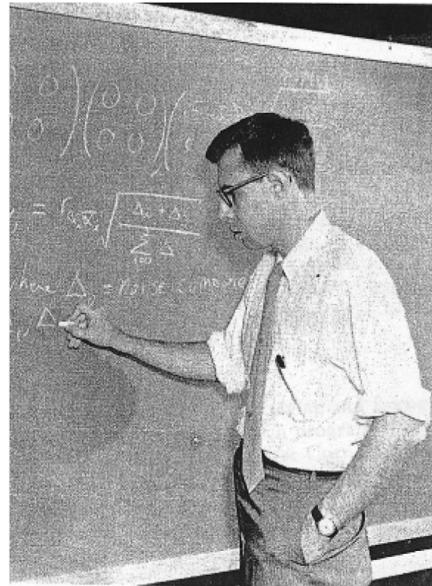
WASHINGTON, July 7 (UPI)—The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence.

The embryo—the Weather Bureau's \$2,000,000 "704" computer—learned to differentiate between right and left after fifty attempts in the Navy's demonstration for newspapermen.

The service said it would use this principle to build the first of a series of Perception thinking machines that will be able to read and write. It is expected to be finished in about a year at a cost of \$100,000.

Dr. Frank Rosenblatt, designer of the Perceptron, conducted the demonstration. He said the machine would be the first device to think as the human brain. As do human beings, Perceptrons will make mistakes at first, but will grow wiser as it gains experience, he said.

Dr. Rosenblatt, a research psychologist at the Cornell Aeronautical Laboratory, Buffalo, said Perceptrons might be fired to the planets as mechanical space explorers.



1958



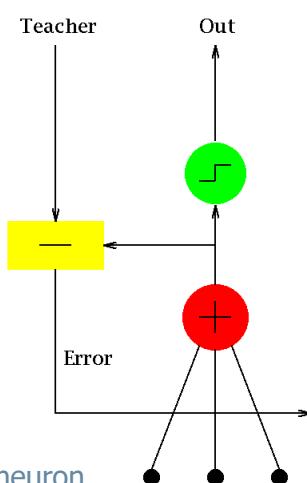
Historia de las redes neuronales artificiales

El ADALINE



ADALINE [Adaptive Linear Element/Neuron]

Red neuronal de una sola capa
y dispositivo físico construido con memristores.



Bernard Widrow:
An adaptive "ADALINE" neuron
using chemical "memristors"
Technical Report 1553-2
Stanford University, 1960

1960



Historia de las redes neuronales artificiales

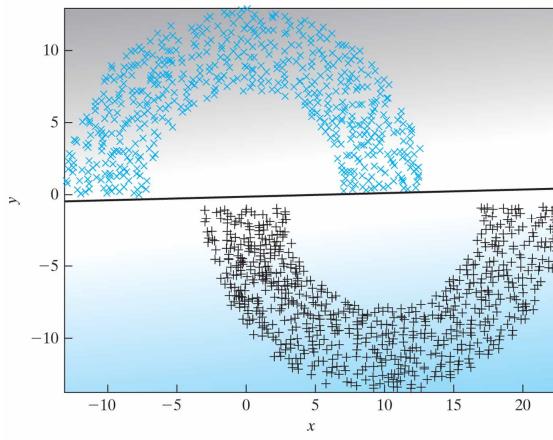
El perceptrón



En realidad...

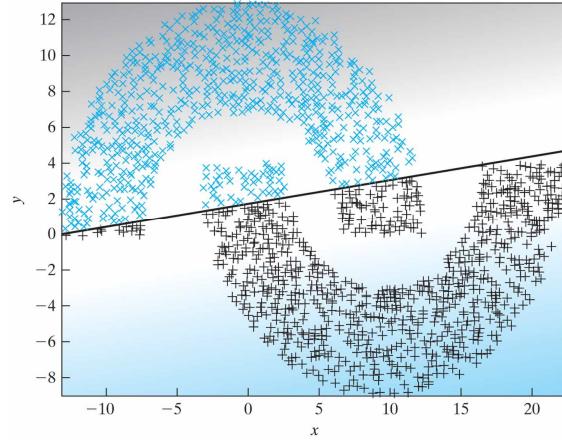
Un clasificador lineal

Classification using perceptron with distance = 1, radius = 10, and width = 6



(b) testing result

Classification using perceptron with distance = -4, radius = 10, and width = 6



(b) testing result

[Haykin: "Neural Networks and Learning Machines", 3rd edition]



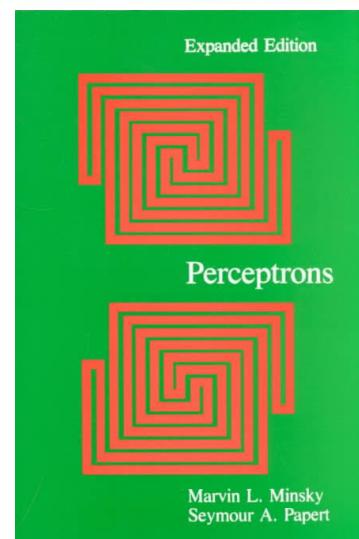
Historia de las redes neuronales artificiales

El perceptrón



Análisis de las capacidades
y limitaciones del perceptrón:

- Muchos pensaron que esas limitaciones se extendían a todos los modelos de redes neuronales, aunque no es así.
- Abandono de los modelos conexiónistas.
- La investigación en redes neuronales casi desaparece.



1969

Marvin Minsky & Seymour Papert:
"Perceptrons: An Introduction to Computational
Geometry". MIT Press, expanded edition, 1987
ISBN 0262631113

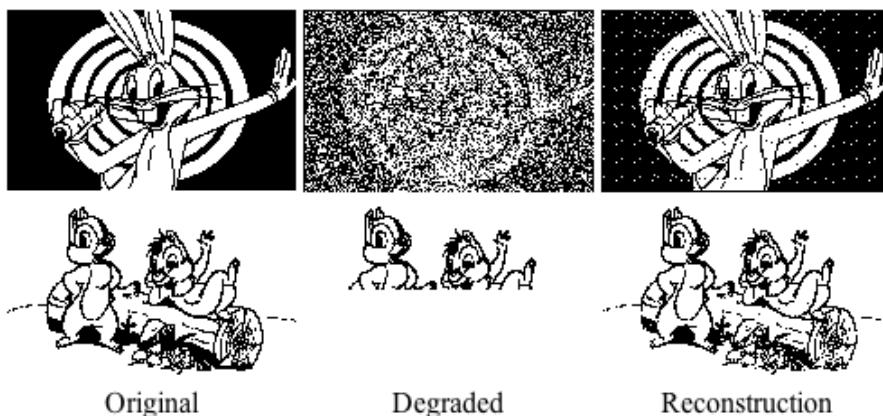


Historia de las redes neuronales artificiales

Redes de Hopfield



Redes recurrentes
que funcionan como memorias asociativas



1982

John J. Hopfield:
"Neural networks and physical systems
with emergent collective computational abilities"
Proceedings of the National Academy of Sciences
PNAS 79(8):2554–2558, 1982

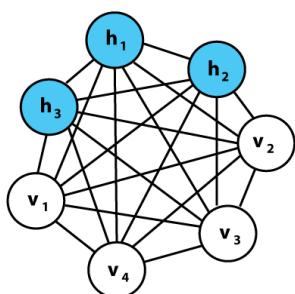


Historia de las redes neuronales artificiales

Máquinas de Boltzmann



Un contraejemplo:
Sí que se pueden
entrenar redes con
múltiples capas de
neuronas.



1985

David H. Ackley, Geoffrey E. Hinton & Terrence J. Sejnowski: "A Learning Algorithm for Boltzmann Machines", Cognitive Science 9(1):147–169, 1985.
DOI 10.1207/s15516709cog0901_7



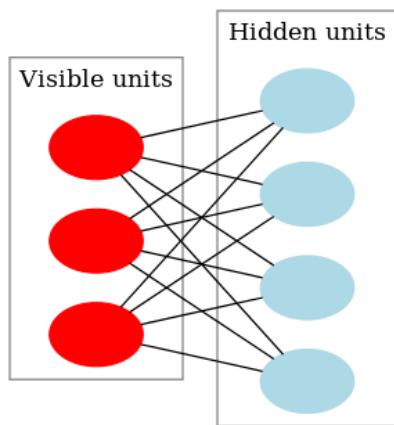
Historia de las redes neuronales artificiales

Máquinas de Boltzmann



Máquinas de Boltzmann restringidas

Harmonium = Restricted Boltzmann Machines



(máquinas de Boltzmann con estructura fija:
grafos bipartidos con una capa de neuronas
ocultas y una capa de neuronas “visibles”,
sin conexiones entre las
neuronas de la misma capa)

1986

Paul Smolensky: “Information Processing in Dynamical Systems: Foundations of Harmony Theory”,
incluido en David E. Rumelhart & James L. McClelland,
“Parallel Distributed Processing: Explorations in the Microstructure of Cognition”,
Volume 1: Foundations, chapter 6, pp. 194-281.
MIT Press, 1986. ISBN 0-262-68053-X.



Historia de las redes neuronales artificiales

Modelos alternativos



Otros modelos clásicos de redes neuronales artificiales

- Neocognitron
Kunihiko Fukushima, 1980
- Self-Organizing Map [SOM]
Teuvo Kohonen, 1982
- Counter-Propagation
Robert Hecht-Nielsen, 1986
- Adaptive Resonance Theory [ART]
Stephen Grossberg & Gail Carpenter, 1987
- Bidirectional Associative Memory [BAM]
Bart Kosko, 1988

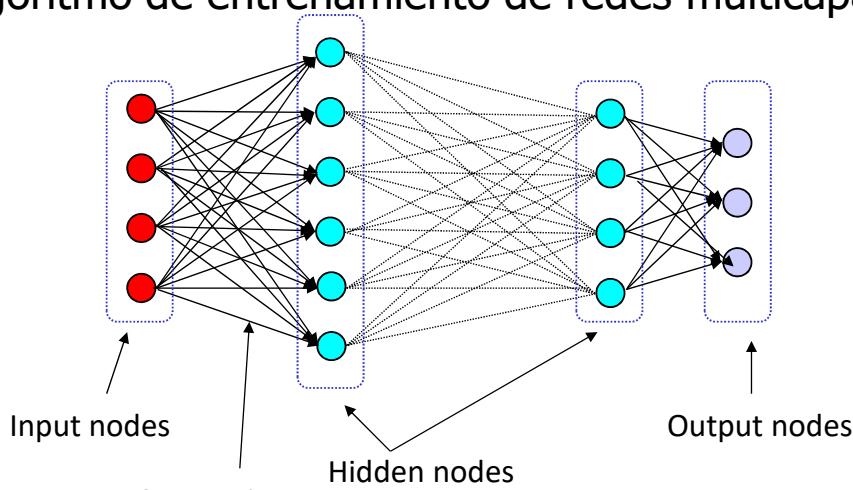


Historia de las redes neuronales artificiales

Backpropagation



Renacimiento de las redes neuronales artificiales
Algoritmo de entrenamiento de redes multicapa



1986

David E. Rumelhart, Geoffrey E. Hinton & Ronald J. Williams: "Learning representations by back-propagating errors" Nature 323(6088):533–536, 1986. DOI 10.1038/323533a0

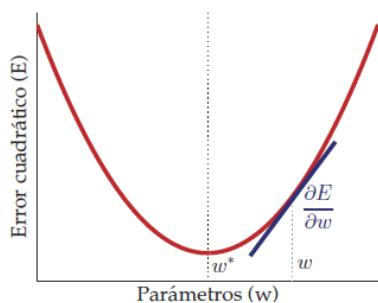


Historia de las redes neuronales artificiales

Backpropagation



Algoritmo de entrenamiento



$$\Delta w_i = -\eta \frac{\partial E}{\partial w_i}$$

1986

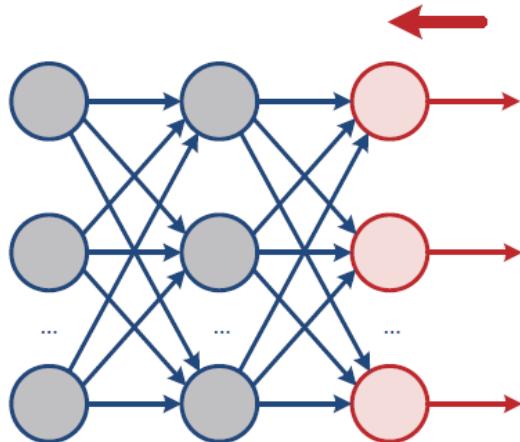


Historia de las redes neuronales artificiales

Backpropagation



Propagación de errores $\delta E / \delta y$

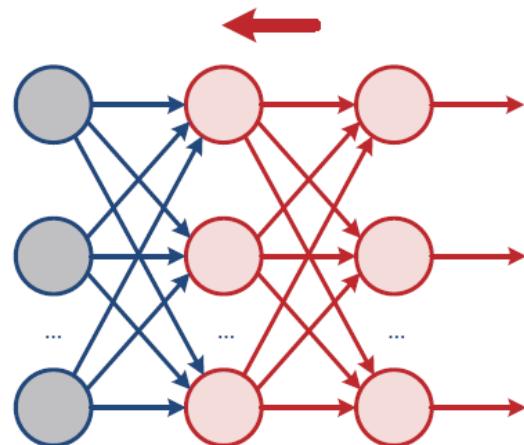


Historia de las redes neuronales artificiales

Backpropagation



Propagación de errores $\delta E / \delta y$

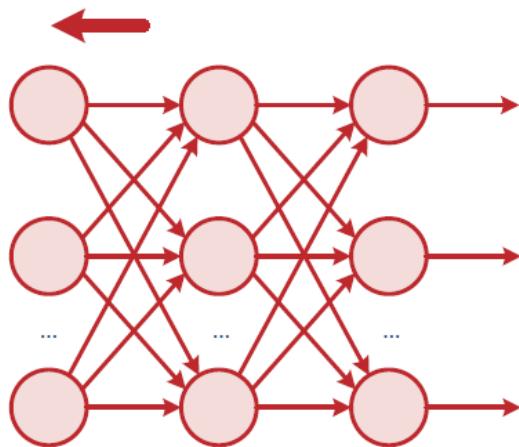


Historia de las redes neuronales artificiales

Backpropagation



Propagación de errores $\delta E / \delta y$

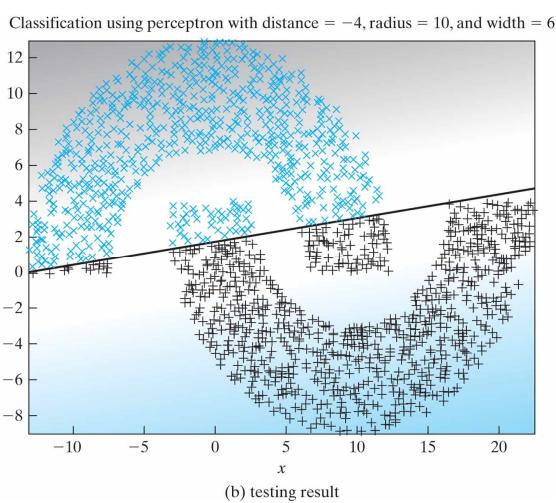


Historia de las redes neuronales artificiales

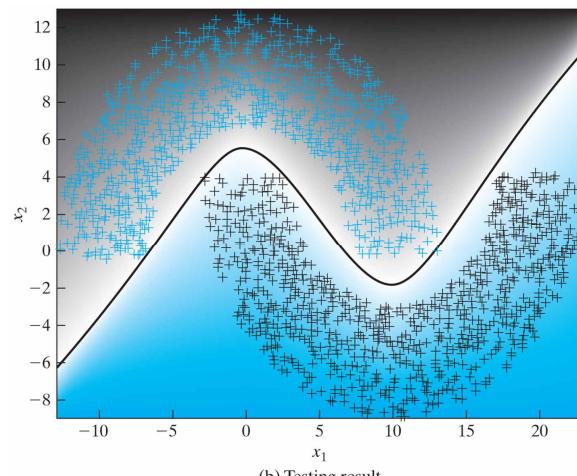
Backpropagation



El resultado...



Perceptrón



Red multicapa



Historia de las redes neuronales artificiales

Backpropagation



Algoritmo redescubierto en múltiples ocasiones...

■ Sistemas de control (años 60)

Arthur E. Bryson, W.F. Denham & S.E. Dreyfus: "Optimal programming problems with inequality constraints. I: Necessary conditions for extremal solutions." AIAA J. 1(11):2544-2550, **1963**.

Arthur E. Bryson & Yu-Chi Ho: "Applied optimal control: optimization, estimation, and control." Blaisdell Publishing Company / Xerox College Publishing, p. 481, **1969**.

■ Diferenciación automática (años 70)

Seppo Linnainmaa: The representation of the cumulative rounding error of an algorithm as a Taylor expansion of the local rounding errors. Master's Thesis (in Finnish), University of Helsinki, 6-7, **1970**.

Seppo Linnainmaa: "Taylor expansion of the accumulated rounding error". BIT Numerical Mathematics. 16(2):146–160, **1976**. DOI 10.1007/bf01931367.

1986???



Historia de las redes neuronales artificiales

Backpropagation

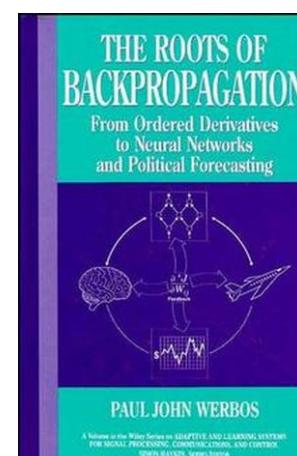


Algoritmo redescubierto en múltiples ocasiones...

■ Redes neuronales (1974!!!)

Paul John Werbos: "Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences." PhD thesis, Harvard University, **1974**.

Paul John Werbos:
"The Roots of Backpropagation:
From Ordered Derivatives
to Neural Networks and Political Forecasting."
John Wiley & Sons, Inc., 1994.
ISBN 0471598976



1986???



Historia de las redes neuronales artificiales

Backpropagation



Política & Publicaciones

Referencias bibliográficas del artículo de Nature

Learning representations by back-propagating errors

David E. Rumelhart*, Geoffrey E. Hinton†
& Ronald J. Williams*

Received 1 May; accepted 31 July 1986.

1. Rosenblatt, F. *Principles of Neurodynamics* (Spartan, Washington, DC, 1961).
2. Minsky, M. L. & Papert, S. *Perceptrons* (MIT, Cambridge, 1969).
3. Le Cun, Y. *Proc. Cognitiva* 85, 599-604 (1985).
4. Rumelhart, D. E., Hinton, G. E. & Williams, R. J. in *Parallel Distributed Processing: Explorations in the Microstructure of Cognition*. Vol. 1: Foundations (eds Rumelhart, D. E. & McClelland, J. L.) 318-362 (MIT, Cambridge, 1986).



Historia de las redes neuronales artificiales

Backpropagation



Política & Publicaciones

Geoffrey Hinton interview

Neural Networks & Deep Learning



"... we managed to get a paper into Nature in 1986. And I did quite a lot of political work to get the paper accepted. I figured out that one of the referees was probably going to be Stuart Sutherland, who was a well known psychologist in Britain. And I went to talk to him for a long time, and explained to him exactly what was going on. And he was very impressed by the fact that we showed that backprop could learn representations for words..."



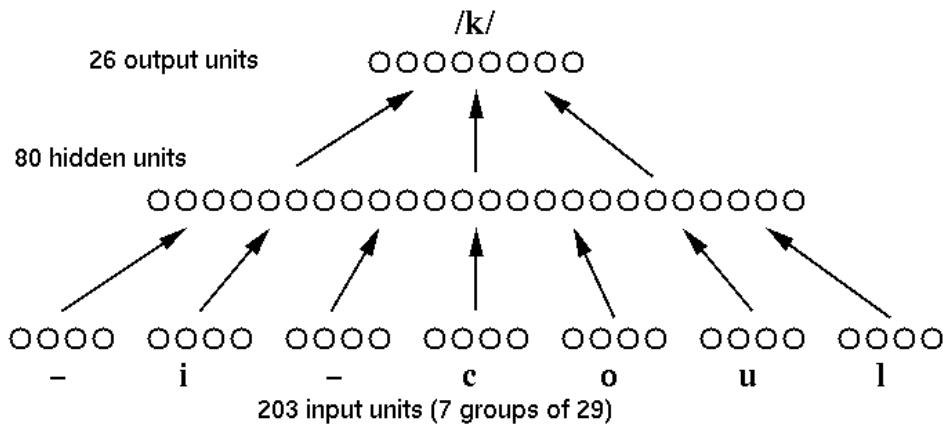
Historia de las redes neuronales artificiales

Backpropagation



NETTalk

Síntesis de voz



1986

Terrence J. Sejnowski & Charles Rosenberg:
"NETtalk: a parallel network that learns to read
aloud," Cognitive Science, 14, 179-211, 1986.



Historia de las redes neuronales artificiales

Redes convolutivas



The MNIST database of handwritten digits

<http://yann.lecun.com/exdb/mnist/>

7	9	4	5	8	:7	4	4	/	0
0	7	3	3	2	4	8	4	5	1
6	6	3	2	9	1	3	3	2	6
1	3	>	1	5	6	5	2	4	4
7	0	9	8	7	5	8	9	5	4
4	6	6	5	0	2	1	3	6	9
8	5	1	8	9	7	8	7	3	6
1	0	2	8	2	3	0	5	1	5
6	7	8	2	5	3	9	7	0	0
7	9	3	9	8	5	7	2	9	8

1990s



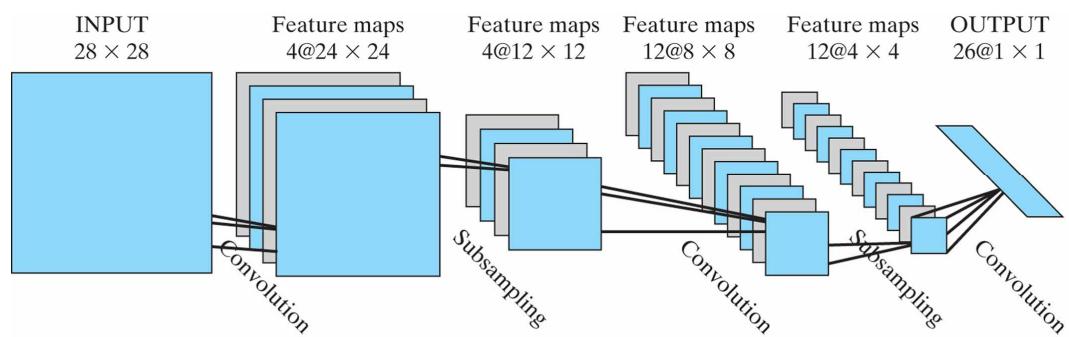
Historia de las redes neuronales artificiales

Redes convolutivas



LeNet

<http://yann.lecun.com/exdb/lenet/>



1990s



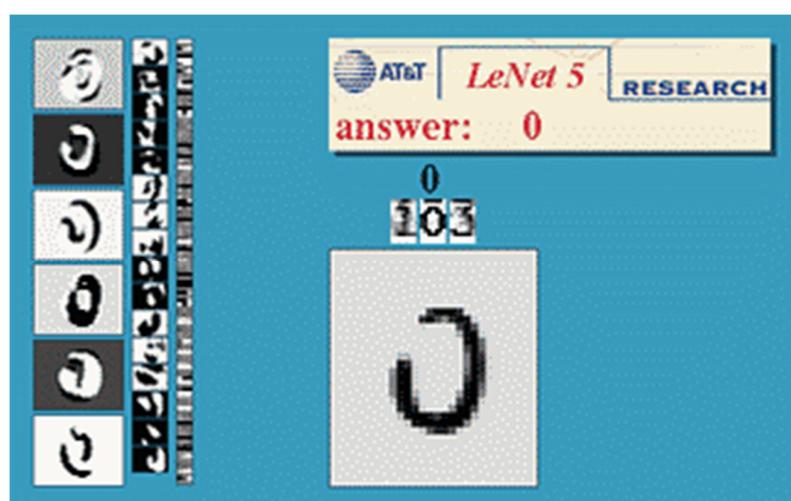
Historia de las redes neuronales artificiales

Redes convolutivas



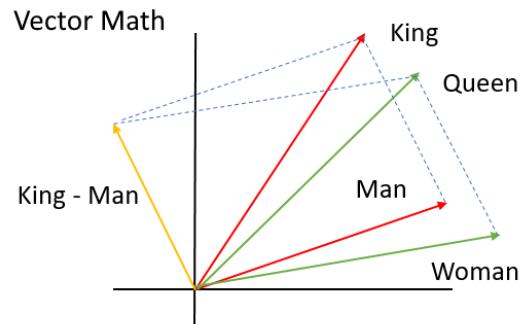
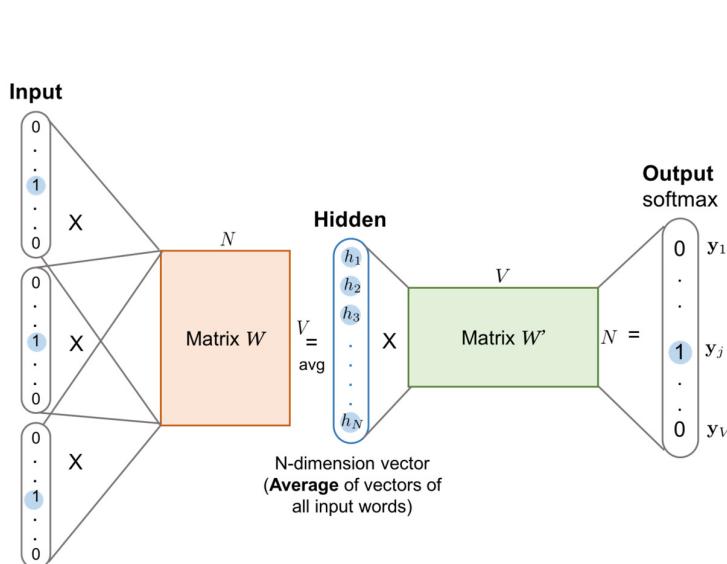
LeNet

<http://yann.lecun.com/exdb/lenet/>



Historia de las redes neuronales artificiales

Word embeddings



2000

Yoshua Bengio, Réjean Ducharme, Pascal Vincent
 "A neural probabilistic language model."
 NIPS 2000: 932-938
 JMLR 3:1137-1155, 2003

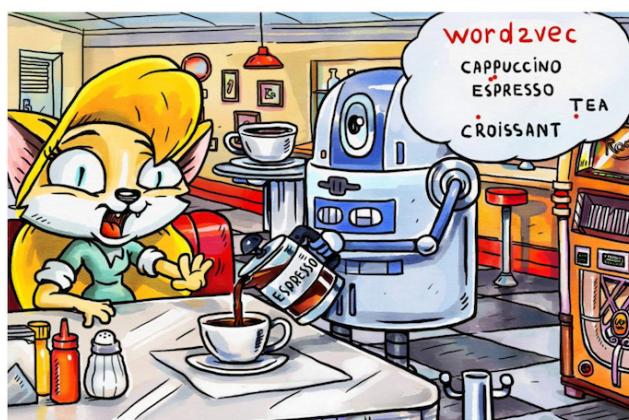
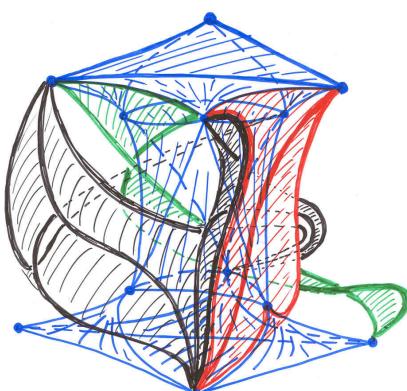


Historia de las redes neuronales artificiales

Word embeddings



word2vec



2000s

Tomas Mikolov et al.: "Efficient Estimation of Word Representations in Vector Space"
 arXiv:1301.3781, 2013

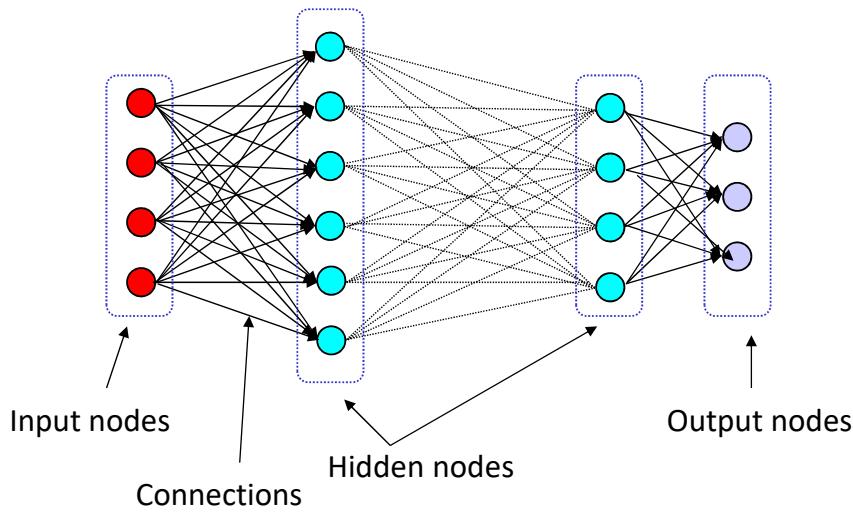


Historia de las redes neuronales artificiales

Deep Learning



Backpropagation no funcionaba bien con redes que tengan varias capas ocultas (salvo en el caso de las redes convolutivas)...



Historia de las redes neuronales artificiales

Deep Learning



Algunos hechos hicieron que backpropagation no tuviera éxito en tareas en las que luego se ha demostrado útil:

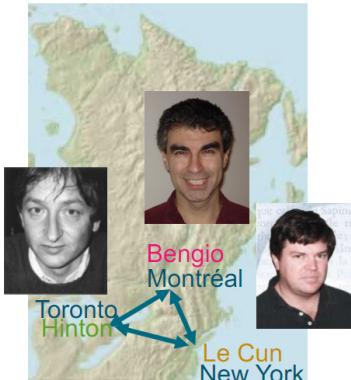
- Capacidad de cálculo limitada.
- Disponibilidad de conjuntos de datos etiquetados.
- “Deep networks” demasiado pequeñas (e inicializadas de forma poco razonable).



Historia de las redes neuronales artificiales Deep Learning



2006: The Deep Breakthrough



- Hinton, Osindero & Teh
« A Fast Learning Algorithm for Deep Belief Nets », *Neural Computation*, 2006
- Bengio, Lamblin, Popovici, Larochelle
« Greedy Layer-Wise Training of Deep Networks », *NIPS'2006*
- Ranzato, Poulnay, Chopra, LeCun
« Efficient Learning of Sparse Representations with an Energy-Based Model », *NIPS'2006*

[Yoshua Bengio]



2006

Historia de las redes neuronales artificiales Deep Learning



Geoffrey Hinton
(University of Toronto & Google)



Yann LeCun
(AT&T Labs → NYU → Facebook)



Joshua Bengio
(University of Montréal & IBM Watson)



2018



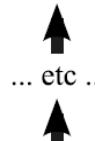
Historia de las redes neuronales artificiales Deep Learning



Motivación

very high level representation:

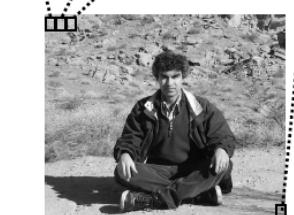
MAN SITTING ...



slightly higher level representation

raw input vector representation:

$x = [23 \ 19 \ 20] \dots [18]$



Yoshua Bengio

"Learning Deep Architectures for AI"

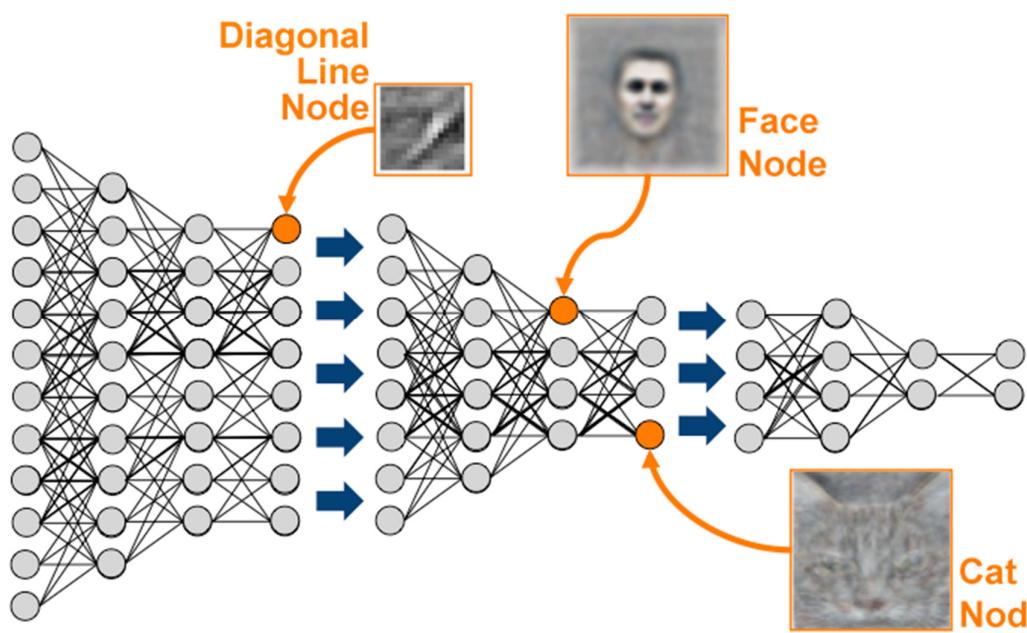
2009



Historia de las redes neuronales artificiales Deep Learning



Deep Learning as hierarchical feature representation



Historia de las redes neuronales artificiales Deep Learning



¿Cuál era el problema de backpropagation?

- Requiere datos etiquetados, pero casi todos los datos disponibles no lo están.
- No resulta demasiado escalable: Demasiado lento en redes con múltiples capas ocultas.
- Se puede quedar atascado en óptimos locales (¿lejos de ser óptimos en “deep networks”?).



Historia de las redes neuronales artificiales Deep Learning



Política & Publicaciones

Yann LeCun @ CVPR'2012



... the reviews [are] so ridiculous, that I don't know how to begin writing a rebuttal without insulting the reviewers ... This time though, the reviewers were particularly clueless, or negatively biased, or both. I was very sure that this paper was going to get good reviews because: 1) it has two simple and generally applicable ideas for segmentation... 2) it uses no hand-crafted features... 3) it beats all published results on 3 standard datasets for scene parsing; 4) it's an order of magnitude faster than the competing methods.

If that is not enough to get good reviews, I just don't know what is."



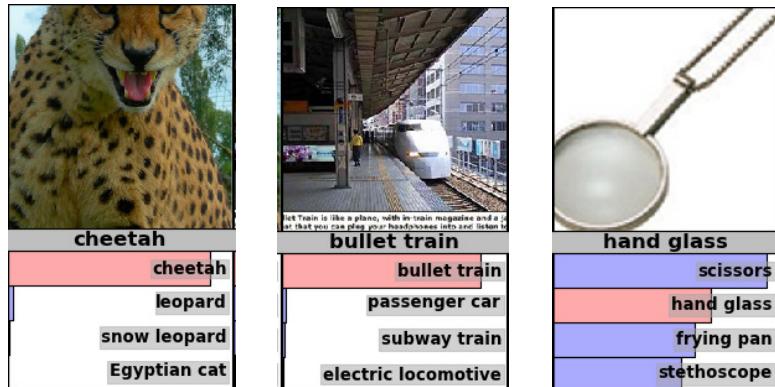
Historia de las redes neuronales artificiales Deep Learning



IMAGENET

Large Scale Visual Recognition Challenge

Reconocimiento de objetos reales en imágenes



2012



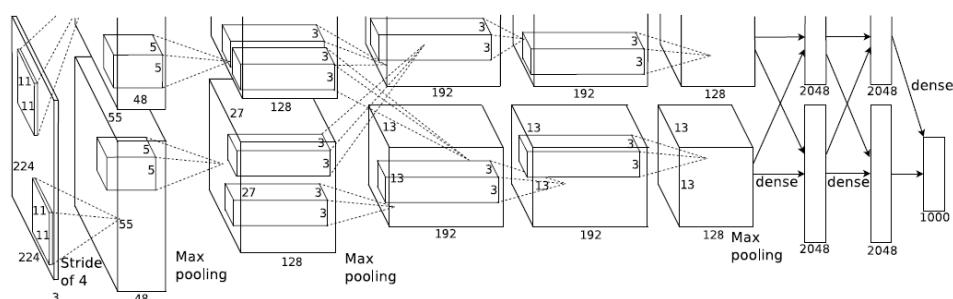
Historia de las redes neuronales artificiales Deep Learning



IMAGENET

AlexNet

Red neuronal diseñada por Alex Krizhevsky (NIPS 2012)



2012

Tasa de error

Clasificación de imágenes

16.4% vs. 25% (2010)

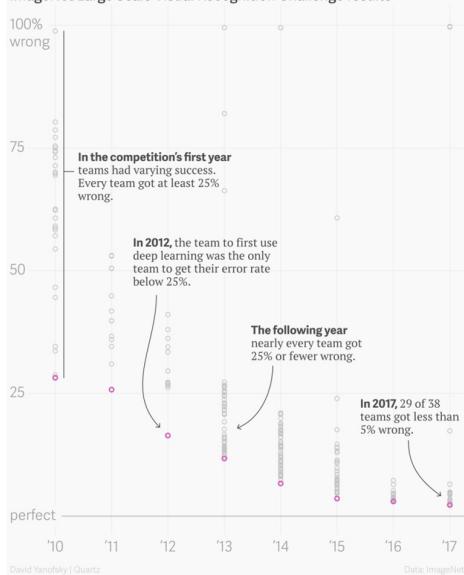


História de las redes neuronales artificiales Deep Learning



Large Scale Visual Recognition Challenge

ImageNet Large Scale Visual Recognition Challenge results



Tasa de error

16.4% Alex Krizhevsky @ NIPS 2012

6.66% GoogLeNet @ ILSVRC'2014

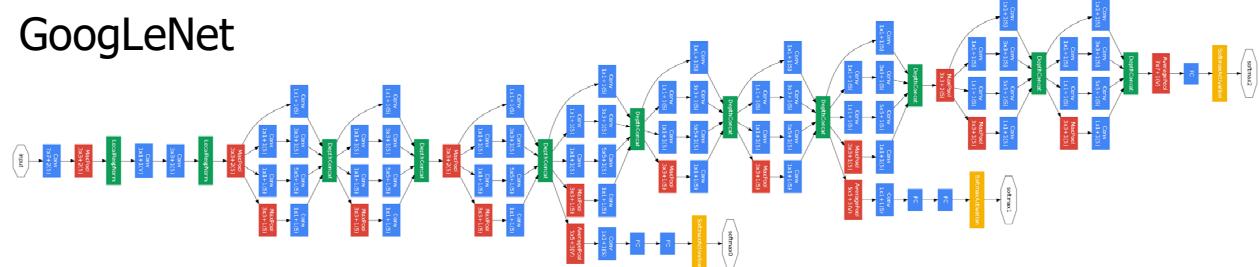
4.94% PreLU-nets (MSR) @ 2015

"Delving Deep into Rectifiers:
Surpassing Human-Level Performance
on ImageNet Classification"
arXiv, 2015, <http://arxiv.org/pdf/1502.01852v1.pdf>

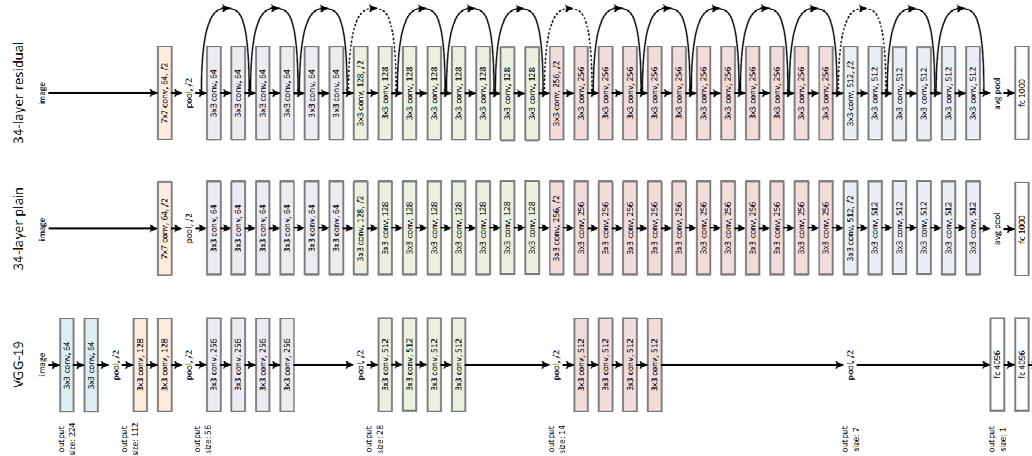


História de las redes neuronales artificiales Deep Learning

GoogLeNet



ResNets

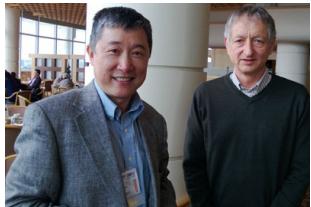


Historia de las redes neuronales artificiales Deep Learning



Reconocimiento de voz

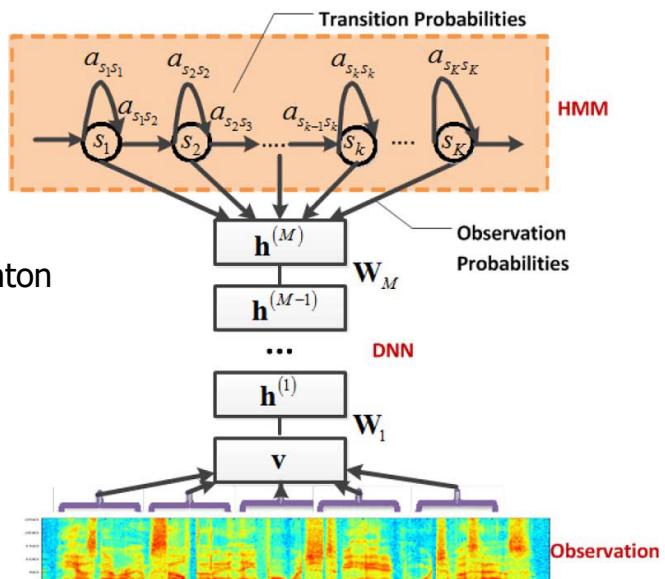
Microsoft®
Research



Li Deng (MSR) & Geoff Hinton



Dong Yu (MSR)



Historia de las redes neuronales artificiales Deep Learning



Reconocimiento de voz

Task	Hours of training data	Deep Neural Network	Gaussian Mixture Model	GMM with more data
Switchboard (Microsoft Research)	309	18.5%	27.4%	18.6% (2000 hrs)
English broadcast news (IBM)	50	17.5%	18.8%	
Google Voice Search (Android 4.1)	5,870	12.3% (and falling)		16.0% (>>5,870 hrs)

Microsoft®
Research

IBM

Google

2012

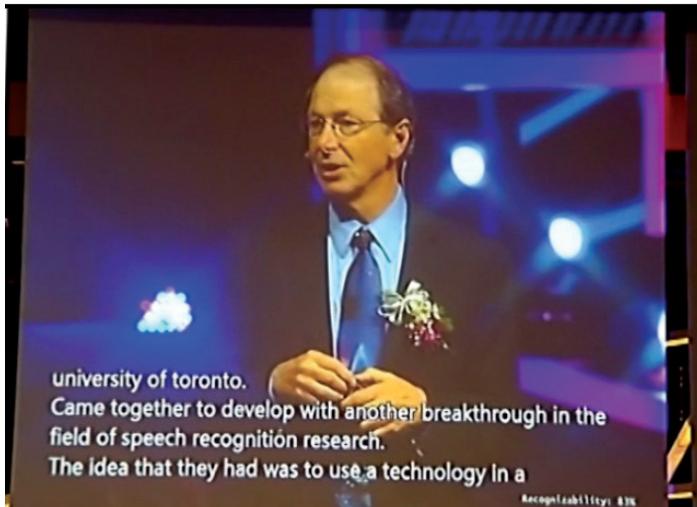
Geoffrey Hinton, Li Deng, Dong Yu et al.:
“Deep Neural Networks
for Acoustic Modeling in Speech Recognition”
IEEE Signal Processing Magazine, 2012



Historia de las redes neuronales artificiales Deep Learning



Traducción simultánea



2012

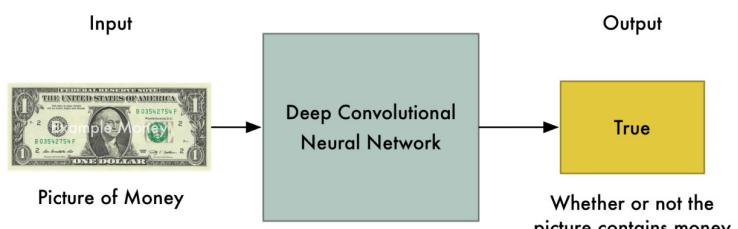


Historia de las redes neuronales artificiales Deep Learning

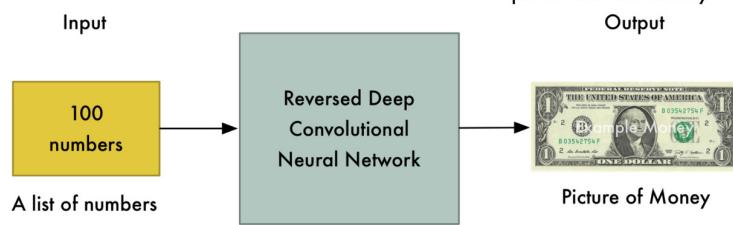


GANs [Generative Adversarial Networks]

Discriminador



Generador



2014



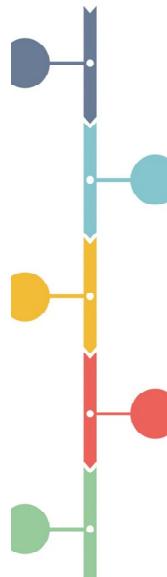
Historia



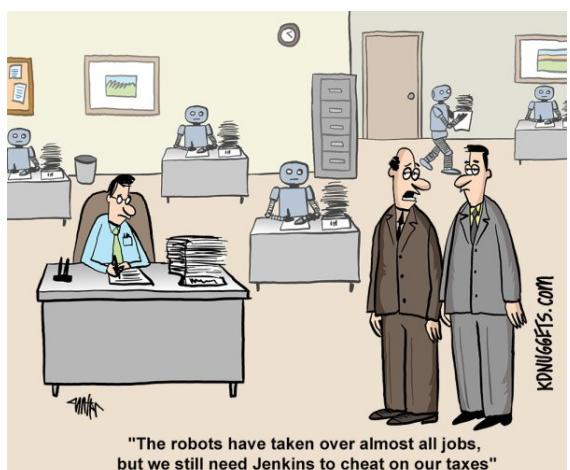
- 1956: Psychologist Frank Rosenblatt uses theories about how brain cells work to design the perceptron, an artificial neural network that can be trained to categorize simple shapes.
- 1969: AI pioneers Marvin Minsky and Seymour Papert write a book critical of perceptrons that quashes interest in neural networks for decades.
- 1986: Yann LeCun and Geoff Hinton perfect backpropagation to train neural networks that pass data through successive layers of artificial neurons, allowing them to learn more complex skills.
- 1987: Terry Sejnowski at Johns Hopkins University creates a system called NETtalk that can be trained to pronounce text, going from random babbling to recognizable speech.
- 1990: At Bell Labs, LeCun uses backpropagation to train a network that can read handwritten text. AT&T later uses it in machines that can read checks.
- 1995: Bell Labs mathematician Vladimir Vapnik publishes an alternative method for training software to categorize data such as images. This sidelines neural networks again.
- 2006: Hinton's research group at the University of Toronto develops ways to train much larger networks with tens of layers of artificial neurons.
- June 2012: Google uses deep learning to cut the error rate of its speech recognition software by 25 percent.
- October 2012: Hinton and two colleagues from the University of Toronto win the largest challenge for software that recognizes objects in photos, almost halving the previous error rate.
- March 2013: Google buys DNN Research, the company founded by the Toronto team to develop their ideas. Hinton starts working at Google.
- March 2014: Facebook starts using deep learning to power its facial recognition feature, which identifies people in uploaded photos.
- May 2015: Google Photos launches. The service uses deep learning to group photos of the same people and let you search your snapshots using terms like "beach" or "dog."

MIT Technology Review

MIT Technology Review: "Teaching Machines to Understand Us", August 2015



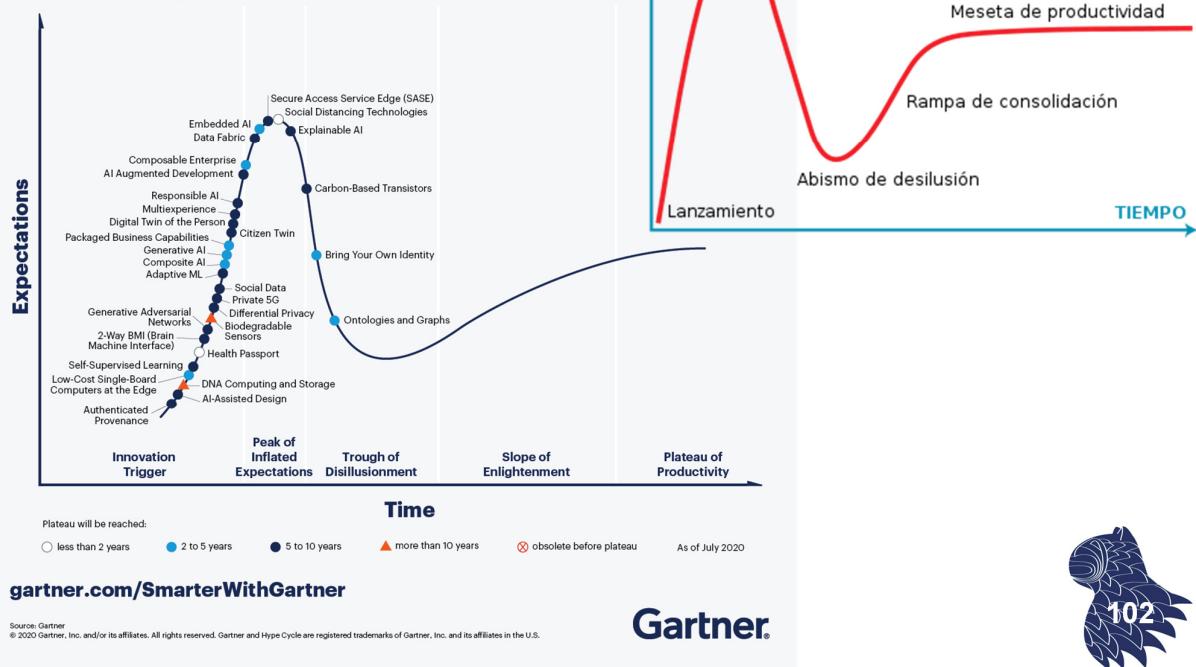
Deep Learning



Deep Learning



Hype Cycle for Emerging Technologies, 2020



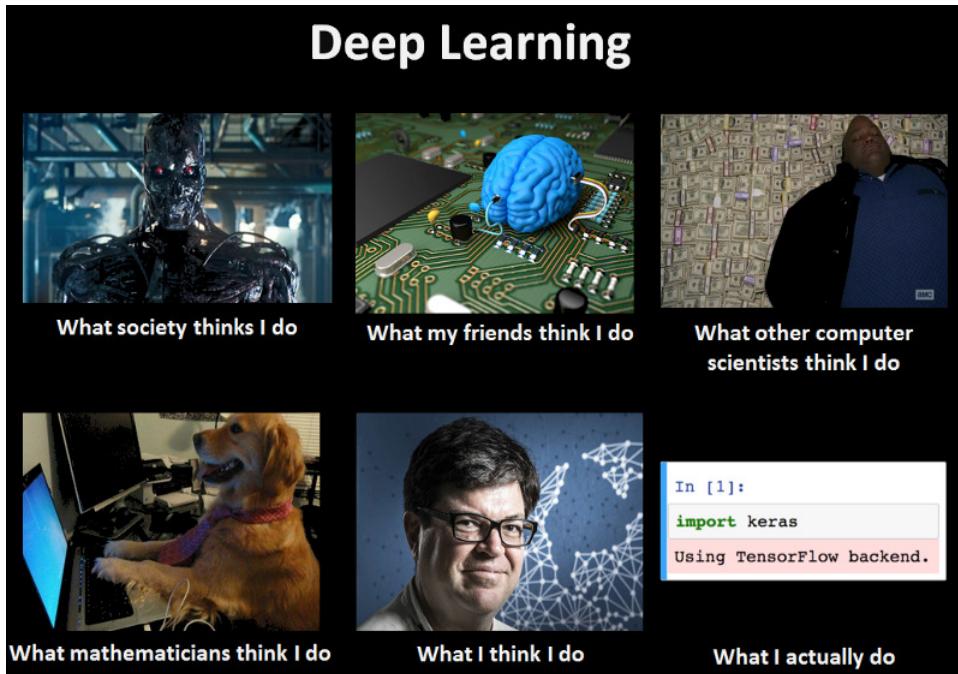
Deep Learning



Hype Cycle for Artificial Intelligence, 2020



En la práctica...



DECSAI
Departamento de Ciencias de la Computación e I.A.

Universidad de Granada



RN&DL – Información adicional
Fernando Berzal, berzal@acm.org

Demos

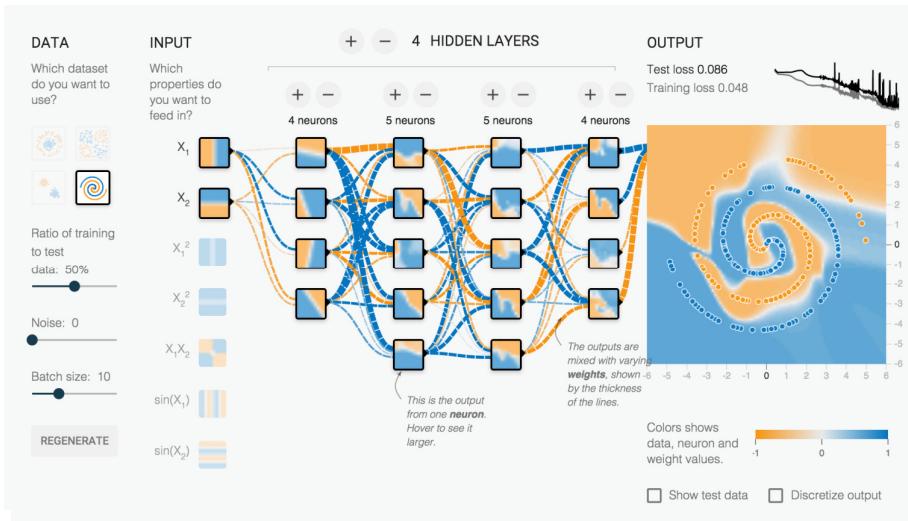
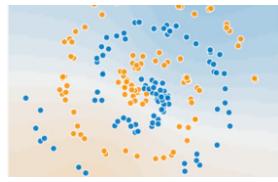


Para jugar un poco...

<http://playground.tensorflow.org/>

<http://ml4a.github.io/demos/>

<http://demos.algorithmia.com/classify-places/>



Cursos

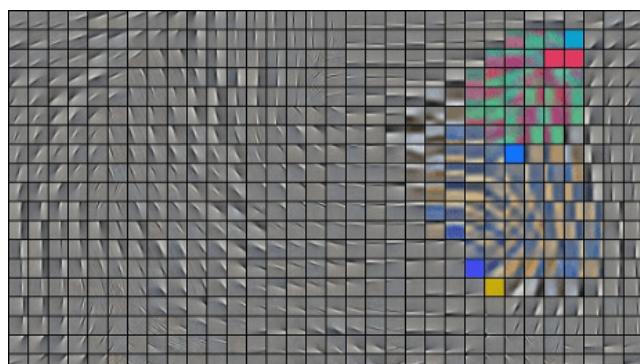


Neural Networks for Machine Learning

by Geoffrey Hinton

(University of Toronto & Google)

<https://www.coursera.org/course/neuralnets>



Cursos



Deep Learning Specialization

by Andrew Ng, 2017

- Neural Networks and Deep Learning
- Improving Deep Neural Networks: Hyperparameter tuning, Regularization and Optimization
- Structuring Machine Learning Projects
- Convolutional Neural Networks
- Sequence Models



deeplearning.ai



<https://www.coursera.org/specializations/deep-learning>

Cursos & Tutoriales



■ Deep Learning Tutorial

Andrew Ng et al. (Stanford University)

<http://ufldl.stanford.edu/tutorial/>

■ Deep Learning: Methods and Applications

Li Deng & Dong Yu (Microsoft Research)

<http://research.microsoft.com/apps/pubs/default.aspx?id=209355>

■ Deep Learning for Natural Language Processing

Richard Socher et al. (Stanford University CS224d)

<http://cs224d.stanford.edu/>

■ Convolutional Neural Networks for Visual Recognition

Andrej Karpathy (Stanford University CS231n)

<http://cs231n.github.io/>

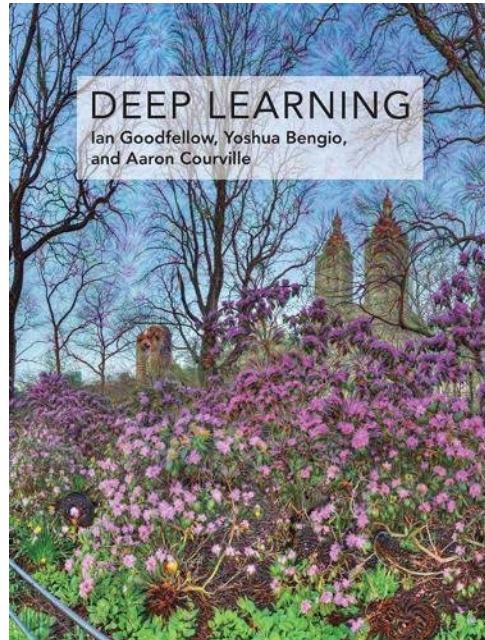


Bibliografía



Lecturas recomendadas

Ian Goodfellow,
Yoshua Bengio
& Aaron Courville:
Deep Learning
MIT Press, 2016
ISBN 0262035618



<http://www.deeplearningbook.org>

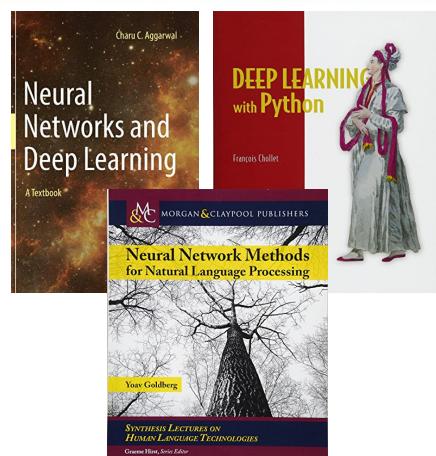


Bibliografía



Lecturas complementarias

- Charu C. Aggarwal:
Neural Networks and Deep Learning: A Textbook. Springer, 2018
ISBN 3319944622
<http://link.springer.com/978-3-319-94463-0>
- François Chollet:
Deep Learning with Python
Manning Publications, 2018
ISBN 1617294438
<https://www.manning.com/books/deep-learning-with-python>
- Yoav Goldberg:
Neural Network Methods in Natural Language Processing
Morgan & Claypool Publishers,, 2017
ISBN 1627052984
<https://doi.org/10.2200/S00762ED1V01Y201703HLT037>

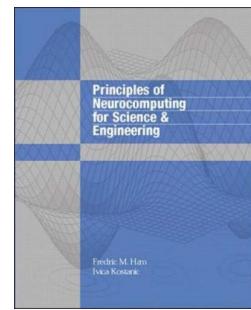
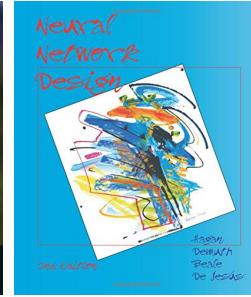
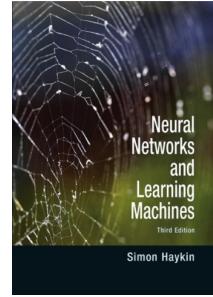


Bibliografía



Lecturas complementarias

- Simon Haykin:
Neural Networks and Learning Machines
Prentice Hall, 3rd edition, 2008
ISBN 0131471392
- Martin T. Hagan, Howard B. Demuth, Mark H. Beale & Orlando de Jesús:
Neural Network Design
Martin Hagan, 2nd edition, 2014
ISBN 0971732116
<http://hagan.okstate.edu/NNDesign.pdf>
- Fredric M. Ham & Ivica Kostanic:
Principles of Neurocomputing for Science and Engineering
McGraw-Hill Higher Education, 2000
ISBN 0070259666

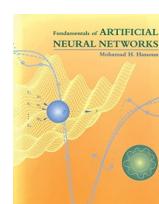
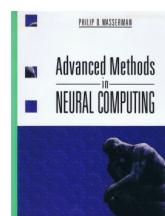
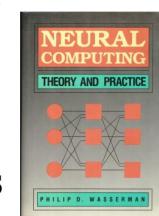
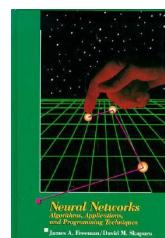
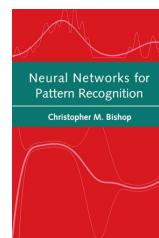


Bibliografía complementaria



Redes neuronales artificiales

- Christopher M. Bishop:
Neural Networks for Pattern Recognition
Oxford University Press, 1995. ISBN 0198538642
- James A. Freeman & David M. Skapura:
Neural Networks: Algorithms, Applications, and Programming Techniques
Addison-Wesley, 1991. ISBN 0201513765
- Mohamad Hassoun:
Fundamentals of Artificial Neural Networks
MIT Press, 2003. ISBN 0262514672
- Philip D. Wasserman:
Neural Computing: Theory and Practice,
Van Nostrand Reinhold, 1989. ISBN 0442207433
Advanced Methods in Neural Computing
Van Nostrand Reinhold, 1993. ISBN 0442004613

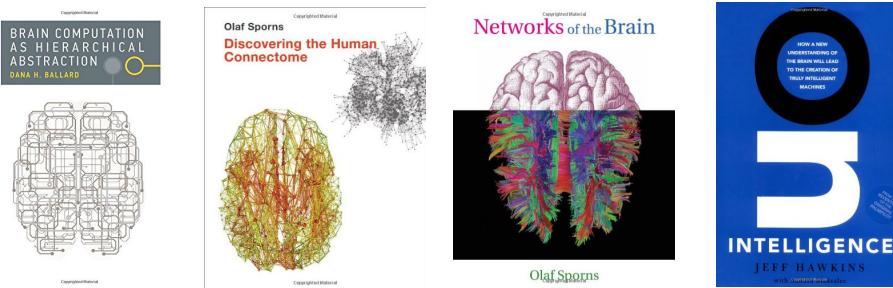


Bibliografía complementaria



“wetware”

- Dana H. Ballard: **Brain Computation as Hierarchical Abstraction.** MIT Press, 2015. ISBN 0262028611
- Olaf Sporns: **Discovering the Human Connectome.** MIT Press, 2012. ISBN 0262017903
- Olaf Sporns: **Networks of the Brain.** MIT Press, 2010. ISBN 0262014696
- Jeff Hawkins: **On Intelligence.** Times Books, 2004. ISBN 0805074562



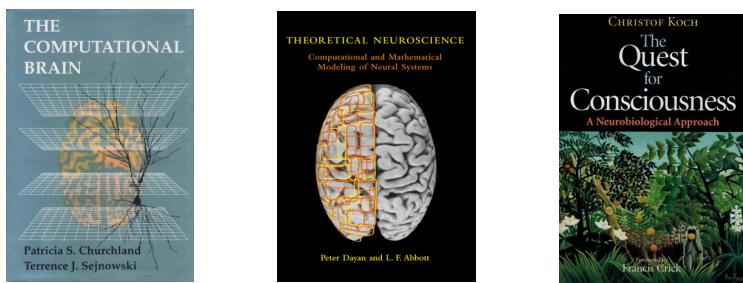
114

Bibliografía complementaria



Computational Neuroscience

- Patricia S. Churchland & Terrence J. Sejnowski: **The Computational Brain.** MIT Press, 1992. ISBN 0262031884
- Peter Dayan & L.F. Abbott: **Theoretical Neuroscience: Computational and Mathematical Modeling of Neural Systems.** MIT Press, 2001. ISBN 0262041995.
- Christof Koch: **The Quest for Consciousness: A Neurobiological Approach.** Roberts & Company Publishers, 2004. ISBN 0974707708



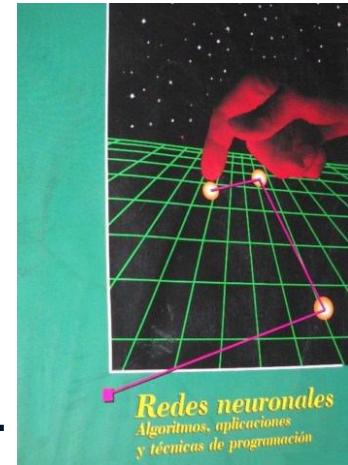
115

Bibliografía



Bibliografía en castellano

- James A. Freeman & David M. Skapura:
Redes Neuronales: Algoritmos, aplicaciones y técnicas de programación
Addison-Wesley / Díaz de Santos, 1993.
ISBN 020160115X



... con ejemplos de código en Pascal

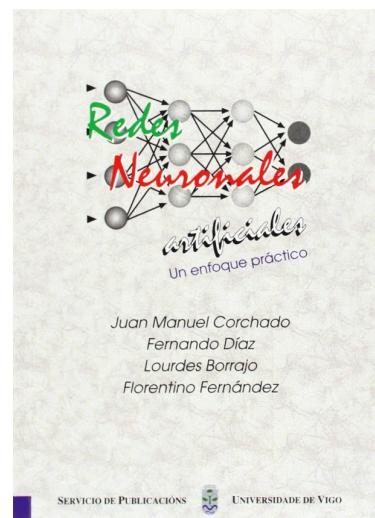


Bibliografía



Bibliografía en castellano

- Juan Manuel Corchado, Fernando Díaz, Lourdes Borrajo & Florentino Fernández:
Redes Neuronales: Un enfoque práctico
Universidad de Vigo, 2000.
ISBN 8481581453



... con un disco de 3½"



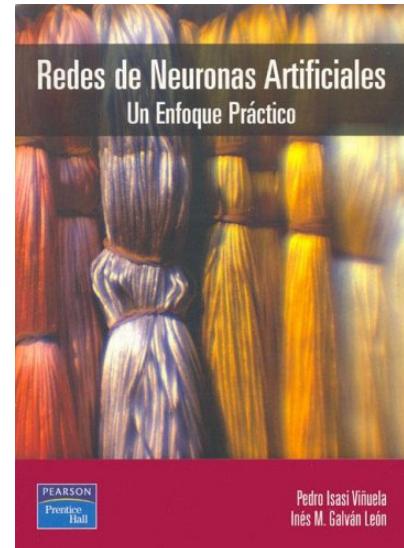
Bibliografía



Bibliografía en castellano

- Pedro Isasi Viñuela & Inés M. Galván León
Las redes neuronales artificiales: Un enfoque práctico
Prentice Hall, 2004
ISBN 8420540250

Descatalogado :-(



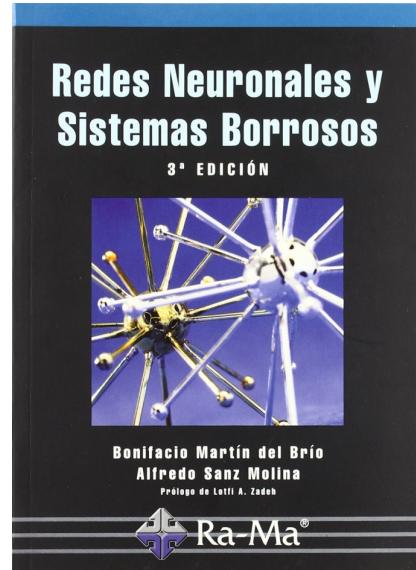
Bibliografía



Bibliografía en castellano

- Bonifacio Martín del Brío & Alfredo Sanz Molina:
Redes Neuronales y Sistemas Borrosos.
Ra-Ma, 3^a Edición, 2006
ISBN 8478977430

Alfaomega Grupo Editor
México D.F.



Bibliografía



Bibliografía en castellano

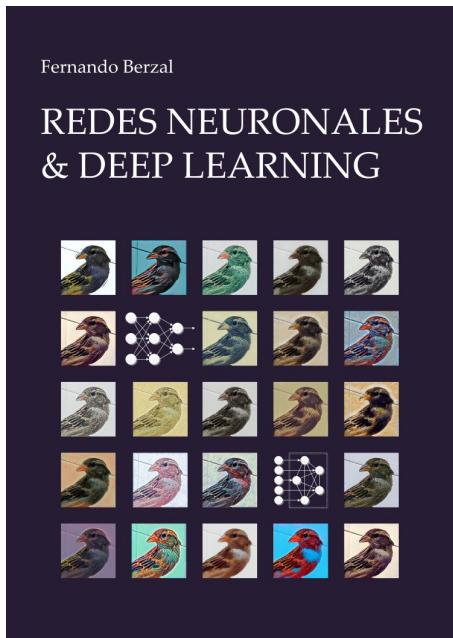
Fernando Berzal:
Redes Neuronales & Deep Learning

Edición independiente, 2018

ISBN 1-7312-6538-7 (b&n)

ISBN 1-7313-1433-7 (color)

<https://deep-learning.ikor.org>



Bibliografía



Bibliografía en castellano

Fernando Berzal:
Redes Neuronales & Deep Learning

Edición en dos volúmenes, 2019

Volumen I: Entrenamiento de redes neuronales artificiales
ISBN 1-0903-2030-2

Volumen II: Regularización, optimización y arquitecturas especializadas
ISBN 1-0903-3688-8

<https://deep-learning.ikor.org>

