DECSAI
Departamento de Ciencias de la Computación e I.A.
Universidad de Granada

Modelos estocásticos

Fernando Berzal, berzal@acm.org

Modelos estocásticos

- Neuronas estocásticas
- Redes de Hopfield
- Máquinas de Boltzmann
- Deep Belief Networks (DBNs)

Deep Learning

Motivación

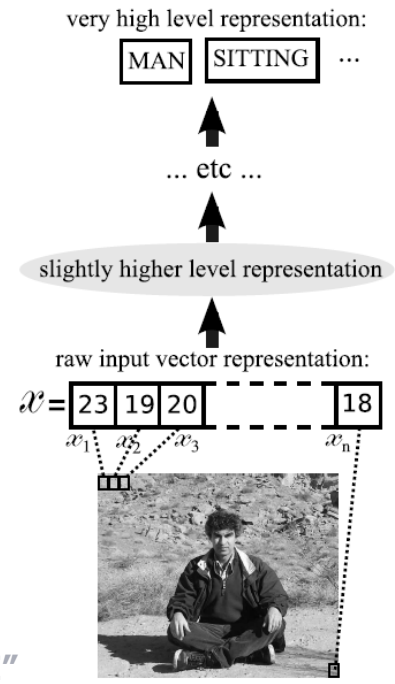

Yoshua Bengio
"Learning Deep Architectures for AI"
2009

Deep Learning

Deep Learning as hierarchical feature representation

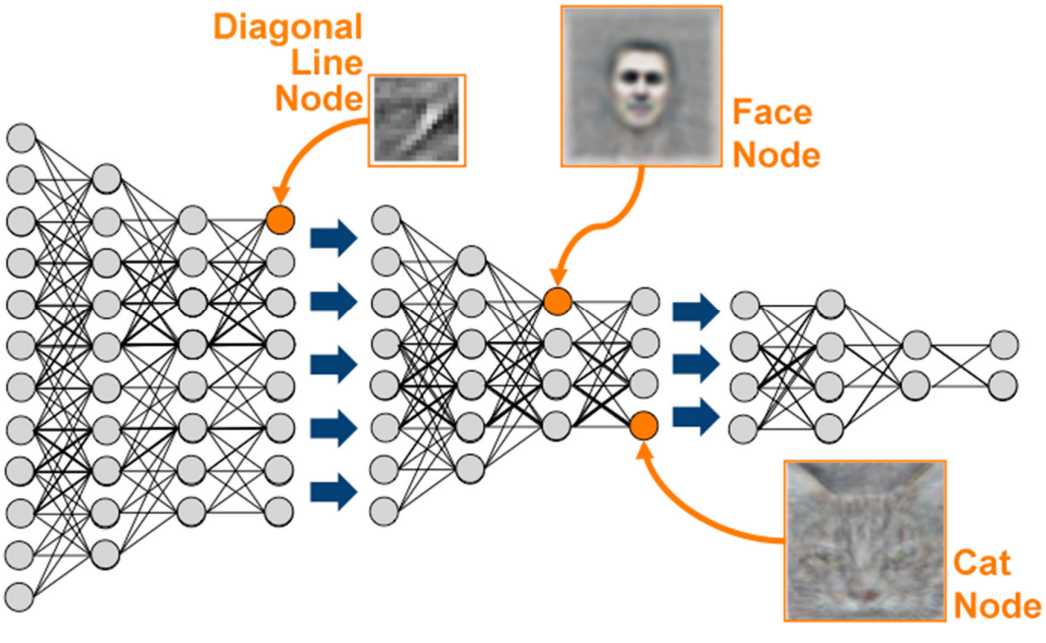

Deep Learning

Backpropagation no funcionaba bien
con redes que tengan varias capas ocultas
(salvo en el caso de las redes convolutivas)…

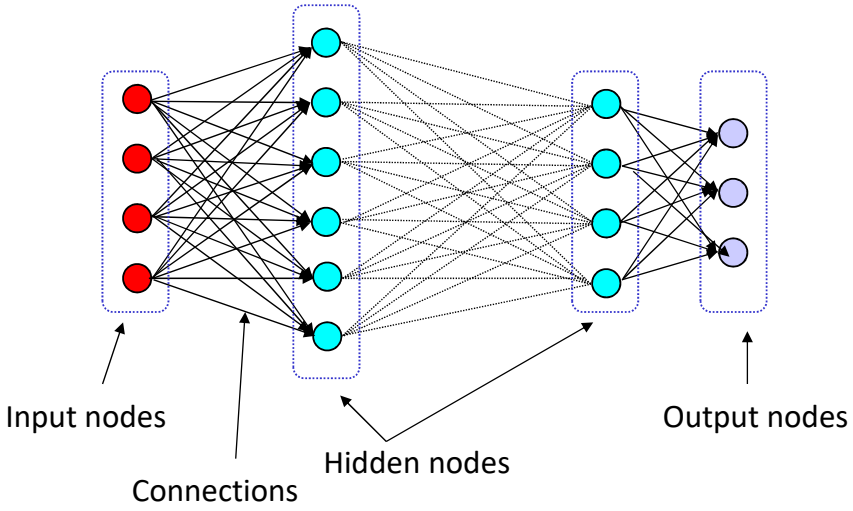

Deep Learning

Algunos hechos hicieron que backpropagation no tuviera
éxito en tareas en las que luego se ha demostrado útil:

- Capacidad de cálculo limitada.
- Disponibilidad de conjuntos de datos etiquetados.
- "Deep networks" demasiado pequeñas
  (e inicializadas de forma poco razonable).

Deep Learning

2006: The Deep Breakthrough

- Hinton, Osindero & Teh « A Fast Learning Algorithm for Deep Belief Nets », *Neural Computation*, 2006
- Bengio, Lamblin, Popovici, Larochelle « Greedy Layer-Wise Training of Deep Networks », *NIPS'2006*
- Ranzato, Poultney, Chopra, LeCun « Efficient Learning of Sparse Representations with an Energy-Based Model », *NIPS'2006*

[Yoshua Bengio]

Deep Learning

Estadística	Inteligencia Artificial
Dimensionalidad baja (<100)	Dimensionalidad alta (>>100)
Mucho ruido en los datos	El ruido no es el mayor problema
Sin demasiada estructura en los datos (puede capturarse usando modelos simples)	Mucha estructura en los datos (demasiado complicada para modelos simples)
PRINCIPAL PROBLEMA	PRINCIPAL PROBLEMA
Separar estructura de ruido	Descubrir una forma de representar la estructura que se pueda aprender
TÉCNICAS	TÉCNICAS
SVM [Support Vector Machines]	Backpropagation

Deep Learning

¿Por qué las SVMs nunca fueron una buena opción en IA?

Sólo son una reencarnación de los perceptrones…

- Expanden la entrada a una capa (enorme) de características **no adaptativas**.
- Sólo tienen una capa de pesos **adaptativos**.
- Disponen de un algoritmo eficiente para ajustar los pesos controlando el sobreaprendizaje (una forma inteligente de seleccionar características y encontrar los pesos adecuados).

Deep Learning

Documento histórico

AT&T Adaptive Systems Research Dept., Bell Labs

1. Jackel bets (one fancy dinner) that by March 14, 2000 people will understand
quantitatively why big neural nets working on large databases are not so bad. (Understanding means that there will be clear conditions and bounds)

Vapnik bets (one fancy dinner) that Jackel is wrong.

But .. If Vapnik figures out the bounds and conditions, Vapnik still wins the bet.

****

2. Vapnik bets (one fancy dinner) that by March 14, 2005, no one in his right mind will use neural nets that are essentially like those used in 1995.

Jackel bets (one fancy dinner) that Vapnik is wrong

Deep Learning

¿Cuál era el problema de backpropagation?

- Requiere datos etiquetados,
  pero casi todos los datos disponibles no lo están.
- No resulta demasiado escalable:
  Demasiado lento en redes con múltiples capas ocultas.
- Se puede quedar atascado en óptimos locales
  (¿lejos de ser óptimos en "deep networks"?).

Deep Learning

Una posibilidad

Mantener la eficiencia y la simplicidad de usar el gradiente para ajustar los pesos, pero usándolo para modelar la estructura de la entrada:

Ajustar los pesos para maximizar la probabilidad de que un modelo (generativo) genere los datos de entrada.

Maximizar p(x), no p(y|x)

Deep Learning

AI & Probabilidad

"Many ancient Greeks supported Socrates opinion that deep, inexplicable thoughts came from the gods. Today's equivalent to those gods is the erratic, even probabilistic neuron. It is more likely that increased randomness of neural behavior is the problem of the epileptic and the drunk, not the advantage of the brilliant."

P.H. Winston, "Artificial Intelligence"
(The first AI textbook, 1977)

Deep Learning

AI & Probabilidad

"All of this will lead to theories of computation which are much less rigidly of an all-or-none nature than past and present formal logic ... There are numerous indications to make us believe that this new system of formal logic will move closer to another discipline which has been little linked in the past with logic. This is thermodynamics primarily in the form it was received from Boltzmann."

John von Neumann, "The Computer and the Brain"
(unfinished manuscript, 1958)

Neuronas estocásticas

Modelos de neuronas: Neuronas binarias estocásticas

$$z = \sum_i x_i w_i$$

$$p = \frac{1}{1+e^{-z}}$$

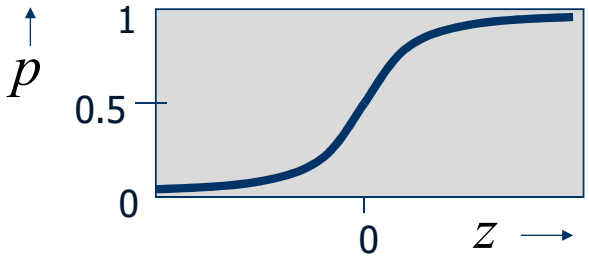

Las mismas ecuaciones que las neuronas sigmoidales, si bien su salida se interpreta como una probabilidad (de producir un spike en una pequeña ventana de tiempo)

Redes de Hopfield

Redes de Hopfield

1982 Redes recurrentes
que funcionan como memorias asociativas

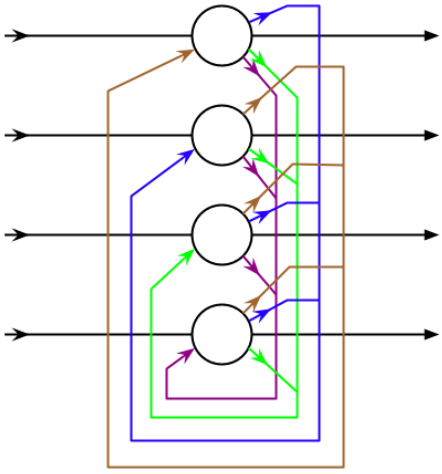

John J. Hopfield:
"Neural networks and physical systems with emergent collective computational abilities"
Proceedings of the National Academy of Sciences
PNAS 79(8):2554–2558, 1982

Redes de Hopfield

- Las redes recurrentes incluyen ciclos (como las redes neuronales biológicas).
- Las redes recurrentes tienen la capacidad de recordar.
- Son útiles para modelar secuencias (equivalen a redes multicapa con una capa por unidad de tiempo, capas que comparten los mismos pesos).

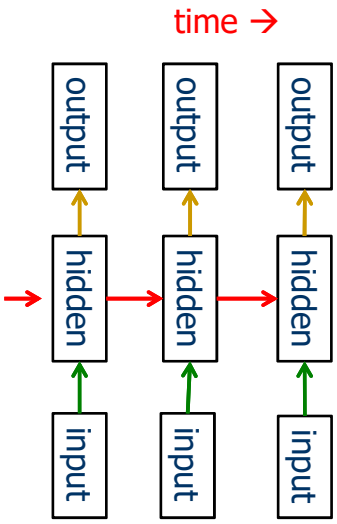

Redes de Hopfield

Sin embargo, el comportamiento dinámico de las redes recurrentes las hace difíciles de entrenar, ya que pueden

- llegar a un estado estable,
- oscilar entre varios estados,
- o comportarse de forma caótica (seguir trayectorias que no pueden predecirse a largo plazo).

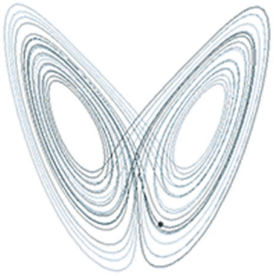

Redes de Hopfield

John Hopfield se dio cuenta de que las redes recurrentes con conexiones simétricas son más fáciles de analizar (y entrenar).

- Existe una función de energía global asociada a la red (cada configuración de la red tiene un nivel de energía).
- El comportamiento de las neuronas binarias estocásticas hace que la red tienda a alcanzar un mínimo de esa función de energía.
- Al obedecer a una función de energía, hay cosas que no pueden hacer (p.ej. modelar ciclos).

Redes de Hopfield

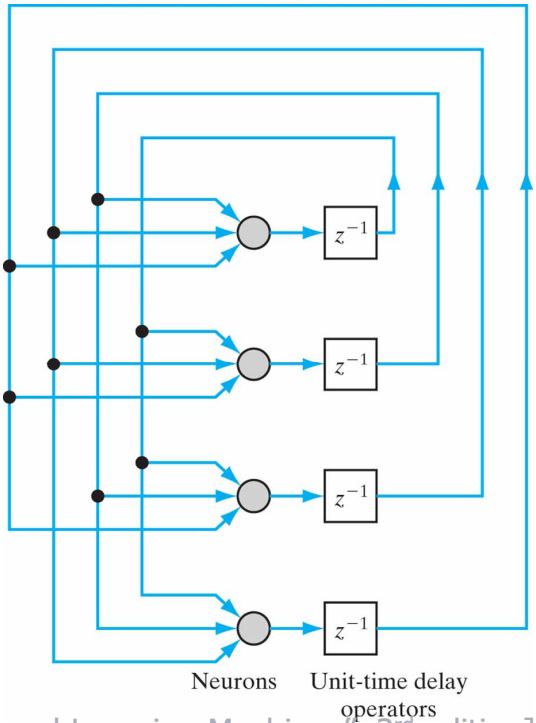

Red de Hopfield

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Redes de Hopfield

Función de energía

Definida como la suma de muchas contribuciones, cada una asociada al peso de una conexión y al estado de las dos neuronas conectadas:

$$E = -\sum_i s_i b_i - \sum_{i<j} s_i s_j w_{ij}$$

Esta función cuadrática de energía permite que cada neurona calcule localmente cómo afecta su estado a la energía global:

$$Energy\ gap = \Delta E_i = E(s_i = 0) - E(s_i = 1) = b_i + \sum_j s_j w_{ij}$$

Redes de Hopfield

Función de energía

Para encontrar una configuración de mínima energía:

- Inicialmente, la red parte de un estado aleatorio.
- Se actualiza el estado de cada neurona, **una a una**, en un orden aleatorio (usando neuronas binarias estocásticas, se establece el estado que lleve a la red a una configuración de mejor energía).

  NOTA: Si las actualizaciones fuesen simultáneas, la energía de la red podría aumentar (no paralelizable).

Redes de Hopfield

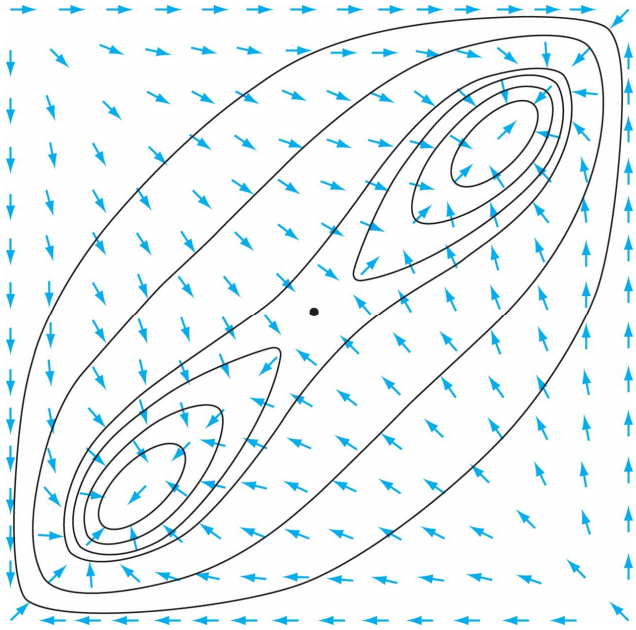

Mapa de energía

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Redes de Hopfield

Memorias asociativas

- Hopfield propuso que la memoria podría corresponder a los mínimos de energía de una red.
- La regla de actualización de las neuronas binarias estocásticas puede servir para "limpiar" una memoria incompleta o corrupta.
- El uso de mínimos de energía proporciona memorias direccionables por su contenido en las que un elemento puede recuperarse a partir de parte de su contenido (a.k.a. memorias asociativas).

Redes de Hopfield

Memorias asociativas

Si usamos +1 y -1 como actividades de las neuronas binarias estocásticas, podemos almacenar un vector de estado binario incrementando el peso de la conexión entre dos unidades por el producto de sus actividades:

$$\Delta w_{ij} = s_i s_j$$

Si usamos 0 y 1, la regla es algo más complicada:

$$\Delta w_{ij} = 4\,(s_i - 1/2)(s_j - 1/2)$$

Redes de Hopfield

TABLE 13.2 Summary of the Hopfield Model

1. *Learning.* Let $\xi_1, \xi_2, \ldots, \xi_\mu$ denote a known set of N-dimensional fundamental memories. Use the outer-product rule (i.e., Hebb's postulate of learning) to compute the synaptic weights of the network as

$$w_{ji} = \begin{cases} \dfrac{1}{N}\displaystyle\sum_{\mu=1}^{M} \xi_{\mu,j}\,\xi_{\mu,i}, & j \neq i \\ 0, & j = i \end{cases}$$

where w_{ji} is the synaptic weight from neuron i to neuron j. The elements of the vector ξ_μ equal ± 1. Once they are computed, the synaptic weights are kept fixed.

2. *Initialization.* Let ξ_{probe} denote an unknown N-dimensional input vector (probe) presented to the network. The algorithm is initialized by setting

$$x_j(0) = \xi_{j,\,\text{probe}}, \qquad j = 1, \ldots, N$$

where $x_j(0)$ is the state of neuron j at time $n = 0$ and $\xi_{j,\text{probe}}$ is the jth element of the probe ξ_{probe}.

3. *Iteration Until Convergence.* Update the elements of state vector $\mathbf{x}(n)$ asynchronously (i.e., randomly and one at a time) according to the rule

$$x_j(n+1) = \text{sgn}\left(\sum_{i=1}^{N} w_{ji}\,x_i(n)\right), \qquad j = 1, 2, \ldots, N$$

Repeat the iteration until the state vector $\mathbf{x}$ remains unchanged.

4. *Outputting.* Let $\mathbf{x}_{\text{fixed}}$ denote the fixed point (stable state) computed at the end of step 3. The resulting output vector $\mathbf{y}$ of the network is

$$\mathbf{y} = \mathbf{x}_{\text{fixed}}$$

Step 1 is the storage phase, and steps 2 through 4 constitute the retrieval phase.

Aprendizaje

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Redes de Hopfield

Memorias asociativas

- La capacidad de almacenamiento de una red de Hopfield completamente conectada con N unidades es sólo de M=0.15N "recuerdos": $0.15N^2$ bits de memoria requieren N^2 log (2M+1) bits para los pesos.

- Cada vez que memorizamos una configuración, pretendemos crear un mínimo de energía, pero dos mínimos cercanos pueden interferir, lo que limita la capacidad de la red de Hopfield.

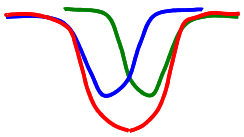

Máquinas de Boltzmann

Máquinas de Boltzmann

1985 Máquinas de Boltzmann
(redes de Hopfield con neuronas ocultas)

David H. Ackley, Geoffrey E. Hinton & Terrence J. Sejnowski:
"A Learning Algorithm for Boltzmann Machines"
Cognitive Science 9(1):147–169, 1985.
DOI 10.1207/s15516709cog0901_7

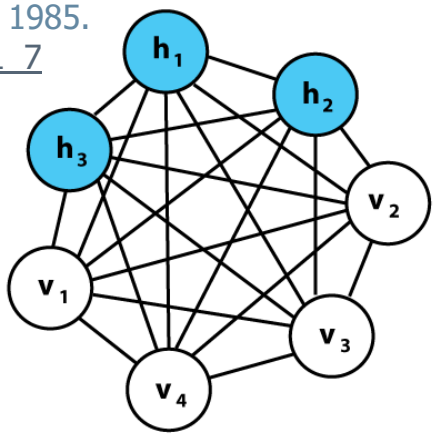

Máquinas de Boltzmann

Las máquinas de Boltzmann son redes de Hopfield con neuronas ocultas:

- Más "potentes" que las redes de Hopfield.
- Menos "potentes" que las redes recurrentes.

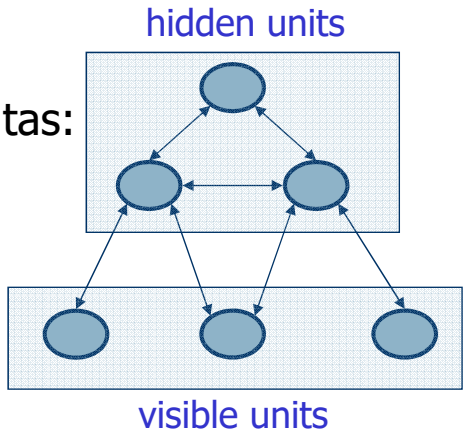

En vez de utilizar las redes para almacenar recuerdos, las utilizamos para construir interpretaciones de las entradas.

Tienen un algoritmo de aprendizaje sencillo y elegante...

Máquinas de Boltzmann

EJEMPLO [Hinton]

Aristas 3D a partir de imágenes 2D

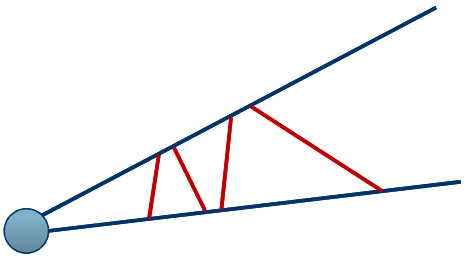

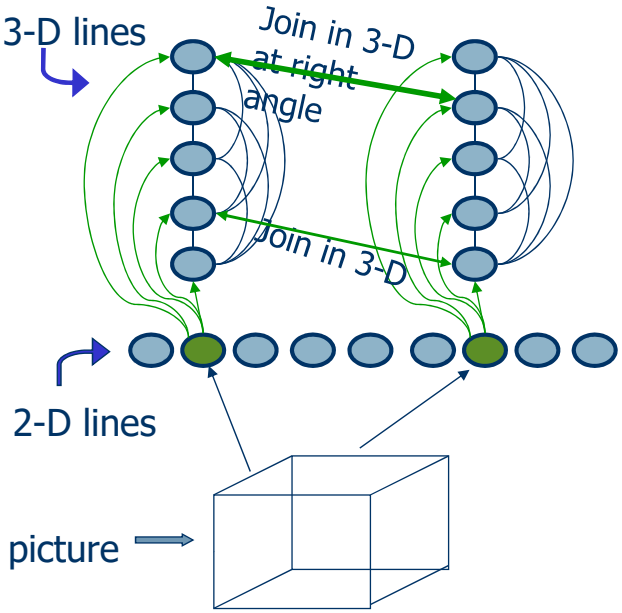

Máquinas de Boltzmann

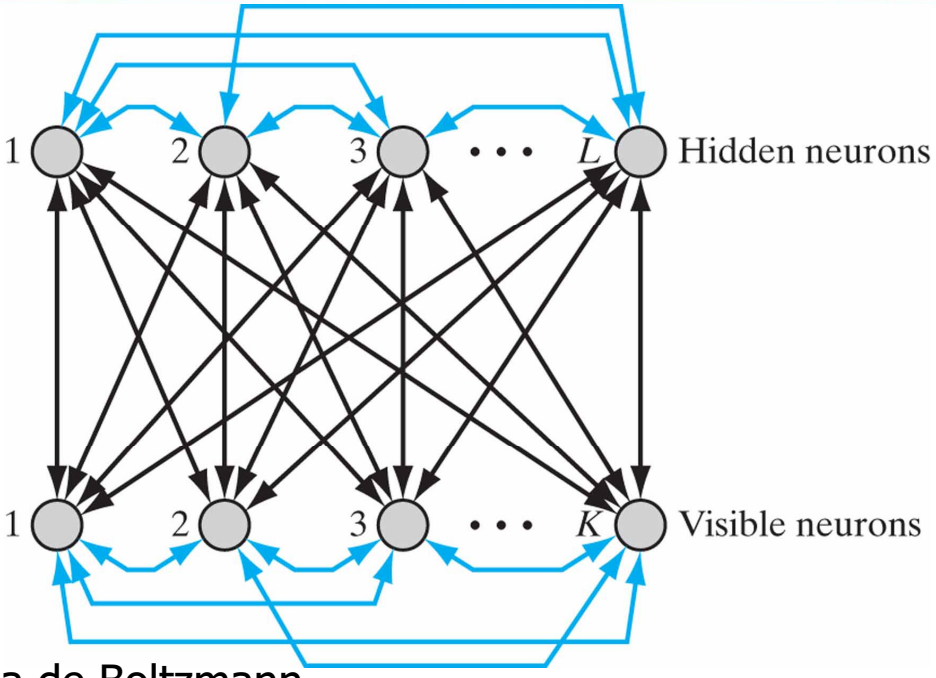

Máquina de Boltzmann

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Máquinas de Boltzmann

Problemas computacionales

- Búsqueda del mínimo de la función de energía
  (los mínimos locales representan interpretaciones subóptimas).

  e.g. Enfriamiento simulado

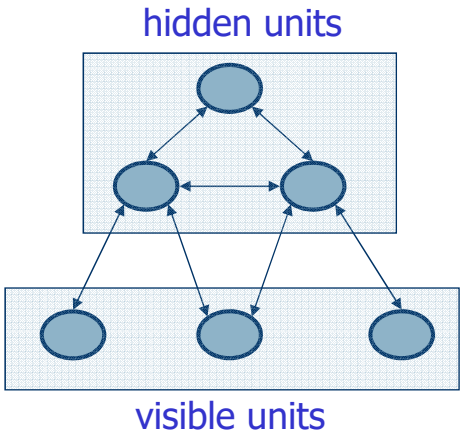

- Aprendizaje:
  Cómo establecer los pesos de las conexiones con las unidades ocultas (y entre las neuronas ocultas).

Máquinas de Boltzmann

Equilibrio térmico

- El equilibro térmico de una máquina de Boltzmann se alcanza cuando se estabiliza la distribución de probabilidad de sus estados (no tiene por qué tratarse de un único estado/configuración de mínima energía).

- Dado un conjunto de entrenamiento de vectores binarios, ajustamos un modelo que asigna una probabilidad a cada vector binario posible:

$$p(Model\ \ i \mid data) = \frac{p(data \mid Model\ \ i)}{\sum_j p(data \mid Model\ \ j)}$$

Máquinas de Boltzmann

La energía de una configuración
está relacionada con su probabilidad:

- Simplemente, definimos la probabilidad como

$$p(\mathbf{v},\mathbf{h}) \propto e^{-E(\mathbf{v},\mathbf{h})}$$

- La probabilidad de una configuración será, por tanto,

$$p(\mathbf{v},\mathbf{h}) = \frac{e^{-E(\mathbf{v},\mathbf{h})}}{\sum_{\mathbf{u},\mathbf{g}} e^{-E(\mathbf{u},\mathbf{g})}}$$

Función de partición

Máquinas de Boltzmann

La probabilidad de una configuración determinada para las neuronas visibles será la suma de las probabilidades de las configuraciones conjuntas que la contienen:

v	h	$-E$	e^{-E}	$p(\mathbf{v},\mathbf{h})$	$p(\mathbf{v})$
1 1	1 1	2	7.39	.186	0.466
1 1	1 0	2	7.39	.186	
1 1	0 1	1	2.72	.069	
1 1	0 0	0	1	.025	
1 0	1 1	1	2.72	.069	0.305
1 0	1 0	2	7.39	.186	
1 0	0 1	0	1	.025	
1 0	0 0	0	1	.025	
0 1	1 1	0	1	.025	0.144
0 1	1 0	0	1	.025	
0 1	0 1	1	2.72	.069	
0 1	0 0	0	1	.025	
0 0	1 1	-1	0.37	.009	0.084
0 0	1 0	0	1	.025	
0 0	0 1	0	1	.025	
0 0	0 0	0	1	.025	
			39.70		

$$p(\mathbf{v})=\frac{\sum_{\mathbf{h}} e^{-E(\mathbf{v},\mathbf{h})}}{\sum_{\mathbf{u},\mathbf{g}} e^{-E(\mathbf{u},\mathbf{g})}}$$

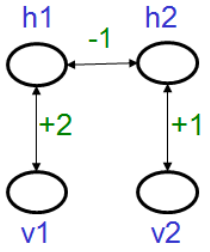

Máquinas de Boltzmann

$$p(\mathbf{v},\mathbf{h}) \propto e^{-E(\mathbf{v},\mathbf{h})}$$

- Si existen muchas neuronas ocultas, no podemos calcular el término de normalización (la función de partición incluye un número exponencial de términos).
- Usamos MCMC [Markov Chain Monte Carlo], comenzando de una configuración aleatoria, hasta que alcance una distribución estacionaria (equilibrio térmico) para tomar muestras del modelo.

Máquinas de Boltzmann

Algoritmo de aprendizaje

OBJETIVO

Maximizar el producto de las probabilidades que la máquina de Boltzmann les asigna a los vectores del conjunto de entrenamiento (o, de forma equivalente, la suma de sus logaritmos).

Es lo mismo que maximizar la probabilidad de que obtengamos los N casos del conjunto de entrenamiento si dejamos que la red llegue a su distribución estacionaria N veces sin entradas externas y muestreamos el estado de sus unidades visibles.

Máquinas de Boltzmann

Algoritmo de aprendizaje

Todo lo que un peso debe conocer
está contenido en la diferencia entre dos correlaciones:

$$\frac{\partial \log p(\mathbf{v})}{\partial w_{ij}} = \langle s_i s_j \rangle_{\mathbf{v}} - \langle s_i s_j \rangle_{model}$$

Valor esperado del producto de los estados en equilibrio térmico cuando se fija el estado de las unidades visibles

Valor esperado del producto de los estados en equilibrio térmico (sin fijar el estado de las unidades visibles)

$$\Delta w_{ij} \propto \langle s_i s_j \rangle_{data} - \langle s_i s_j \rangle_{model}$$

Máquinas de Boltzmann

Algoritmo de aprendizaje

¿Por qué?

$$\Delta w_{ij} \propto \langle s_i s_j \rangle_{data} - \langle s_i s_j \rangle_{model}$$

- La probabilidad de una configuración global en equilibrio térmico es una función exponencial de su energía (el equilibrio hace que el logaritmo de las probabilidades sea una función lineal de la energía).

$$-\frac{\partial E}{\partial w_{ij}} = s_i s_j$$

- El proceso de alcanzar el equilibrio se encarga propagar información acerca de los pesos, por lo que no necesitamos backpropagation.

Máquinas de Boltzmann

Algoritmo de aprendizaje

¿Por qué?

$$\Delta w_{ij} \propto \langle s_i s_j \rangle_{data} - \langle s_i s_j \rangle_{model}$$

$$p(\mathbf{v}) = \frac{\sum_{\mathbf{h}} e^{-E(\mathbf{v},\mathbf{h})}}{\sum_{\mathbf{u}} \sum_{\mathbf{g}} e^{-E(\mathbf{u},\mathbf{g})}}$$

La parte positiva encuentra configuraciones ocultas que funcionan bien con v (y baja su energía)

La parte negativa encuentra configuraciones conjuntas que mejor compiten (y sube su energía)

Máquinas de Boltzmann

- En una máquina de Boltzmann, las actualizaciones estocásticas de las distintas unidades deben ser secuenciales.

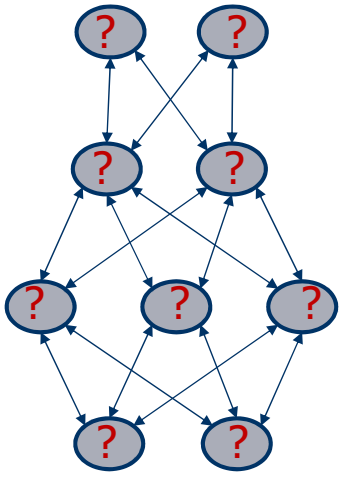

- Existe una arquitectura que admite actualizaciones paralelas alternas mucho más eficientes: **DBM [Deep Boltzmann Machine]**
  - Sin conexiones entre unidades de una misma capa.
  - Sin conexiones entre capas no adyacentes.

Máquinas de Boltzmann

DBM [Deep Boltzmann Machine]

MNIST: Datos reales & muestras del modelo aprendido

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas

1986 Harmonium = Restricted Boltzmann Machines
(máquinas de Boltzmann con estructura fija: grafos bipartidos con una capa de neuronas ocultas y una capa de neuronas "visibles", sin conexiones entre las neuronas de la misma capa)

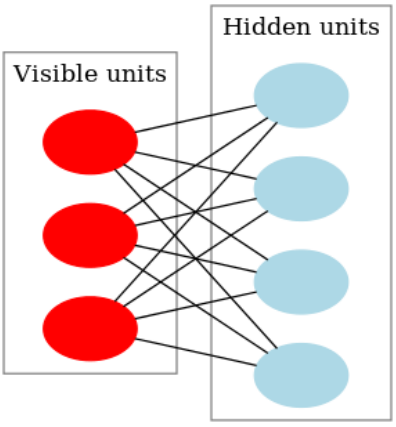

Paul Smolensky: "Information Processing in Dynamical Systems: Foundations of Harmony Theory". In David E. Rumelhart & James L. McLelland, Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Volume 1: Foundations. MIT Press, chapter 6, pp. 194-281. ISBN 0-262-68053-X.

Máquinas de Boltzmann

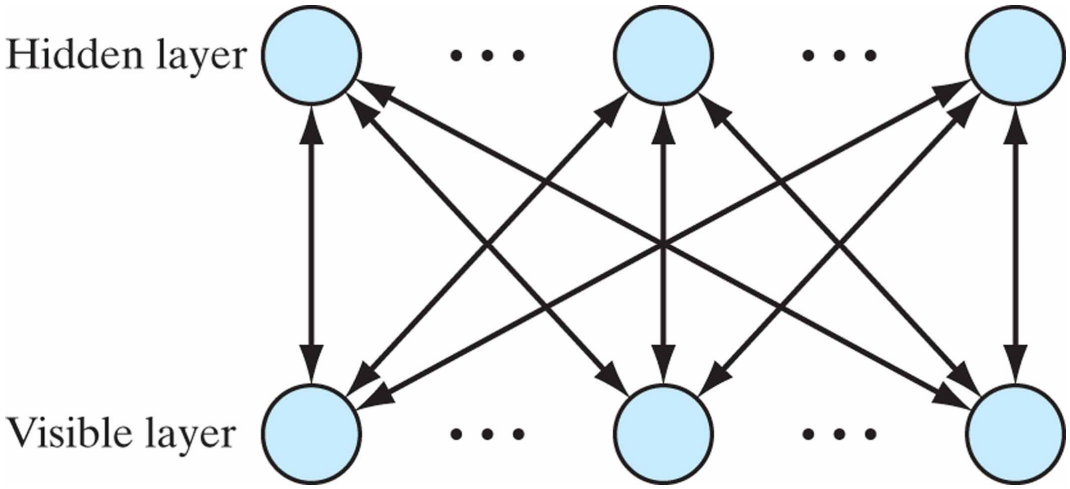

RBM: Máquina de Boltzmann restringida

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

Tipo particular de Markov Random Field [MRF] con una capa de neuronas estocásticas ocultas y una capa de neuronas estocásticas visibles u observables.

NOTA

Un campo aleatorio de Markov [MRF] es un modelo estocástico que representa una distribución conjunta de probabilidades mediante un grafo en el que cada nodo representa una variable aleatoria y cada arista una dependencia entre las variables que conecta.

Máquinas de Boltzmann

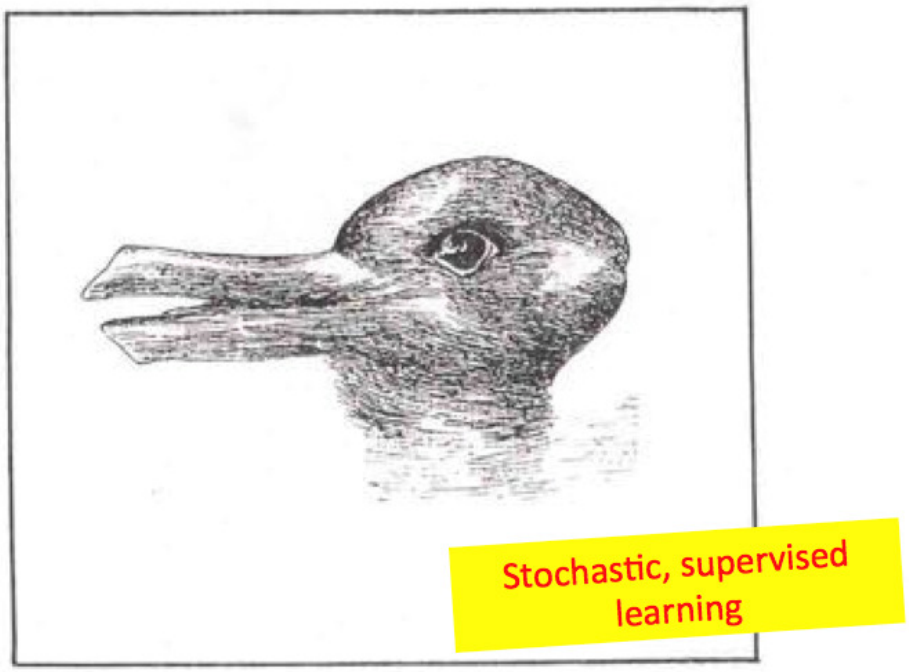

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

- La distribución sobre las unidades visibles (v) y ocultas (h) dados los parámetros del modelo (θ) se define en términos de una función de energía E:

$$p(\mathbf{v}, \mathbf{h}; \theta) = \frac{\exp(-E(\mathbf{v}, \mathbf{h}; \theta))}{Z}$$

donde Z es un factor de normalización o función de partición: $Z = \sum_{\mathbf{v}} \sum_{\mathbf{h}} \exp(-E(\mathbf{v}, \mathbf{h}; \theta))$

- La probabilidad marginal que el modelo le asigna a un vector visible v es: $p(\mathbf{v}; \theta) = \frac{\sum_{\mathbf{h}} \exp(-E(\mathbf{v}, \mathbf{h}; \theta))}{Z}$

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

Función de energía

- Para RBMs Bernoulli (visible) – Bernoulli (oculta):

$$E(\mathbf{v}, \mathbf{h}; \theta) = -\sum_{i=1}^{I} \sum_{j=1}^{J} w_{ij} v_i h_j - \sum_{i=1}^{I} b_i v_i - \sum_{j=1}^{J} a_j h_j$$

- Para RBMs Gaussian (visible) – Bernoulli (oculta):

$$E(\mathbf{v}, \mathbf{h}; \theta) = -\sum_{i=1}^{I} \sum_{j=1}^{J} w_{ij} v_i h_j - \frac{1}{2} \sum_{i=1}^{I} (v_i - b_i)^2 - \sum_{j=1}^{J} a_j h_j$$

Máquinas de Boltzmann

Bernoulli-Bernoulli RBM

Neuronas estocásticas binarias

$$p(h_j = 1|\mathbf{v};\theta) = \sigma\left(\sum_{i=1}^{I} w_{ij}v_i + a_j\right)$$

$$p(v_i = 1|\mathbf{h};\theta) = \sigma\left(\sum_{j=1}^{J} w_{ij}h_j + b_i\right)$$

$$\sigma(x) = 1/(1+\exp(-x))$$

Máquinas de Boltzmann

Bernoulli-Gaussian RBM

Neuronas binarias en la capa oculta,
valores reales en la capa visible.

$$p(h_j = 1|\mathbf{v};\theta) = \sigma\left(\sum_{i=1}^{I} w_{ij}v_i + a_j\right),$$

$$p(v_i|\mathbf{h};\theta) = N\left(\sum_{j=1}^{J} w_{ij}h_j + b_i, 1\right),$$

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

Calculando el gradiente del logaritmo de la función de verosimilitud [log-likelihood], se puede derivar la regla de actualización de los pesos de una RBM:

$$\Delta w_{ij} = E_{\text{data}}(v_i h_j) - E_{\text{model}}(v_i h_j)$$

E_{data} es el valor esperado observado en el conjunto de entrenamiento (muestreando h_j dados los v_i de acuerdo con el modelo) y E_{model} es el valor esperado bajo la distribución definida por el modelo.

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

Al restringir la topología de la red,
facilitamos el aprendizaje:

- En una RBM, se alcanza el equilibrio en un solo paso cuando se fija el valor de las unidades visibles:
  el cálculo del valor exacto de $E_{data}=\langle v_i h_j \rangle_{\mathbf{v}}$ es directo.

- Por desgracia, el cálculo de E_{model} es intratable…

Máquinas de Boltzmann

$$\Delta w_{ij} = \eta(\langle v_i h_j \rangle^0 - \langle v_i h_j \rangle^\infty)$$

Una fantasía

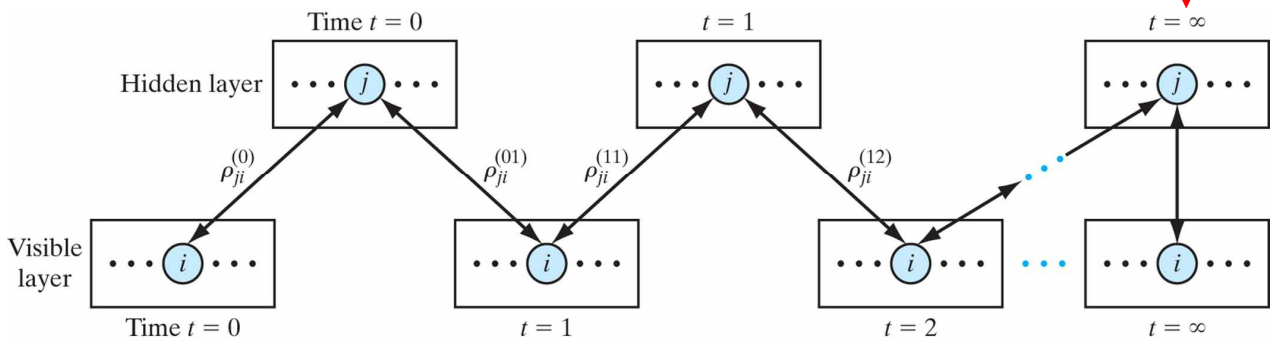

$\langle v_i h_j \rangle^0$ $\langle v_i h_j \rangle^\infty$

Muestreo de Gibbs @ RBM

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Máquinas de Boltzmann

Comenzamos con el estado de las neuronas visibles v_i:

$$\mathbf{h}_i \sim p(\mathbf{h}|\mathbf{v}_i, \boldsymbol{\theta})$$
$$\mathbf{v}'_i \sim p(\mathbf{v}|\mathbf{h}_i, \boldsymbol{\theta})$$
$$\mathbf{h}'_i \sim p(\mathbf{h}|\mathbf{v}'_i, \boldsymbol{\theta})$$

Podemos interpretar v_i' como el intento de reconstruir los datos originales v_i tras haberlos codificado en h_i (y volverlos a decodificar).

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

$$\Delta w_{ij} = E_{\text{data}}(v_i h_j) - E_{\text{model}}(v_i h_j)$$

La "divergencia contrastiva" [contrastive divergence] fue el primer método eficiente propuesto para aproximar E_{model}, consistente en ejecutar sólo algunos pasos del algoritmo de muestreo de Gibbs:

$$\text{Initialize } \mathbf{v_0} \text{ at data}$$
$$\text{Sample } \mathbf{h_0} \sim \mathbf{p}(\mathbf{h}|\mathbf{v_0})$$
$$\text{Sample } \mathbf{v_1} \sim \mathbf{p}(\mathbf{v}|\mathbf{h_0})$$
$$\text{Sample } \mathbf{h_1} \sim \mathbf{p}(\mathbf{h}|\mathbf{v_1})$$

Máquinas de Boltzmann

Divergencia contrastiva

$$\Delta w_{ij} = \eta(\langle v_i h_j \rangle^0 - \langle v_i h_j \rangle^1)$$

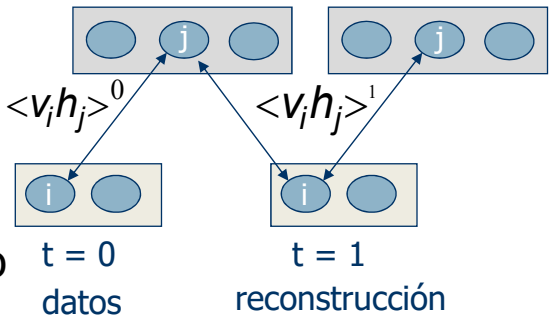

- Comenzamos con un vector del conjunto de entrenamiento sobre las unidades visibles.
- Actualizamos todas las unidades ocultas en paralelo.
- Actualizamos todas las unidades visibles en paralelo para obtener una reconstrucción de los datos.
- Volvemos a actualizar las unidades ocultas de nuevo.

No estamos siguiendo el gradiente del log-likelihood, pero funciona…

Máquinas de Boltzmann

Máquinas de Boltzmann restringidas [RBMs]

$$\Delta w_{ij} = E_{\text{data}}(v_i h_j) - E_{\text{model}}(v_i h_j)$$

Si usamos (v_1,h_1) para aproximar $E_{model}(v_i h_j)$ obtenemos el **algoritmo CD-1**.

Si ejecutamos más pasos de la cadena de Markov hasta obtener (v_k,h_k) tenemos el **algoritmo CD-k**.

Existen mejores técnicas para estimar el gradiente de las RBMs, como la verosimiliud máxima estocástica o divergencia contrastiva persistente [**PCD**]

Máquinas de Boltzmann

Divergencia contrastiva

$$\Delta w_{ij} = \eta(\langle v_i h_j \rangle^0 - \langle v_i h_j \rangle^1)$$

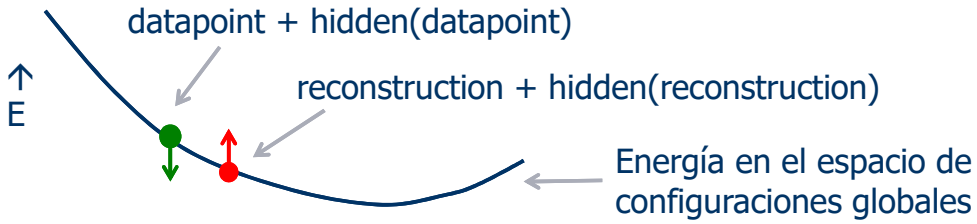

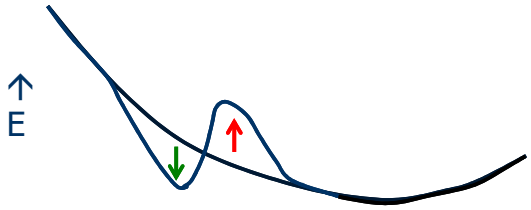

Cambio en los pesos para modificar la energía en el punto correspondiente a los datos.

Cambio en los pesos para aumentar la energía en el punto correspondiente a la reconstrucción.

Máquinas de Boltzmann

Geoff Hinton doesn't need to make hidden units.
They hide by themselves when he approaches.

Geoff Hinton doesn't disagree with you,
he contrastively diverges

Deep Belief Nets actually
believe deeply in Geoff Hinton.

Yann LeCun: "Geoff Hinton facts"
http://yann.lecun.com/ex/fun/index.html

Máquinas de Boltzmann

Algorithm 27.3: CD-1 training for an RBM with binary hidden and visible units

Initialize weights $\mathbf{W} \in \mathbb{R}^{R \times K}$ randomly;
$t := 0$;
for *each epoch* **do**
  $t := t + 1$;
  for *each minibatch of size* B **do**
    Set minibatch gradient to zero, $\mathbf{g} := \mathbf{0}$;
    for *each case* $\mathbf{v}_i$ *in the minibatch* **do**
      Compute $\boldsymbol{\mu}_i = \mathbb{E}[\mathbf{h}|\mathbf{v}_i, \mathbf{W}]$;
      Sample $\mathbf{h}_i \sim p(\mathbf{h}|\mathbf{v}_i, \mathbf{W})$;
      Sample $\mathbf{v}'_i \sim p(\mathbf{v}|\mathbf{h}_i, \mathbf{W})$;
      Compute $\boldsymbol{\mu}'_i = \mathbb{E}[\mathbf{h}|\mathbf{v}'_i, \mathbf{W}]$;
      Compute gradient $\nabla_{\mathbf{W}} = (\mathbf{v}_i)(\boldsymbol{\mu}_i)^T - (\mathbf{v}'_i)(\boldsymbol{\mu}'_i)^T$;
      Accumulate $\mathbf{g} := \mathbf{g} + \nabla_{\mathbf{W}}$;
    Update parameters $\mathbf{W} := \mathbf{W} + (\alpha_t / B)\mathbf{g}$

CD-1: Contrastive Divergence

[Murphy: "Machine Learning: A Probabilistic Perspective", 2012]

Máquinas de Boltzmann

Algorithm 1

RBMupdate($\mathbf{x}_1, \epsilon, W, \mathbf{b}, \mathbf{c}$)

This is the RBM update procedure for binomial units. It can easily adapted to other types of units.

$\mathbf{x}_1$ is a sample from the training distribution for the RBM

ϵ is a learning rate for the stochastic gradient descent in Contrastive Divergence

W is the RBM weight matrix, of dimension (number of hidden units, number of inputs)

$\mathbf{b}$ is the RBM offset vector for input units

$\mathbf{c}$ is the RBM offset vector for hidden units

Notation: $Q(\mathbf{h}_2. = 1|\mathbf{x}_2)$ is the vector with elements $Q(\mathbf{h}_{2i} = 1|\mathbf{x}_2)$

for all hidden units i **do**
- compute $Q(\mathbf{h}_{1i} = 1|\mathbf{x}_1)$ (for binomial units, $\text{sigm}(\mathbf{c}_i + \sum_j W_{ij}\mathbf{x}_{1j})$)
- sample $\mathbf{h}_{1i} \in \{0, 1\}$ from $Q(\mathbf{h}_{1i}|\mathbf{x}_1)$

end for

for all visible units j **do**
- compute $P(\mathbf{x}_{2j} = 1|\mathbf{h}_1)$ (for binomial units, $\text{sigm}(\mathbf{b}_j + \sum_i W_{ij}\mathbf{h}_{1i})$)
- sample $\mathbf{x}_{2j} \in \{0, 1\}$ from $P(\mathbf{x}_{2j} = 1|\mathbf{h}_1)$

end for

for all hidden units i **do**
- compute $Q(\mathbf{h}_{2i} = 1|\mathbf{x}_2)$ (for binomial units, $\text{sigm}(\mathbf{c}_i + \sum_j W_{ij}\mathbf{x}_{2j})$)

end for

- $W \leftarrow W + \epsilon(\mathbf{h}_1\mathbf{x}_1' - Q(\mathbf{h}_2. = 1|\mathbf{x}_2)\mathbf{x}_2')$
- $\mathbf{b} \leftarrow \mathbf{b} + \epsilon(\mathbf{x}_1 - \mathbf{x}_2)$
- $\mathbf{c} \leftarrow \mathbf{c} + \epsilon(\mathbf{h}_1 - Q(\mathbf{h}_2. = 1|\mathbf{x}_2))$

CD-1: Contrastive Divergence

[Bengio: "Learning Deep Architectures for AI", 2009]

Máquinas de Boltzmann

PCD: Persistent Contrastive Divergence

Mini-batch learning @ RBMs [Tieleman 2008]

Fase positiva: $E_{data} = \langle v_i h_j \rangle_{\mathbf{v}}$

- Fijamos la unidades visibles al valor de un vector de1l conjunto de entrenamiento.
- Calculamos el valor exacto $\langle v_i h_j \rangle$ para todos los pares (unidad visible, unidad oculta).
- Para cada par de unidades conectadas, promediamos $\langle v_i h_j \rangle$ sobre los datos del mini-lote.

Máquinas de Boltzmann

PCD: Persistent Contrastive Divergence
Mini-batch learning @ RBMs [Tieleman 2008]

Fase negativa: E_{model}

- Mantenemos un conjunto de partículas (cada partícula es un vector que corresponde a una configuración global de la red RBM).
- Actualizamos cada partícula unas cuantas veces utilizando actualizaciones paralelas alternas.
- Para cada par de unidades conectadas, promediamos $<v_i h_j>$ sobre el conjunto de partículas.

Máquinas de Boltzmann

Algorithm 27.4: Persistent CD for training an RBM with binary hidden and visible units

Initialize weights $\mathbf{W} \in \mathbb{R}^{D \times L}$ randomly;
Initialize chains $(\mathbf{v}_s, \mathbf{h}_s)_{s=1}^{S}$ randomly ;
for $t = 1, 2, \ldots$ **do**
  // Mean field updates ;
  for *each case* $i = 1 : N$ **do**
    $\mu_{ik} = \text{sigm}(\mathbf{v}_i^T \mathbf{w}_{:,k})$
  // MCMC updates ;
  for *each sample* $s = 1 : S$ **do**
    Generate $(\mathbf{v}_s, \mathbf{h}_s)$ by brief Gibbs sampling from old $(\mathbf{v}_s, \mathbf{h}_s)$
  // Parameter updates ;
  $\mathbf{g} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{v}_i (\boldsymbol{\mu}_i)^T - \frac{1}{S} \sum_{s=1}^{S} \mathbf{v}_s (\mathbf{h}_s)^T$;
  $\mathbf{W} := \mathbf{W} + \alpha_t \mathbf{g}$;
  Decrease α_t

PCD: Persistent Contrastive Divergence
[Murphy: "Machine Learning: A Probabilistic Perspective", 2012]

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]
Características que permiten reconstruir imágenes…

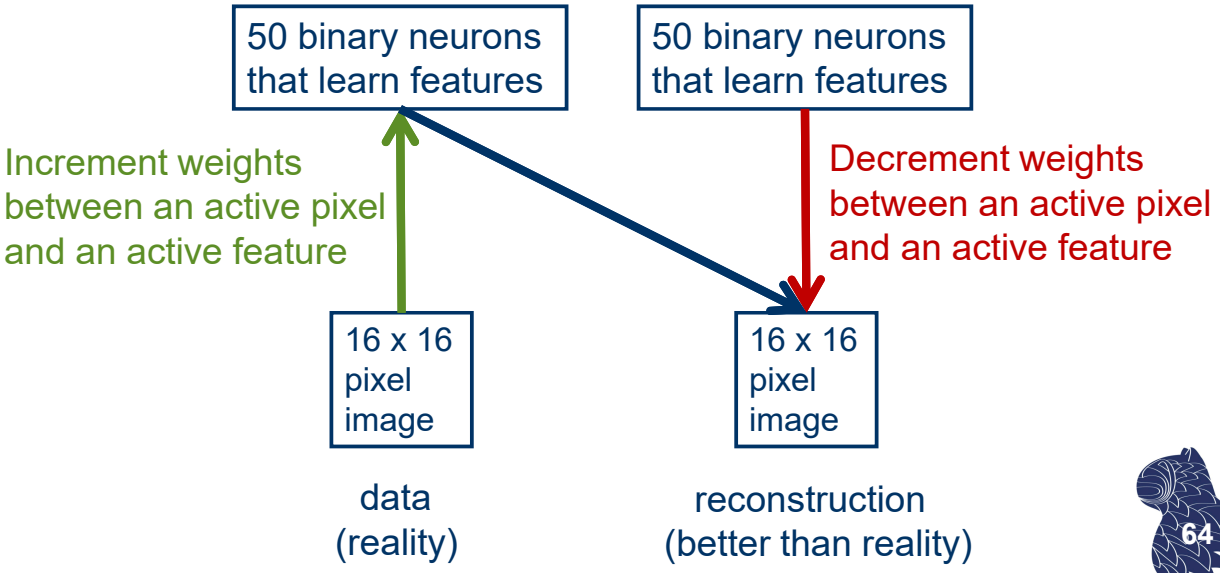

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

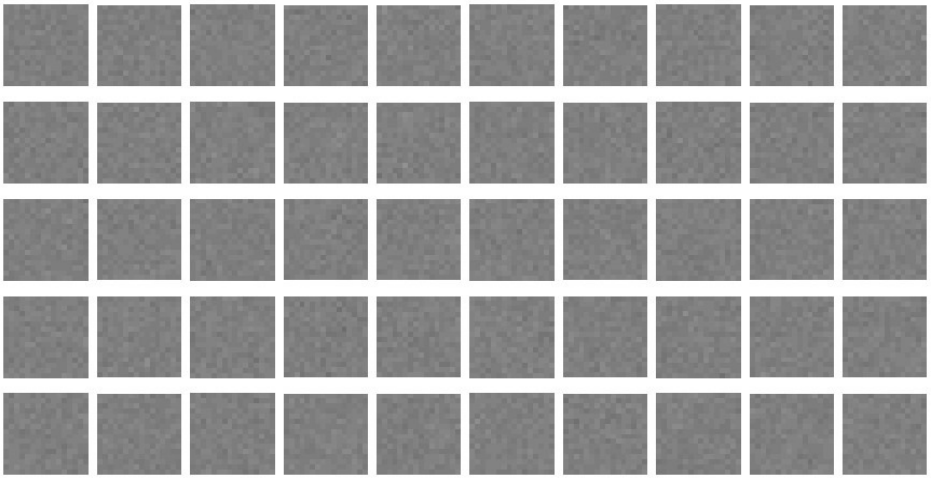

Inicialización:
Pesos pequeños aleatorios para romper simetrías

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

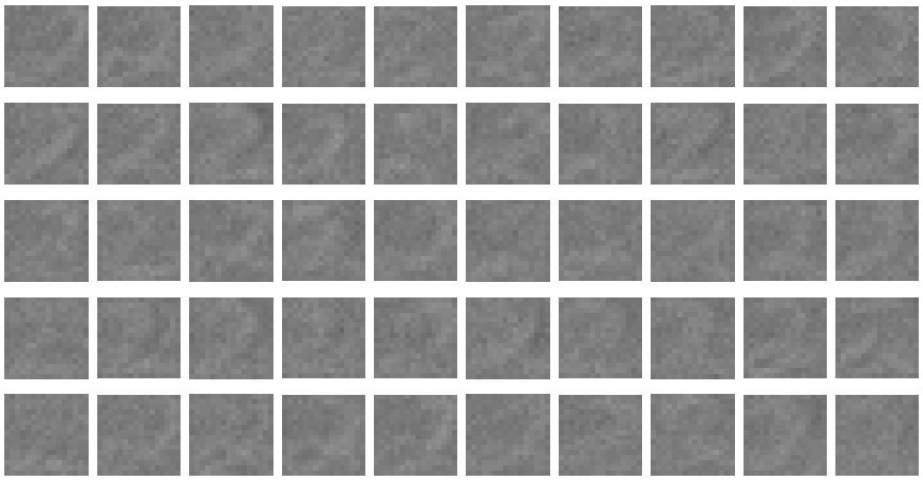

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

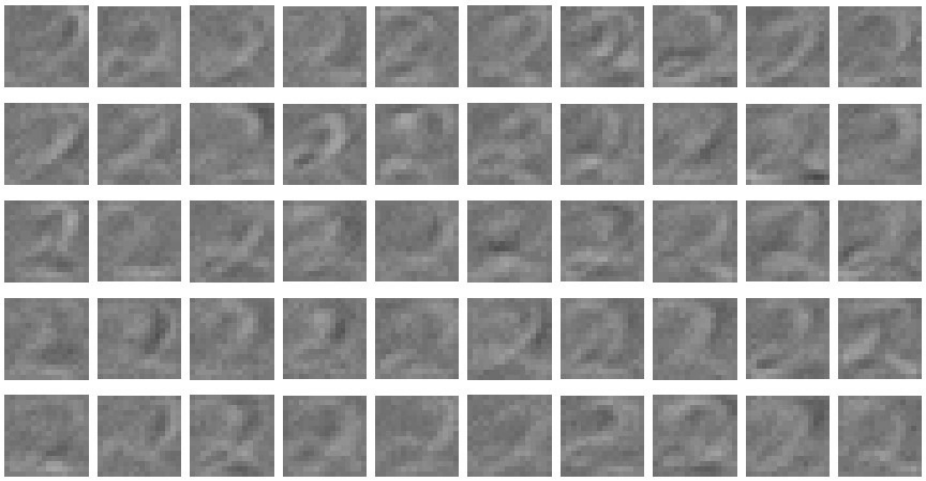

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

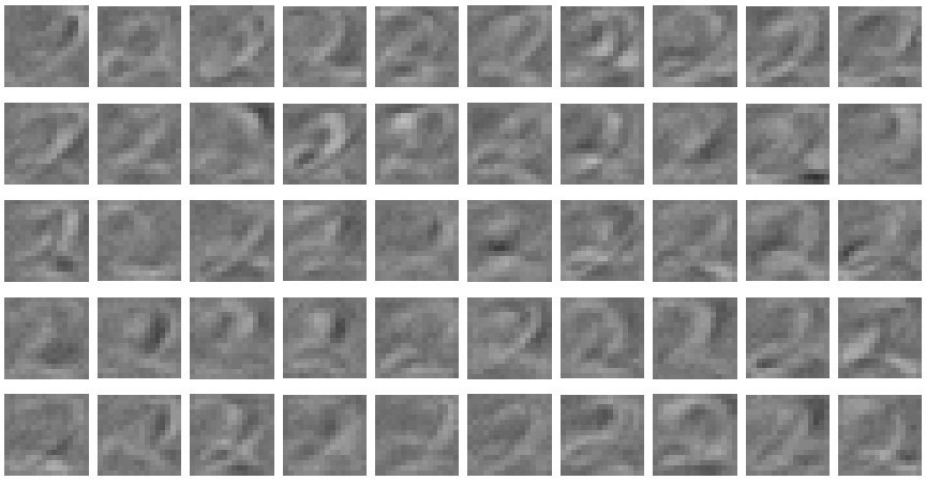

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

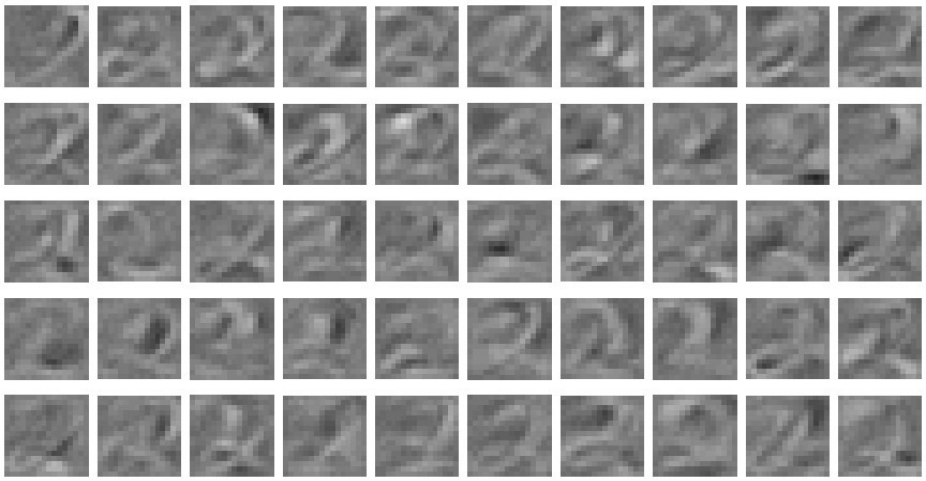

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

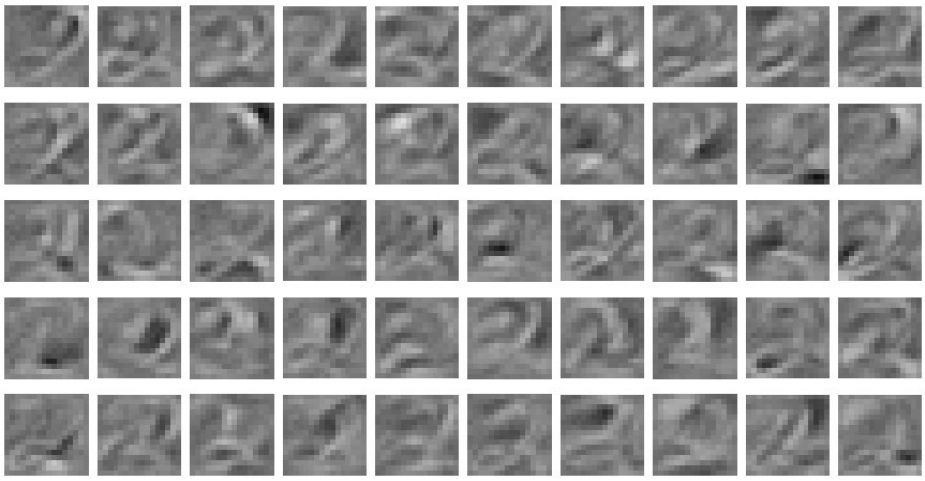

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

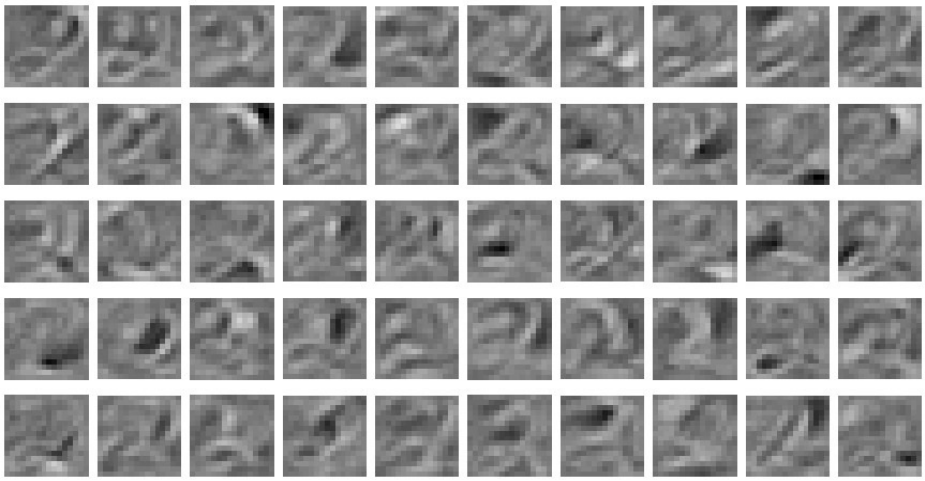

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

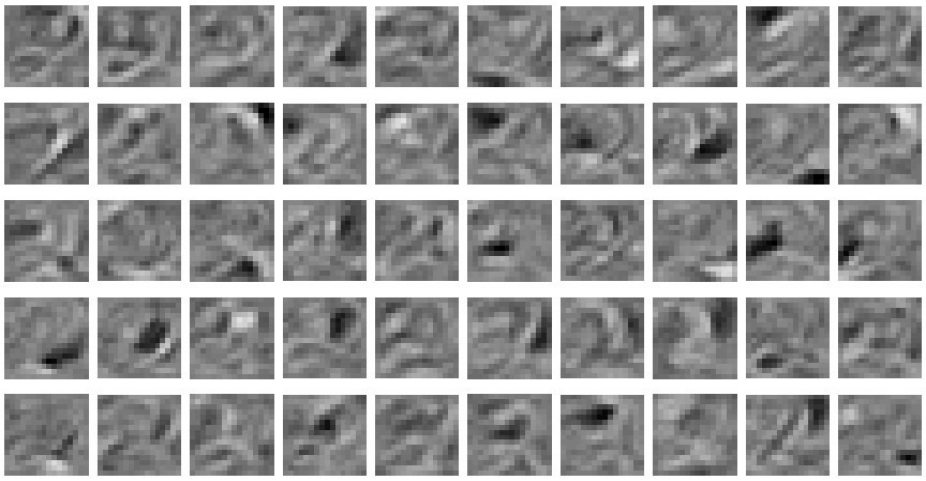

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

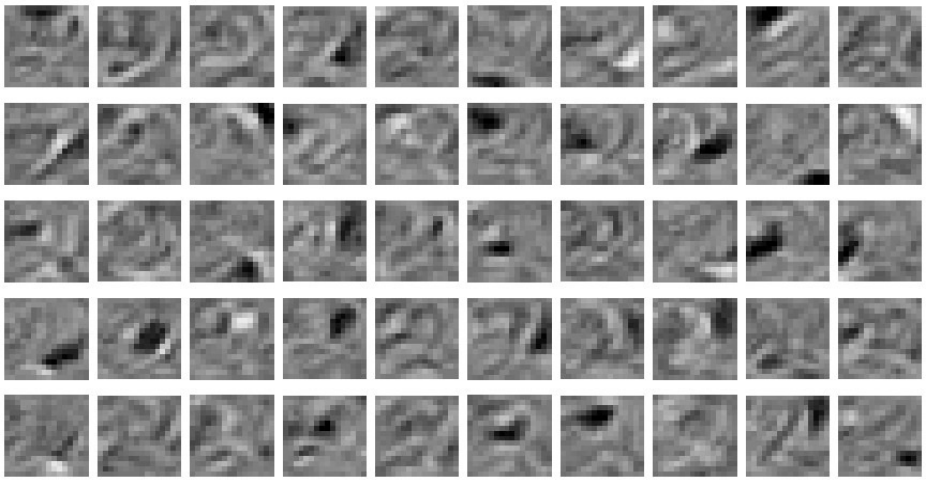

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

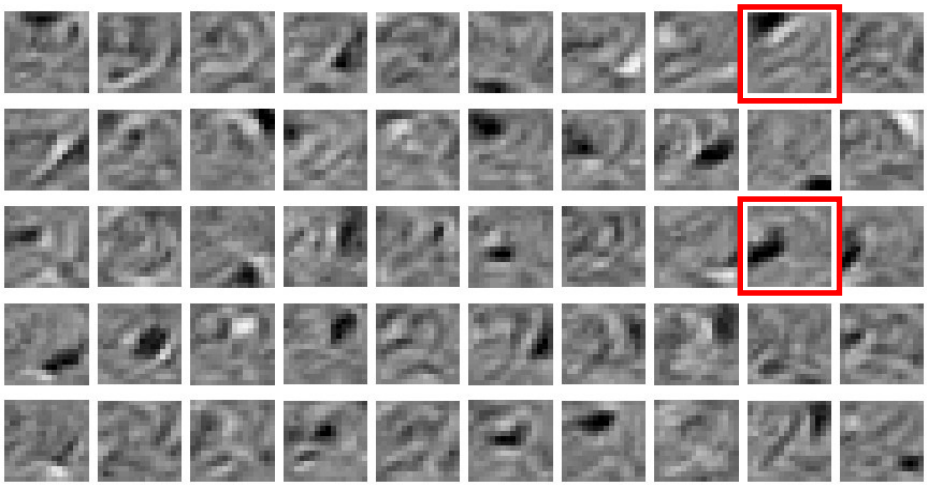

Configuración final de los pesos:

Cada neurona oculta aprende una característica distinta.

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

¿Cómo se reconstruyen las imágenes?

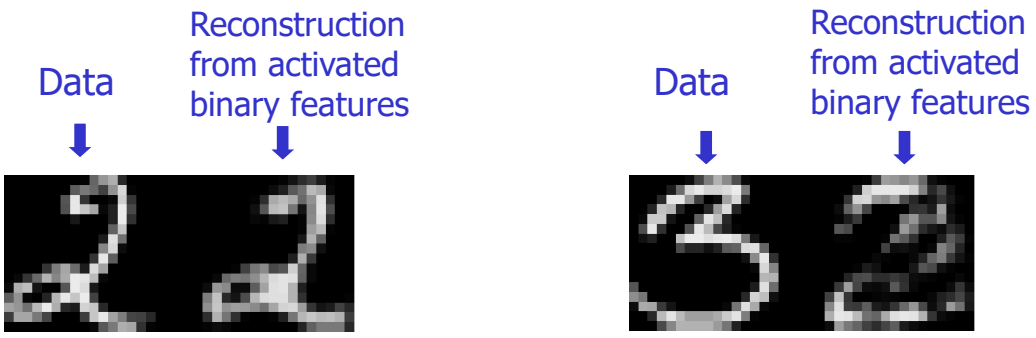

New test image from the digit class that the model was trained on

Image from an unfamiliar digit class

Máquinas de Boltzmann

EJEMPLO: DIVERGENCIA CONTRASTIVA [Hinton]

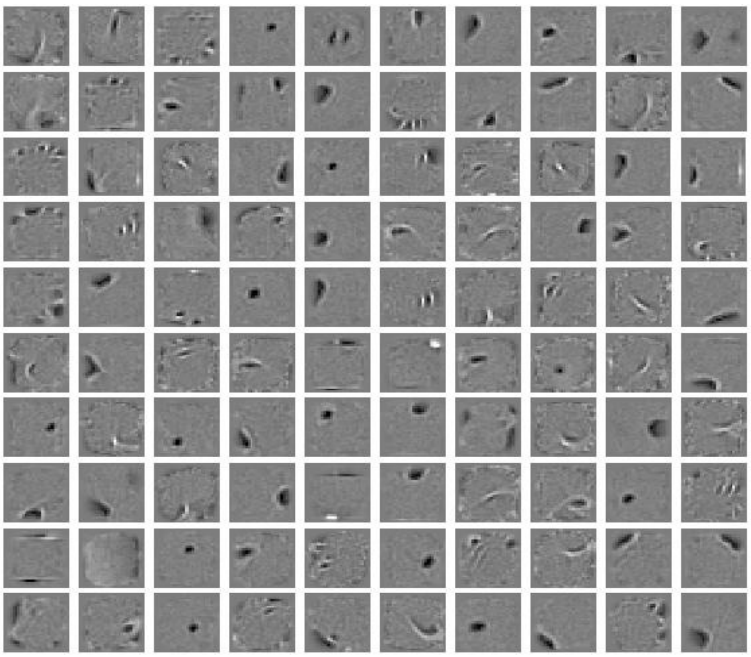

Características aprendidas por la primera capa oculta de un modelo de los 10 dígitos.

Máquinas de Boltzmann

APLICACIÓN: SISTEMAS DE RECOMENDACIÓN

La competición del millón de dólares

NETFLIX

- Tenemos las evaluaciones de medio millón de usuarios sobre 18000 películas en una escala de 1 a 5.
- Cada usuario sólo evalúa una pequeña fracción de las películas.

OBJETIVO

Predecir las evaluaciones de películas:
"filtrado colaborativo" [collaborative filtering]

Máquinas de Boltzmann

APLICACIÓN: SISTEMAS DE RECOMENDACIÓN

La competición del millón de dólares

NETFLIX

	M1	M2	M3	M4	M5	M6
U1				3		
U2	5		1			
U3		3	5			
U4	4		?			5
U5			4			
U6					2	

Máquinas de Boltzmann

APLICACIÓN: SISTEMAS DE RECOMENDACIÓN

La competición del millón de dólares

NETFLIX

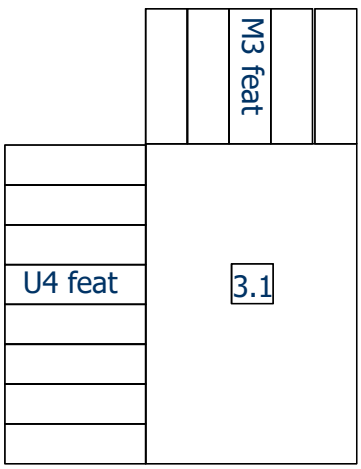

Factorización de matrices

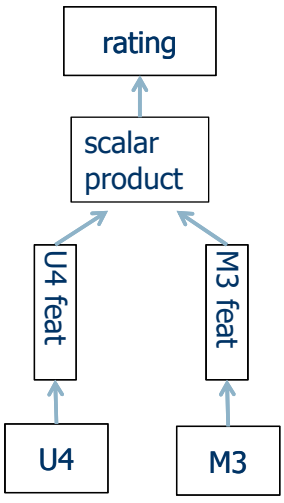

Alternativa basada en RBM

Máquinas de Boltzmann

APLICACIÓN: SISTEMAS DE RECOMENDACIÓN

La competición del millón de dólares

Tratamos cada usuario
como un caso de entrenamiento:

- Vector de evaluaciones de películas.
- Una unidad visible por película (5-way softmax): la regla CD para softmax es la misma que para una unidad binaria
- ~100 unidades ocultas

Uno de los valores visibles es desconocido (tiene que proporcionarlo el modelo).

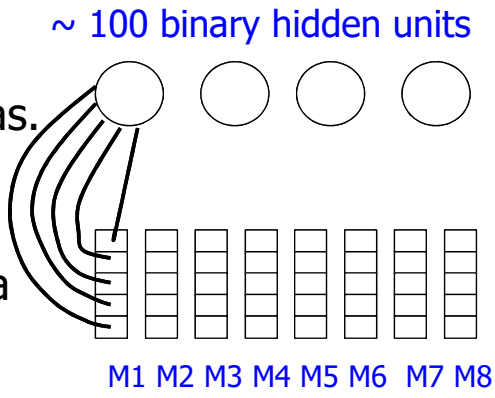

Máquinas de Boltzmann

APLICACIÓN: SISTEMAS DE RECOMENDACIÓN

La competición del millón de dólares

No tenemos evaluaciones de todos los usuarios para todas las películas:

- Para cada usuario, usamos una RBM con unidades visibles sólo para las películas que ha evaluado.
- Tenemos diferentes RBMs, pero se comparten los pesos.
- Los modelos se entrenan primero con CD1, luego con CD3, CD5 y CD9
- Cada RBM sólo tiene un caso de entrenamiento.

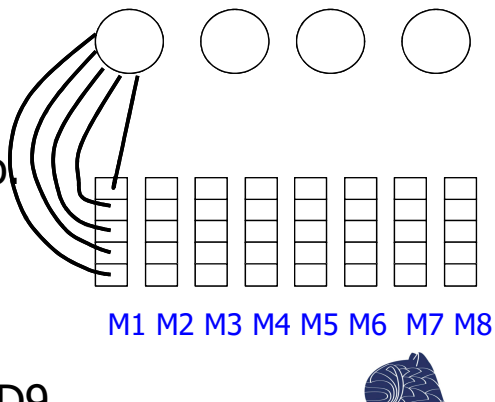

Máquinas de Boltzmann

APLICACIÓN: SISTEMAS DE RECOMENDACIÓN

La competición del millón de dólares

- Las RBMs funcionan tan bien como los métodos de factorización de matrices, pero dan distintos errores.
- Se pueden combinar sus predicciones.
- El equipo que se llevó el premio utilizaba diferentes RBMs, que combinaba con múltiples modelos.

Deep Belief Networks (DBNs)

Las redes de creencia [belief networks] son grafos dirigidos acíclicos compuestos de variables estocásticas.

Cuando observamos algunas variables, queremos resolver dos problemas:

- **Inferencia:**
  Inferir los estados de las variables no observadas.
- **Aprendizaje:**
  Ajustar las interacciones entre las variables para que sea más probable que la red genere los datos.

Deep Belief Networks (DBNs)

Dos tipos de redes neuronales
compuestas de neuronas estocásticas

- Redes de Hopfield y máquinas de Boltzmann (conexiones simétricas & funciones de energía)
- Redes causales (grafos dirigidos acíclicos): **Sigmoid Belief Nets** [Neal 1992]

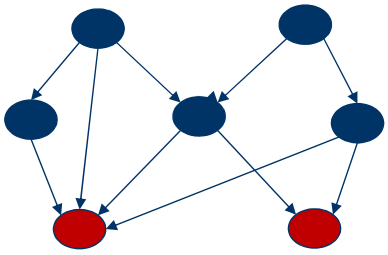

Deep Belief Networks (DBNs)

¿Por qué es difícil aprender SBNs?

Para aprender W,
necesitamos muestrear de la
distribución de la primera capa oculta:

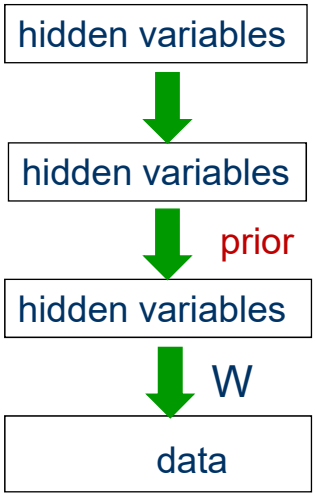

- Aunque dos causas ocultas sean independientes, se vuelven dependientes cuando observamos el efecto en el que ambas pueden influir ["explaining away"].
- Necesitamos conocer los pesos de las capas superiores (todos los pesos interactúan).
- Tenemos que integrar sobre todas las posibles configuraciones de las capas superiores !!!

Deep Belief Networks (DBNs)

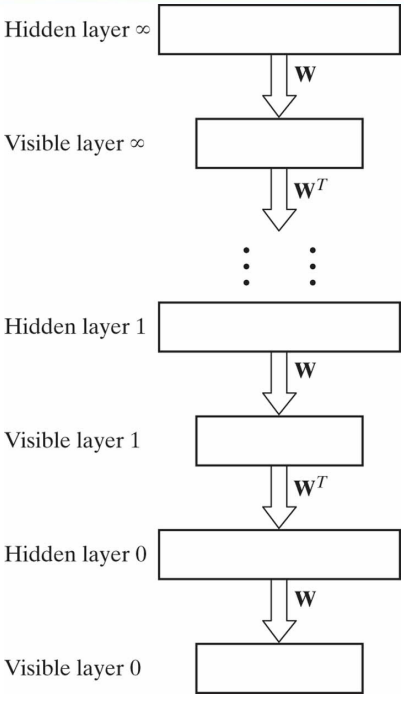

RBM ≡ SBN of infinite depth

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Deep Belief Networks (DBNs)

IDEA: "Stacking"

- Entrenamos una capa de características que reciben directamente los datos de entrada.
- A continuación, usamos las activaciones de las características aprendidas como entradas para aprender las características de una segunda capa de características.
- Repetimos…

Deep Belief Networks (DBNs)

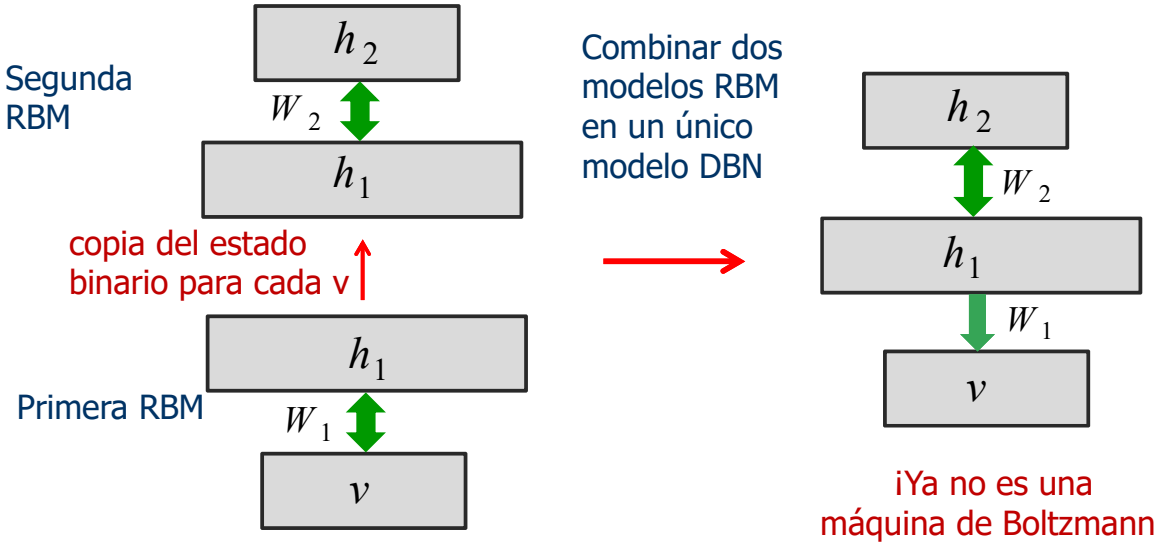

Deep Belief Networks (DBNs)

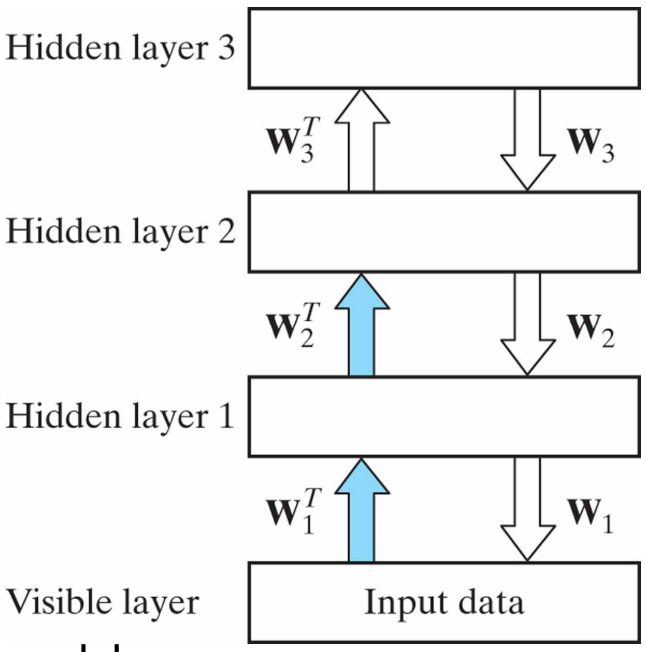

DBN generative model

[Haykin: "Neural Networks and Learning Machines", 3rd edition]

Deep Belief Networks (DBNs)

Algoritmo greedy de aprendizaje por capas
[Greedy layer-wise learning of DBNs]

- Ajustar una RBM para aprender W_1 (CD-1 o PCD).
- Desenrollar la RBM en una DBN con dos capas ocultas:

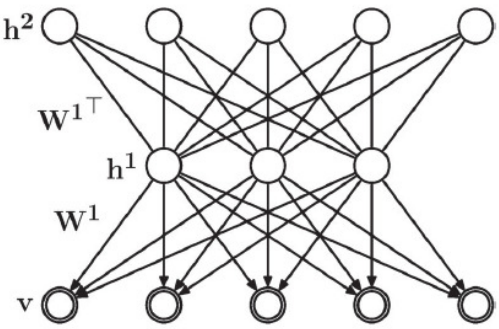

Deep Belief Networks (DBNs)

Algoritmo greedy de aprendizaje por capas
[Greedy layer-wise learning of DBNs]

- "Congelamos" los pesos dirigidos W_1 y dejamos que W_2 no tenga que coincidir con W_1^T.
- Ajustamos una segunda RBM para aprender $p(h_1|W_2)$. La entrada de esta segunda RBM será la activación de las unidades ocultas $E[h_1|v,W_1]$.
- Seguimos añadiendo capas ocultas…

Deep Belief Networks (DBNs)

Algoritmo greedy de aprendizaje por capas

[Greedy layer-wise learning of DBNs]

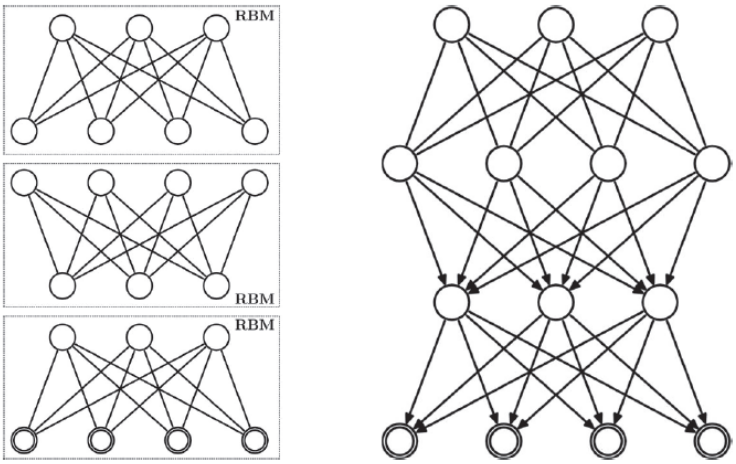

Stack of RBMs and corresponding DBN

Ruslan Salakhutdinov: Deep Generative Models
Ph.D. thesis, University of Toronto, 2009

Deep Belief Networks (DBNs)

Algorithm 2

`TrainUnsupervisedDBN`$(\widehat{P}, \epsilon, \ell, W, \mathbf{b}, \mathbf{c}, \texttt{mean\_field\_computation})$
Train a DBN in a purely unsupervised way, with the greedy layer-wise procedure in which each added layer is trained as an RBM (e.g. by Contrastive Divergence).
$\widehat{P}$ is the input training distribution for the network
ϵ is a learning rate for the RBM training
ℓ is the number of layers to train
W^k is the weight matrix for level k, for k from 1 to ℓ
$\mathbf{b}^k$ is the visible units offset vector for RBM at level k, for k from 1 to ℓ
$\mathbf{c}^k$ is the hidden units offset vector for RBM at level k, for k from 1 to ℓ
`mean_field_computation` is a Boolean that is true iff training data at each additional level is obtained by a mean-field approximation instead of stochastic sampling

for $k = 1$ to ℓ **do**
  • initialize $W^k = 0$, $\mathbf{b}^k = 0$, $\mathbf{c}^k = 0$
  while not stopping criterion **do**
    • sample $\mathbf{h}^0 = \mathbf{x}$ from $\widehat{P}$
    for $i = 1$ to $k-1$ **do**
      if `mean_field_computation` **then**
        • `assign` $\mathbf{h}^i_j$ `to` $Q(\mathbf{h}^i_j = 1|\mathbf{h}^{i-1})$, `for all elements` j `of` $\mathbf{h}^i$
      else
        • `sample` $\mathbf{h}^i_j$ `from` $Q(\mathbf{h}^i_j|\mathbf{h}^{i-1})$, `for all elements` j `of` $\mathbf{h}^i$
      end if
    end for
    • `RBMupdate`$(\mathbf{h}^{k-1}, \epsilon, W^k, \mathbf{b}^k, \mathbf{c}^k)$ {thus providing $Q(\mathbf{h}^k|\mathbf{h}^{k-1})$ for future use}
  end while
end for

Algoritmo de entrenamiento de una DBN

[Bengio: "Learning Deep Architectures for AI", 2009]

Deep Belief Networks (DBNs)

Algoritmo greedy de aprendizaje por capas

[Greedy layer-wise learning of DBNs]

¿Por qué funciona?

- El model RBM inferior puede expresarse como

$$p(v) = \sum_h p(h)\ p(v \mid h)$$

- Si dejamos intacto p(v|h) y mejoramos p(h), mejoraremos p(v)

Deep Belief Networks (DBNs)

Ajuste final: "backfitting" / "fine-tuning"

Se suelen afinar los pesos finales usando una versión "contrastiva" del algoritmo wake-sleep para SBNs:

- Muestreo ascendente para ajustar los pesos descendentes (para que sean buenos a la hora de reconstruir las actividades de la capa inferior).
- Muestreo de Gibbs en la RBM superior (ajustar los pesos de la RBM usando CD).
- Muestreo descendente para ajustar los pesos ascendentes (para que sean buenos a la hora de reconstruir las actividades de la capa superior).

Por desgracia, este procedimiento es muy lento.

Deep Belief Networks (DBNs)

MNIST

- Las primeras dos capas ocultas se aprenden sin utilizar las etiquetas.

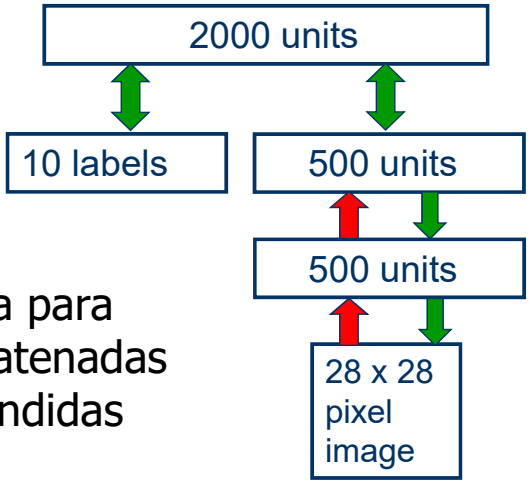

- La capa superior se entrena para modelar las etiquetas concatenadas con las características aprendidas en la segunda capa oculta.

- Los pesos finales se afinan para obtener un modelo generativo mejor usando "contrastive wake-sleep".

Deep Belief Networks (DBNs)

MNIST: 1.25% error

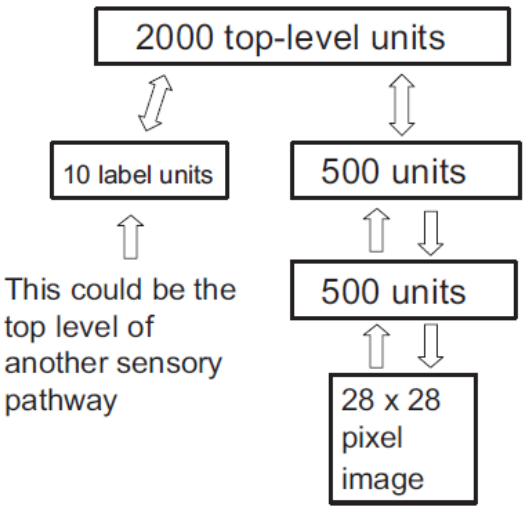

Geoffrey E. Hinton, Simon Osindero & Yee-Whye Teh:
A fast learning algorithm for deep belief nets.
Neural Computation 18, 1527–1554, 2006.

Deep Belief Networks (DBNs)

DEMO

Geoffrey Hinton: "The Next Generation of Neural Networks"
Google Tech Talks, 2007
https://www.youtube.com/watch?v=AyzOUbkUf3M

DBN-DNN

Generative pre-training of deep neural nets

- Backpropagation no funciona bien cuando existen varias capas ocultas, debido al problema conocido como "desaparición del gradiente" [vanishing gradient]: Cuanto más nos alejamos de los datos, más pequeños son los gradientes.

- Sin embargo, podemos inicializar los parámetros de la red utilizando aprendizaje no supervisado: forzamos que el modelo tenga una respuesta multidimensional (los vectores de entrada) en vez de escalar (la clase) y con eso se mejora el entrenamiento de la red.

DBN-DNN

Generative pre-training of deep neural nets

Las redes multicapa con varias capas ocultas [deep neural networks] que se entrenan con una fase de pre-entrenamiento no supervisado DBN seguido de backpropagation se denominan DBN-DNN.

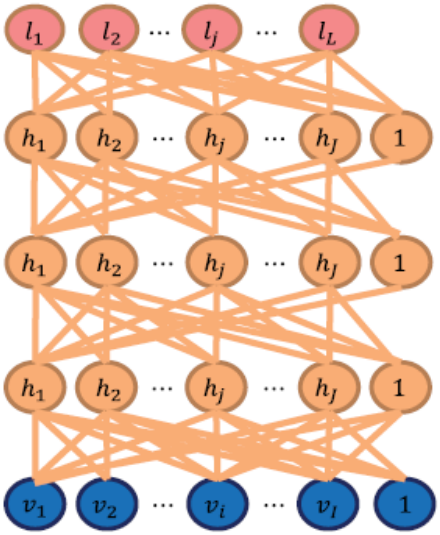

DBN-DNN

Para resolver problemas de aprendizaje usando DBNs:

- Utilizamos el algoritmo greedy de aprendizaje por capas para apilar un conjunto de RBMs.
- Consideramos este proceso como un "pre-entrenamiento" que nos ayuda a encontrar un buen conjunto inicial de pesos, que luego afinaremos utilizando una técnica de **búsqueda local**.
- "Contrastive wake-sleep" es mejor para modelos generativos, mientras que **backpropagation** se usa para modelos discriminativos.

DBN-DNN

Este proceso (pre-training + backpropagation):

- Solventa muchas de las limitaciones del uso del backpropagation estándar.
- Facilita el aprendizaje de redes con varias capas ocultas [deep nets].
- Permite que las redes generalicen mejor.

DBN-DNN

¿Por qué funciona?

- **Optimización**: El algoritmo greedy por capas es escalable y no empezamos a utilizar backpropagation hasta que tenemos un conjunto razonable de predictores de características (que pueden ser muy útiles para discriminar entre clases).
- **Sobreaprendizaje**: La mayor parte de la información proviene de los datos de entrada; el ajuste final sólo modifica ligeramente las fronteras de decisión.

  Además, podemos aprovechar datos no etiquetados.

DBN-DNN

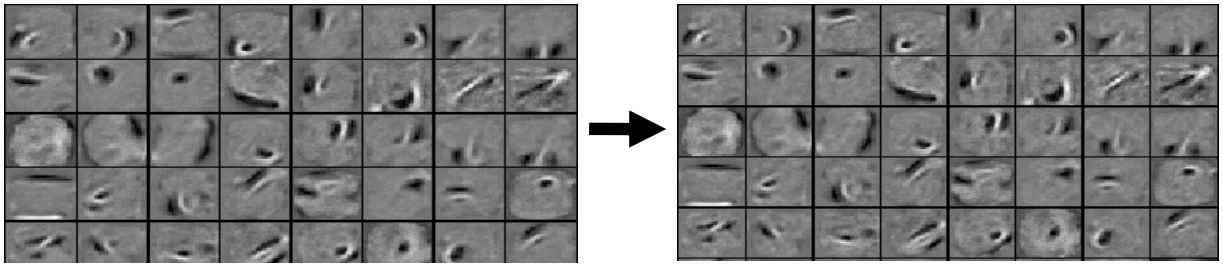

Before fine-tuning

After fine-tuning

DBN-DNN

El efecto del pre-entrenamiento no supervisado
[Erhan et al., AISTATS'2009]

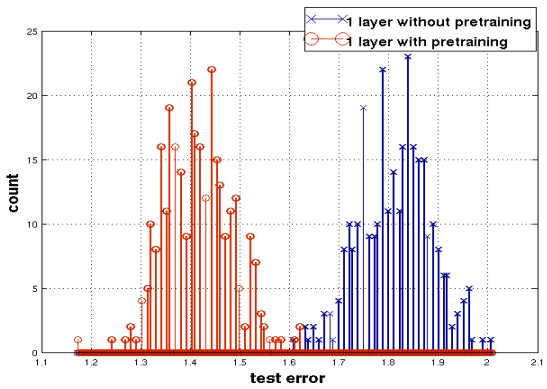

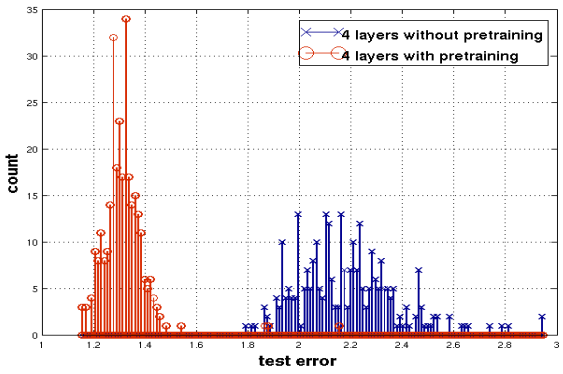

DBN-DNN

El efecto del pre-entrenamiento no supervisado
[Erhan et al., AISTATS'2009]

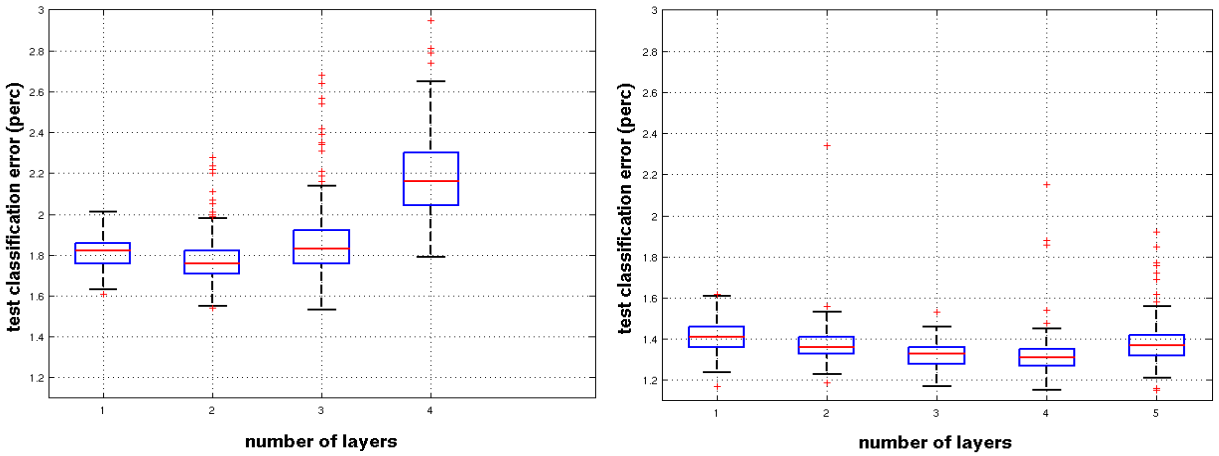

DBN-DNN

El efecto del pre-entrenamiento no supervisado
[Erhan et al., AISTATS'2009]

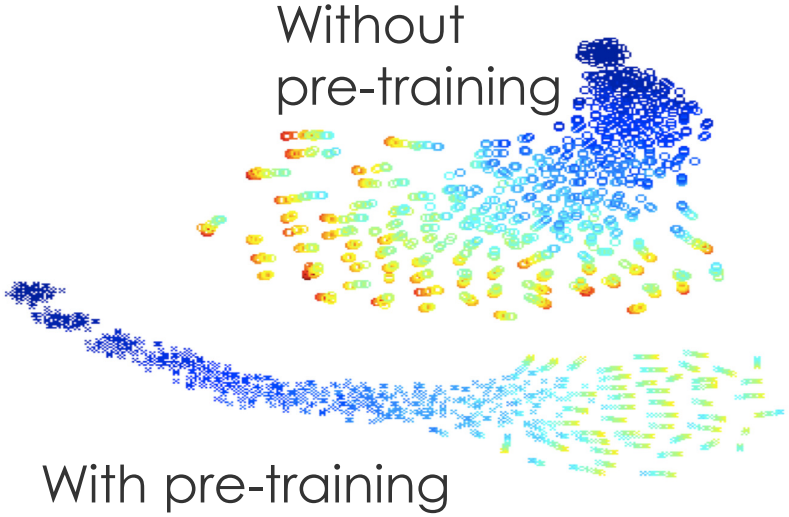

DBN-DNN

Pre-entrenamiento no supervisado

¿Por qué funciona?

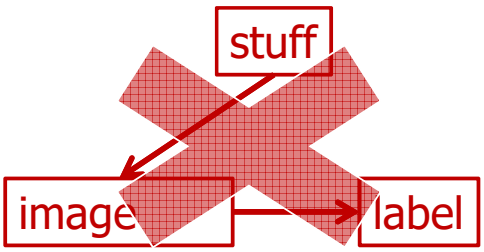

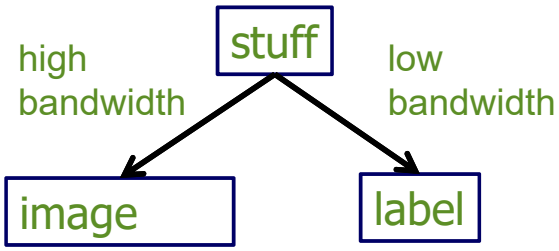

Tiene sentido descubrir primero qué es lo que generó la imagen para luego determinar a qué clase corresponde.

DBN-DNN

MNIST

1. Entrenamos la DBN.
2. Añadimos un bloque softmax sobre la capa superior…

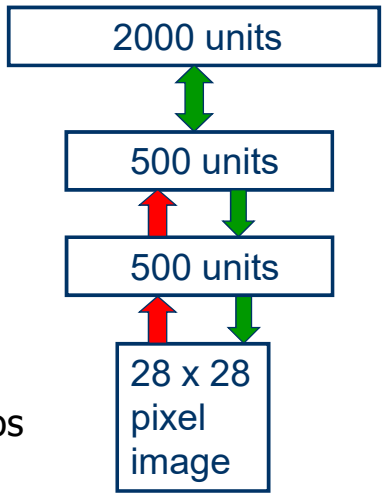

Tasa de error

1.6% Backprop usando 1 ó 2 capas ocultas
1.5% Backprop con restricciones L2 sobre pesos
1.4% Support Vector Machines
1.25% DBN Modelo generativo (contrastive wake-sleep)
1.15% DBN-DNN (modelo generativo + backpropagation)
0.49% CNN 600,000 dígitos distorsionados
0.39% CNN 600,000 dígitos distorsionados (pre-training+backprop)

DBN-DNN

Ejemplo
DBN-HMM

Red DBN-DNN utilizada para ajustar los parámetros de un modelo oculto de Markov [HMM] en sistemas de reconocimiento de voz.

@ Microsoft Research

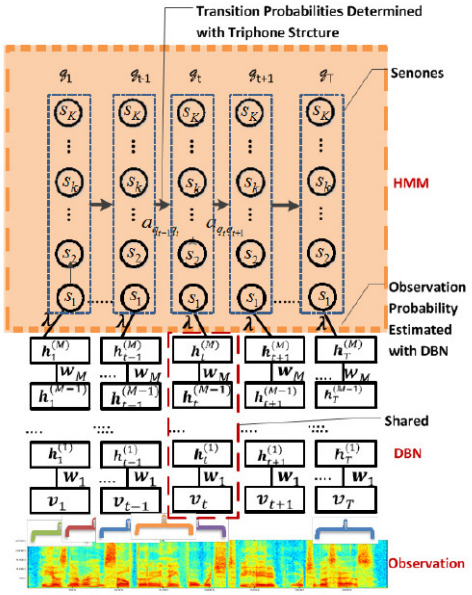

DBN-DNN

Ejemplo
DBN-HMM
TIMIT benchmark

- El mejor sistema de reconocimiento de voz independiente del hablante requería combinar varios modelos y tenía una tasa de error del **24.4%**.

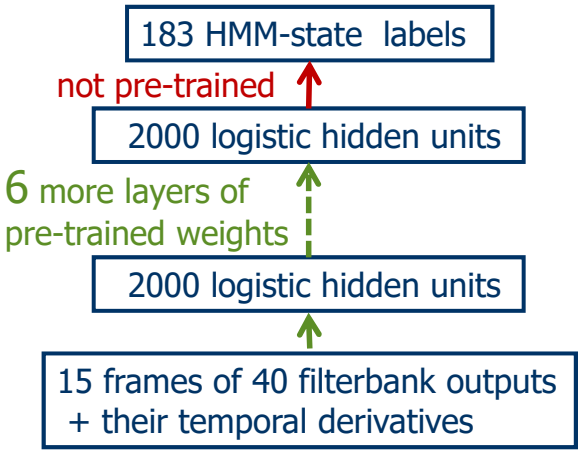

- Una red DBN-HMM con 8 capas bajó el error directamente al **20.7%** y cambió la forma de diseñar sistemas de reconocimiento de voz.

Deep Learning

Para algunos investigadores, que intentan obtener garantías teóricas basadas en resultados matemáticos: "[deep learning] might seem to be a regression" ;-)

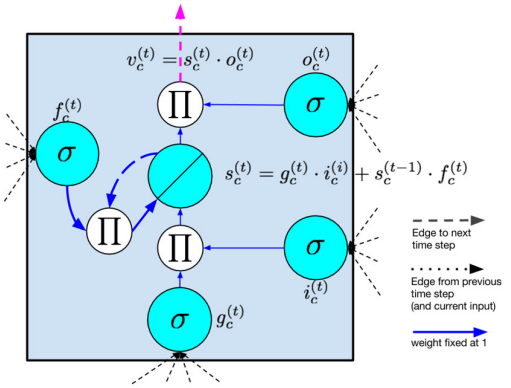

LSTM (red recurrente)

En la práctica, los algoritmos con las mejores propiedades teóricas no son siempre los que mejor funcionan (sin restar importancia al estudio de las propiedades de los algoritmos de aprendizaje).

Deep Learning

Las técnicas heurísticas tienen éxito gracias a la disponibilidad de grandes conjuntos de datos (en los que el riesgo de sobreaprendizaje es menor) y la capacidad de cálculo de los sistemas actuales.

La validación con conjuntos de datos de prueba independientes ofrece una estimación de su comportamiento esperado en situaciones reales (los análisis teóricos se centran en el peor caso).

Deep Learning

Few Things Are Guaranteed

When attainable, theoretical guarantees are beautiful. They reflect clear thinking and provide deep insight to the structure of a problem. Given a working algorithm, a theory which explains its performance deepens understanding and provides a basis for further intuition. Given the absence of a working algorithm, theory offers a path of attack.

However, there is also beauty in the idea that well-founded intuitions paired with rigorous empirical study can yield consistently functioning systems that outperform better-understood models, and sometimes even humans at many important tasks. Empiricism offers a path forward for applications where formal analysis is stifled, and potentially opens new directions that might eventually admit deeper theoretical understanding in the future.

Zachary Lipton:
"Deep Learning and the Triumph of Empiricism"
KDnuggets, July 2015

Cursos

Neural Networks for Machine Learning
by Geoffrey Hinton
(University of Toronto & Google)
https://www.coursera.org/course/neuralnets

coursera

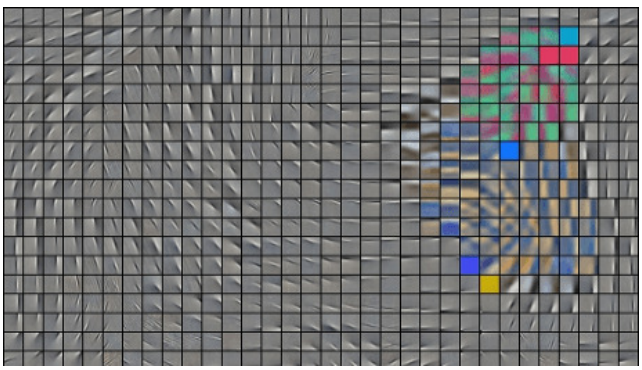

UNIVERSITY OF TORONTO

Bibliografía

Lecturas recomendadas

Ian Goodfellow,
Yoshua Bengio
& Aaron Courville:
Deep Learning
MIT Press, 2016
ISBN 0262035618

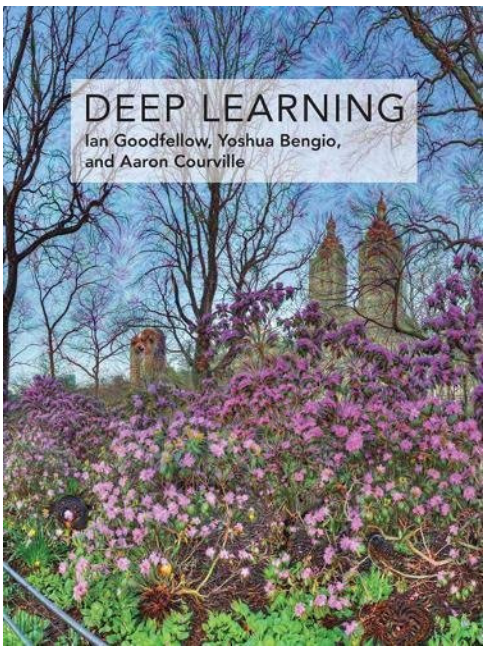

http://www.deeplearningbook.org

Bibliografía

Bibliografía en castellano

- Fernando Berzal:
  Redes Neuronales
  & Deep Learning
  Próximamente…